

**LITERATURE REVIEW
METODOLOGI PENELITIAN**

Identifikasi Emosi melalui Elektroensephalogram

Disusun untuk memenuhi tugas kelompok pada mata kuliah Metodologi Penelitian



KELOMPOK 1:

Nursilva Aulianisa Putri	3411181089
Rafi Azizi Muchtar	3411181123
Novia Putri Syahida	3411181137
Iman Muhdi	3411181173

**PROGRAM STUDI INFORMATIKA
FAKULTAS SAINS DAN INFORMATIKA
UNIVERSITAS JENDERAL ACHMAD YANI**

2021

PENCARIAN LITERATUR

1.1. Keyword yang digunakan untuk pencarian

Berdasarkan proses pencarian melalui berbagai situs jurnal online, maka diperoleh penggunaan keyword, sumber dan hasil pencarian sebagai berikut :

- a. Keyword : Identification EEG Emotion
 Sumber : IEEE Xplore | Science Direct | IOP Science | Springer
 Link
 Hasil pencarian : 49 Result | 2.458 Result | 37 Result | 2.495 Result
- b. Keyword : EEG Emotion Classification
 Sumber : IEEE Xplore | Science Direct | IOP Science
 Hasil pencarian : 445 Result | 2.473 Result | 76 Result

1.2. Hasil pencarian dalam bentuk tabel

Database (IEEE Explorer / Science Direct / Google Scholar / Springer Link / IOP Science)	Keyword	Jumlah hasil pencarian yang muncul	Jumlah hasil filter setelah membaca abstrak	Referensi (dalam sitasi) hasil filter
IEEE Xplore	Identification EEG Emotion	49	electroencephalography (42) emotion recognition (32) medical signal processing (31) feature extraction (19) neurophysiology (14) signal classification (14) support vector machines (12) learning (artificial intelligence) (11) pattern classification (7) brain (6) cognition (6) biometrics (access control) (5) brain-computer interfaces (5) human computer interaction (4) music (4)	[2] [4] [17]


			neural nets (4) psychology (4) convolutional neural nets (3) face recognition (3) signal processing (3) wavelet transforms (3) artificial intelligence (2) bioelectric potentials (2) biomedical electrodes (2) decision trees (2)	
IEEE Xplore	EEG Emotion Classification	445	electroencephalography (514) emotion recognition (426) medical signal processing (399) signal classification (312) feature extraction (294) support vector machines (159) learning (artificial intelligence) (142) neurophysiology (93) brain-computer interfaces (74) pattern classification (71) human computer interaction (53) image classification (45) wavelet transforms (44) psychology (43) convolutional neural nets (42) music (42) neural nets (42) brain (40) entropy (31) feature selection (31) face recognition (24) medical image processing (22) cognition (21) medical disorders (21) medical signal detection (20)	[3] [5] [6] [7] [8] [13] [14] [15] [16] [18] [20]
Science Direct	Identification EEG Emotion	2.458	Neuroscience (1,419) Psychology (819) Medicine and Dentistry (794) Computer Science (305) Engineering (230) Social Sciences (125)	[11]


			Biochemistry, Genetics and Molecular Biology (97) Pharmacology, Toxicology and Pharmaceutical Science (58) Agricultural and Biological Sciences (51) Nursing and Health Professions (31)	
Science Direct	EEG Emotion Classification	2.473	Neuroscience (1,185) Medicine and Dentistry (837) Psychology (581) Computer Science (542) Engineering (356) Social Sciences (125) Biochemistry, Genetics and Molecular Biology (82) Agricultural and Biological Sciences (48) Pharmacology, Toxicology and Pharmaceutical Science (47) Decision Sciences (35)	[1] [9]
IOP Science	Identification EEG Emotion	37	J. Neural Eng. (25) Physiol. Meas. (4) Biomed. Phys. Eng. Express (2) IOP Conf. Ser.: Mater. Sci. Eng. (1)	[10]
IOP Science	EEG Emotion Classification	76	J. Neural Eng. (43) J. Phys.: Conf. Ser. (10) Physiol. Meas. (6) IOP Conf. Ser.: Mater. Sci. Eng. (6) Biomed. Phys. Eng. Express (2) Quantum Electron. (1) Phys.-Usp. (1)	[12]
Springer Link	Identification EEG Emotion	2.495	Medicine & Public Health (581) Psychology (401) Engineering (397) Computer Science (385) Biomedicine (306) Neurosciences (516) Artificial Intelligence (394) Neurology (374) Psychiatry (311) Computational Intelligence (216)	[19]

Pada setiap database dilakukan pencarian dengan keyword ‘Identification EEG Emotion’ dan ‘EEG Emotion Classification’. Jurnal dipilih berdasarkan kebaruan tahun rilis dan kesesuaian dengan topik khusus identifikasi emosi dengan EEG, kami mengabaikan jurnal dengan tema yang sedikit mirip yaitu BCI. Selanjutnya, dipilih jurnal dengan judul yang menarik dan sekiranya dapat kami pahami, lalu membaca abstrak dan memilih mana yang lengkap meliputi keseluruhan bagian yang ditugaskan seperti dataset, kebaruan, metode, hingga akurasi.

Adapun kami melakukan pencarian pada 4 database kemudian melakukan filter seperti yang telah dijelaskan diatas. Dari hasil pencarian dan filtering tersebut, kami mendapatkan 14 referensi dari database IEEE Xplore [2] [3] [4] [5] [6] [7] [8] [13] [14] [15] [16] [17] [18] [20], 3 referensi dari database Science Direct [1] [9] [11], 2 referensi dari database IOP Science [10] [12], dan 1 referensi dari database Springer Link [19].

1.3. Jumlah Paper tiap tahun dalam keyword terkait dalam bentuk grafik (jumlah vs tahun)





LITERATUR REVIEW

2.1. **Ceritakan kebaruan atau hal yang difokuskan dalam paper tersebut. Hal ini berelevan dengan result**

Pada penelitian ini, kebaruan yang dilakukan terletak pada penggunaan metode komputasi yang digunakan, dimana proses klasifikasi dilakukan dengan menerapkan metode CNN (Convolutional Neural Network) terhadap data input gambar spektrogram dinamika sinyal EEG dengan penggunaan 3 kelas, yaitu Fear (takut), fun (senang), dan sadness (sedih). Penelitian ini berhasil mencapai akurasi sebesar 84,69% [1].

Penelitian ini berfokus terhadap pengembangan penggunaan sistem pengenalan sinyal EEG dengan menerapkan metode ekstraksi Wavelet pada penerapan metode LVQ (Learning Vector Quantization). Penelitian Ini berhasil membuktikan bahwa dengan menggunakan metode ekstraksi Wavelet dapat meningkatkan akurasi sistem sebesar 15%. Penelitian ini juga menambahkan proses ekstraksi dengan menggunakan gelombang asimetris terhadap konfigurasi tiga gelombang sinyal EEG, yaitu theta, alpha, dan beta. Penelitian ini juga membuktikan bahwa dengan penggunaan gelombang asimetris pada proses ekstraksi mampu meningkatkan akurasi jika dibandingkan tanpa penggunaan gelombang asimetris sebesar 3% [2].

Pada penelitian ini, kebaruan yang dilakukan terdapat pada penggunaan kerangka kerja gabungan metode antara MLF (Multi – Level Features) – CapsNet terhadap pengenalan emosi sinyal EEG multi – kanal. Penelitian ini menggabungkan penggunaan fitur multi – level yang diekstraksi pada lapisan konvolusi yang berbeda dalam membentuk primary capsules. Penelitian ini juga menambahkan penerapan metode bottleneck untuk mengurangi jumlah parameter serta mempercepat proses komputasi dengan hasil berupa

peningkatan akurasi klasifikasi sebesar 0,3% pada dataset DEAP dan 1% pada dataset dreamer [3].

Penelitian ini berfokus terhadap usulan penggunaan metode identifikasi berbasis aturan dan algoritma Decision Tree untuk klasifikasi pengenalan emosi menggunakan sinyal EEG. Penelitian ini melakukan perbandingan terhadap 3 penerapan metode berbasis aturan, yaitu algoritma Rule – Based (RIPPER), algoritma Decision Tree (J4.8) dan Support Vector Machine (SVM) [4].

Pada penelitian ini berfokus dalam menyelidiki fitur yang dapat diandalkan di antara ketiga fitur dari metode time domain (mean, standard deviation dan number of peaks) untuk pengenalan emosi berbasis EEG. Dari hasil eksperimen menunjukkan bahwa dari ketiga fitur yang diujikan, terdapat satu fitur yaitu mean (rata-rata) yang memberikan hasil akurasi paling tinggi dibandingkan dengan kedua fitur lainnya yang diperoleh dari model klasifikasi Naive Bayes [5].

Pada penelitian ini berfokus dalam menyajikan pendekatan untuk deteksi keadaan mental pasien menggunakan sinyal Electroencephalogram (EEG) yang akan diterapkan pada aplikasi sehingga dapat memberikan kemudahan dan kenyamanan pada pasien dalam mengetahui keadaan mentalnya. Dengan mencoba beberapa metode ekstraksi fitur (Discrete Wavelet Transform, Wavelet Energy/Wavelet Entropy dan Statistical-Based Features) dan klasifikasi (QDA, KNN dan SVM) untuk mendapatkan nilai akurasi yang tertinggi dalam menentukan nilai akurasi dari kelas emosi, didapatkan hasilnya pada metode klasifikasi SVM yang mendapatkan nilai akurasi tertinggi pada penelitian ini dalam mendeteksi kelas emosi yang diujikan dibandingkan dari kedua metode klasifikasi lainnya yang mendapatkan akurasi lebih rendah [6].

Pada penelitian ini berfokus untuk memvalidasi efisiensi dan efektivitas dari sistem yang dibuat, dimana berdasarkan hasil eksperimen dari 30 puluh

peserta yang menonton beberapa klip film emosional dengan menargetkan tujuh emosi dasar yang berbeda (joy, amusement, tenderness, anger, disgust, fear, sadness) dan neutrality. Sistem yang dihasilkan oleh penelitian ini telah mampu mendapatkan nilai akurasi yang lebih tinggi jika dibandingkan dengan sistem pengenalan emosi real-time terkini dari sinyal EEG lainnya dalam hal akurasi dan kemampuan untuk mengenali beberapa emosi diskrit serupa dalam ruang koordinat valence-arousal [7].

Penelitian ini berfokus pada sebuah metode Independent Component Analysis, Support Vector Machine dan Linear Discriminant Analysis yang digunakan untuk mendapatkan nilai akurasi dari beberapa kelas emosi yang diujikan. Dari hasil eksperimen mengatakan bahwa akurasi meningkat dengan bertambahnya jumlah sampel pelatihan dan dari hasil analisis akurasi kelas emosi yang dilakukan oleh penelitian ini diketahui bahwa metode SVM lebih baik dibandingkan dengan metode LDA sebagai pengklasifikasi [8].

Penelitian ini mengusulkan model baru untuk identifikasi emosi didasarkan pada pembuatan peta fitur berdasarkan representasi karakteristik sinyal EEG topografi (TOPO-FM) dan holografik (HOLO-FM). Kemudian ekstraksi fitur dari peta fitur menggunakan deep learning, lalu fitur yang diekstraksi digabungkan bersama untuk proses klasifikasi [9].

Penelitian ini mengusulkan model identifikasi emosi EEG baru bernama TF-LSTM (Time Frequency-Long Short Term Memory). Dengan TF, ekstraksi sinyal EEG menggunakan time-slide window yang berbeda dan menggabungkan karakteristik statistik domain time-frequency dari 4 pita frekuensi dengan LSTM untuk mendapatkan fitur urutan EEG untuk pengenalan emosi [10].

Penelitian ini mengidentifikasi fitur-fitur yang dapat membedakan emosi dengan baik. Fitur-fitur yang diidentifikasi adalah power, entropi, dimensi

fraktal, statistik atau wavelet. Fitur diekstraksi dengan PCA kemudian diklasifikasikan menggunakan 3 metode yang berbeda yaitu SVM, KNN dan Decision Tree [11].

Penelitian ini berfokus pada metode KNN yang memiliki kinerja baik dalam pengenalan emosi berbasis EEG. Namun, nilai penghitungan jarak Euclidean pada knn tidak mewakili nilai fitur yang penting. Oleh karena itu penelitian ini mengusulkan klasifikasi emosi berdasarkan K-star yang dapat mengatasi kekurangan pada KNN, juga membandingkannya dengan sejumlah metode pembelajaran mesin lainnya termasuk KNN [12].

Pada penelitian ini berfokus mengenai cara mengecualikan sebuah data yang kurang penting dengan mengurangi kompleksitas komputasi, metode ekstraksi fitur menggunakan Intrinsic Mode Function (IMF) yang dominan di antara IMF lainnya. Lain dari itu setelah tahapan pencarian IMF dominan maka dilakukan proses lokalisasi waktu dan frekuensi menggunakan metode District Wavelet Transform (DWT) menggunakan db5 wavelet. Parameter yang digunakan pada penelitian ini yaitu High Order Statistic (HOS). Proses reduksi fitur menggunakan PCA yang mempengaruhi hasil akhir mengenai akurasi dari model komputasi yang dibangun [13].

Dalam penelitian ini, Convolutional Neural Network diimplementasikan pada data citra virtual untuk mengklasifikasikan emosi. Data EEG mentah dilakukan reshaping, decomposition dan kemudian PCC dihitung untuk membangun citra virtual unggulan. Untuk peningkatan lebih lanjut akan mungkin dilakukan dengan mengambil sekumpulan besar data untuk melatih model. Convolutional Neural Network dengan input data yang signifikan sangat efektif dan potensial dalam penelitian yang terkait dengan sinyal otak manusia [14].

Pada penelitian ini telah dilakukan pengenalan emosi menggunakan sinyal EEG berbasis stimulus visual.. IMF1 dan IMF2 menunjukkan hasil yang paling signifikan dalam keadaan valence, arousal, dominance. Parameter Hjorth sangat efektif sebagai fitur. Kanal diperiksa secara terpisah untuk menemukan aktivitas kanal terbaik. Hasil yang lebih baik diperoleh di lobus oksipital, aktivitas kanal terbaik telah diperoleh dari saluran Fp2, F4, F8, FC4, FT8, T7, Cz, C4, T8, CPz, CP4, Pz, O2 EEG untuk pengenalan emosi [15].

Pada penelitian ini berfokus mengenai perbandingan antara metode klasifikasi CNN dengan SVM, KNN maupun PNN. Sebelum proses konvolusi, terdapat sebuah proses fitur reduksi menggunakan metode PCA. Model komputasi CNN digunakan untuk mengklasifikasikan data input menjadi 2 kelas yaitu valence dengan 2 kategori yaitu non-active (boring, tired) dan active (alertness, excitement). Sedangkan kelas lainnya yaitu Arousal dengan 2 kategori non-pleasant (sadness, stress) dan pleasant (happy). Masing masing dari kelas tersebut menghasilkan nilai akurasi rata-rata 84,3% untuk valence dan 81,2% untuk arousal [16].

Penelitian ini berfokus terhadap perbandingan klasifikasi antara penerapan metode Hidden Markov Model (HMM) dengan Support Vector Machine (SVM) dengan menerapkan metode ekstraksi menggunakan Discriminative Frequency Components (DFC). Proses ekstraksi tersebut dilakukan dengan menerapkan metode Short Time Fourier Transform dalam menghitung Power Spectral Density (PSD). Penelitian ini berhasil membuktikan peningkatan akurasi sebesar 12,85% dengan penerapan metode DFC terhadap metode klasifikasi Support Vector Machine dan peningkatan sebesar 11,77% terhadap penerapan metode DFC terhadap metode klasifikasi Hidden Markov Model (HMM) [17].

Penelitian ini berfokus terhadap metode ekstraksi fitur Time Frequency Domain (TFD), reduksi dimensi data Principal Component Analysis (PCA) dan klasifikasi menggunakan Jaringan Syaraf Tiruan Backpropagation pada sinyal EEG, dimana setiap metode ekstraksi fitur yang berbeda dapat menghasilkan hasil klasifikasi yang berbeda. Tingkat pengenalan emosi terbaik yang didapatkan pada penelitian ini adalah 63,75%. Dari percobaan ini juga dapat disimpulkan bahwa fitur sebagai input untuk classifier memegang peranan penting untuk hasil klasifikasi, jadi semakin efektif fitur yang diambil dari data maka semakin baik hasil klasifikasinya [18].

Pada penelitian ini berfokus terhadap perbandingan 2 fitur EEG, yaitu power spectrum dan fusion dalam melakukan pengenalan emosi. Fitur fusion merupakan gabungan dari fitur power spectrum dan wavelet entropy energy. Fitur power spectrum diekstraksi dengan metode STFT, sementara fitur wavelet entropy energy diekstraksi menggunakan metode DWT. Selanjutnya untuk mendapatkan kelas emosi, dilakukan klasifikasi dengan metode SVM dan RVM [19].

Pada penelitian ini berfokus dalam menggunakan metode Dekomposisi Wavelet dan K-Nearest Neighbor untuk meningkatkan akurasi mengenai klasifikasi emosi berbasiskan sinyal EEG. Proses ekstraksi fitur mengenai dekomposisi wavelet dibagi menjadi 2 untuk melakukan perbandingan yaitu daubechies2 dan coiflet2. Hasil penelitian menunjukkan bahwa nilai k optimum pada parameter K-Nearest Neighbor untuk penelitian ini adalah 21. Proses ekstraksi fitur dekomposisi wavelet dengan 2 metode mempengaruhi hasil akhir mengenai akurasi dari model komputasi yang dibangun, sehingga hal tersebut dijadikan perbandingan di akhir penelitian [20].

2.2. Karakteristik data yang digunakan

a. Berikan sumber data (jika disebut dituliskan, jika merekam sendiri tuliskan)

Perolehan data pada beberapa penelitian didapatkan dari dataset DEAP (Dataset for Emotion Analysis using Physiological Signals) dengan 32 partisipan (16 pria dan 16 wanita) yang dilakukan rekaman terhadap reaksi dalam menonton 40 video musik berdurasi 1 menit [3] [4] [6] [9] [11] [12] [13] [14] [16] [18] [20]. Total rekaman data yang diperoleh dari DEAP dengan 32 subjek menghasilkan 1280 buah data [4][16]. Selain dataset DEAP terdapat penggunaan berbagai dataset yaitu DREAMER dengan 23 partisipan (14 pria dan 9 wanita) [3] [9], SEED (SJTU emotion EEG Dataset) sebanyak 15 partisipan (7 pria dan 8 wanita) [9], AMIGOS dikumpulkan dari 40 partisipan [9], IAPS (International Affective Picture System) dengan 48 gambar, IADS (International Affective Digitized Sounds) dengan 48 suara untuk stimulus [15] dan beberapa data rekaman manual dengan berbagai partisipan yaitu 10 partisipan [1] [2], 12 partisipan (7 pria dan 5 wanita) [5], 30 mahasiswa sarjana atau pascasarjana (30 Pria) [7], 32 partisipan (18 pria dan 14 wanita) [8], 10 orang dewasa (5 pria dan 5 wanita) [10] [19], 25 partisipan (12 pria dan 12 wanita) [15], dan 13 partisipan (6 pria dan 7 wanita) [17].

Setiap subjek atau partisipan harus mengikuti beberapa syarat seperti usia yang memadai untuk melakukan perekaman sinyal EEG, rentang usia partisipan pada berbagai data sebagai berikut : 24 - 33 tahun [1], 20 - 25 tahun [2] [8], 18 - 38 tahun [5], 19 - 32 tahun [6], 19 - 26 tahun [7], 19-37 tahun, 22 - 33 tahun [9] [11] dan 23-26 tahun[10], 22-25 tahun [17] dan 21-24 tahun [19]. Selain itu terdapat syarat mengenai kesehatan untuk melakukan perekaman sinyal EEG seperti tidur cukup antara 7 – 9 jam, melakukan olahraga ringan, sudah makan terlebih dahulu [2], tidak

memiliki penyakit kronis seperti stroke, gagal jantung, diabetes dan penyakit kronis lainnya [5] [17], mengambil tembakau maupun kafein selama 24 jam sebelum percobaan [7], penglihatan normal, pendengaran normal, tidak memiliki riwayat perawatan medis yang parah maupun gangguan psikologis / neurologis [17] [19], dan tidak kidal [19].

Perangkat yang digunakan untuk melakukan rekaman sinyal EEG kepada subjek/partisipan memiliki perbedaan pada setiap penelitian, seperti Emotiv EPOC [9] [19] yang merupakan sebuah headset EEG nirkabel 14-elektroda dengan frekuensi sampling 128 Hz [7] atau 256 Hz [5], BioSemi Active Two [9] [10] [14] [16] [17] [20], EEG headset Mind Wave [10], Brain Vision BrainAmp EEG [15] maupun EEG ESI Neuro Scan System [9]. Perangkat rekaman sinyal EEG yang digunakan memiliki dua posisi penempatan elektroda yaitu 14 elektroda [3] [5] [7] ataupun 10-20 elektroda [1] [6] [14] [20] sesuai dengan penggunaan di setiap penelitian.

b. Jumlah kelas dan sebutkan kelas yang digunakan

Penelitian ini dilakukan klasifikasi ke dalam 2 kelas, yaitu Happy dan Sad [5], Arousal (passive/active), Valence (negative/positive) [9], Valence dengan 2 kategori non-active (boring, tired) active (alertness, excitement) dan Arousal dengan 2 kategori non-pleasant (sadness, stress) pleasant (happy) [16].

Penelitian ini dilakukan pengklasifikasian sinyal ke dalam 3 kelas, yaitu Fear, Sadness, dan Fun [1], Excited, Relax, dan Sad [2], Valence low/high, Arousal low/high, dan Dominance low/high [3], Arousal (Low/High), Valence (Low/High) dan Dominance (Low/High) [11], Netral, Positif (happiness) dan Negative (sadness) [10][19].

Penelitian ini dilakukan klasifikasi terhadap sinyal ke dalam 4 kelas, yaitu happy, sad, angry dan relaxed [4][17], High valence/High arousal (happy/excited), High valence/Low arousal (relaxed/calm), Low valence/High arousal (angry/fear) dan Low valence/Low arousal (sad/depressed) [6][18], High valence, High arousal, Low valence dan Low arousal [12][20], Valence (low/high), Dominance (low/high), Arousal (low/high) dan Liking (low/high) [13].

Penelitian ini terdapat 5 kelas emosi berdasarkan rating 1-9 yaitu valence, arousal, dominance, liking dan familiarity (rating 1-5) [14].

Penelitian ini dilakukan pengklasifikasian sinyal ke dalam 6 kelas, yaitu Valence (happiness dan unhappiness), Arousal (calmness dan excitement), dan Dominance (domination dan control of emotions) [15].

Penelitian ini dilakukan klasifikasi terhadap sinyal ke dalam 7 kelas, yaitu happy, sad, anger, disgust, neutral, fear dan surprised [8].

Penelitian ini dilakukan klasifikasi sinyal dengan jumlah 8 kelas yang dikategorikan berdasarkan 3 kategori emosi positif (joy, amusement, tenderness), empat kategori emosi negatif (anger, sadness, fear, disgust), dan keadaan netral [7].

c. Dimensi data misalnya ukuran tiap frame & fps (video), lokasi (curah hujan), durasi waktu satu set data, waktu prediksi (curah hujan), kanal (sinyal EEG), stimulasi (jika ada, khusus sinyal EEG).

Pada penelitian ini, data input yang digunakan adalah citra gambar spektogram yang diperoleh dari sinyal otak menggunakan kanal Fp1. Penempatan elektroda dipasang pada dahi bagian Frontal Polar – belahan kiri dengan sampling rate 512 Hz. Stimulasi yang diberikan selama proses

perekaman yaitu peserta disajikan video yang telah di edit khusus dengan total durasi 224 detik. Dalam sample video tersebut, terdapat beberapa adegan sedih, lucu dan menakutkan untuk membuat respons emosional peserta. Proses perekaman berlangsung bersamaan pada saat video stimulasi ditetel yang direkam melalui laptop dengan jarak 30 cm dari partisipan. Proses perekaman dilakukan pada ruangan terisolasi dengan aturan dimana peserta tidak diperbolehkan untuk melakukan gerakan tubuh apapun [1].

Penelitian selanjutnya, dilakukan dengan menggunakan data sinyal EEG pada kanal AF3, T7, T8 dan AF4 dengan pemberian stimulus berupa lagu instrumental yang dapat membangkitkan gelombang beta atau keadaan terkesitasi (excited) selama 3 menit. Pada sesi selanjutnya subjek diberikan waktu istirahat selama 30 menit dengan stimulus berupa music instrumental yang dapat menghasilkan gelombang alpha untuk menghasilkan kondisi emosi rileks. Pada sesi selanjutnya subjek diberikan stimulus berupa suara yang dapat membangkitkan gelombang theta untuk menghasilkan kondisi emosi sedih pada peserta [2].

Penelitian dengan dataset DEAP, stimulus yang diberikan terhadap subjek partisipan selama proses perekaman adalah berupa 40 video musik berdurasi satu menit, kemudian pada sesi selanjutnya, setiap peserta diberikan kuisioner untuk mengukur respons emosional yang dirasakan setelah menonton setiap video [3] [4] [6] [9] [11] [12] [13] [14] [16] [20]. Penelitian dengan dataset DREAMER stimulus yang diberikan adalah dengan menonton 18 klip film berdurasi antara 65 - 393 detik untuk memunculkan 9 emosi yang berbeda [3] [9]. Penelitian dengan dataset AMIGOS menggunakan 14 kanal dan sampling rate 128Hz, subjek diberi stimulus 16 klip video pendek [9]. Kemudian penelitian dengan dataset SEED menggunakan 62 kanal, subjek diberi stimulus berupa 5 klip film yang menggambarkan emosi [9].

Penelitian lain melakukan perekaman sinyal EEG dengan stimulus video lucu selama 12 menit kemudian dilanjutkan dengan video sedih selama 6 menit [5], klip film Cina dengan resolusi berukuran 720 x 576 piksel yang disajikan secara acak pada layar LCD 15 inci [7]. Kemudian terdapat beberapa stimulus berupa gambar yaitu sebuah gambar dari setiap kelas emosi sebanyak 35 gambar yang dibagi ke dalam 5 kelompok (1 kelompok memiliki 7 tampilan gambar dari setiap emosi) [8], kelompok gambar makanan berlabel emosi netral, positif dan negative. Pada setiap percobaan, 10 detik pertama subjek diberikan 5 gambar uji relaksasi yang tidak terkait dengan emosi, selanjutnya diberikan 15 gambar secara berurutan dengan total durasi 120 detik [10]. Selanjutnya disajikan 45 gambar pada layar PC 21 inci yang ditempatkan didepan subjek selama 6 detik [17].

Penelitian selanjutnya menggunakan data sinyal EEG pada kanal F7, T7, C3, C4 dan O2 [4], kemudian pada beberapa penelitian menggunakan 4 kanal menurut sistem standar 10-20 dengan kanal Fp1, Fp2, F3, F4 [6] dan kanal Fp1, F3, P3, O1 [8] yang ditempatkan pada kulit kepala subjek. Kemudian digunakan juga 4 kanal dan frekuensi sampling sebesar 256 Hz sehingga didapatkan panjang data sebesar 46.080 ($256 \text{ Hz} * 3 \text{ menit} * 60 \text{ detik}$), sehingga total dimensi data adalah 4 kanal x 46.080 titik data. [5]. Penelitian menggunakan berbagai jumlah kanal untuk dataset DEAP yaitu 32 kanal dengan frekuensi sampling 512Hz [9] [14] [15], 23 kanal [12] dan 14 kanal [7] [9] [11] yang diekstraksi dalam 5 pita frekuensi, yaitu delta (1–4 Hz), theta (4–8 Hz), alfa (8–12 Hz), beta (13–30 Hz), dan gamma (31–45 Hz) [7] [9].

Pada penelitian ini, partisipan diberikan stimulus menggunakan gambar selama 22 menit, dimana pada setiap gambar di 1 menit awal partisipan harus memusatkan focus, 6 detik setelahnya diberikan stimulasi dan 14 detik kemudian partisipan melakukan penilaian tentang stimulus tersebut dengan range 1 - 9. Setelah melakukan penilaian terdapat 1 detik black

screen untuk melanjutkan ke gambar kedua hingga 60 gambar selesai dilihat oleh partisipan. Total data yang diperoleh sebanyak 25 partisipan*60 gambar = 1500 data [15].

Beberapa penelitian berfokus terhadap penggunaan data sinyal EEG pada 32 kanal, yaitu AF3, AF4, F3, F4, F5, F6, F7, F8, FC3, FC4, FC5, FC6, C3, C4, C5, C6, CP3, CP4, CP5, CP6, P3, P4, P5, P6, P7, P8, PO3, PO4, PO5, PO6, O1, O2 [17] dan pada 4 kanal yaitu F3, F4, P3 dan P4. Pada penelitian tersebut menggunakan data DEAP sehingga ukuran data sebesar 40 x 40 x 8064 (video x channel x data) dan label DEAP 40 x 4 (Video x valence, dominance, liking) [16].

Pada penelitian ini, 32 kanal data otak, 8 kanal data wajah (EOG) dan data otot (EMG) digunakan oleh dataset DEAP untuk memperoleh sinyal EEG. Stimulus yang diberikan merupakan sebuah video yang dapat memicu emosi valence dan arousal subjek [18]. Penelitian selanjutnya dengan perolehan data oleh peneliti, subjek diberi stimulus 30 klip video yang berdurasi 10 hingga 30 detik yang berisi tiga keadaan emosi yaitu neutral, happiness dan sadness. Sinyal EEG didapatkan dari perangkat dengan frekuensi 128 Hz dan 12 kanal yaitu AF3, AF4, F3, F4, F7, F8, FC5, FC6, P7, P8, O1, dan O2 [19].

2.3. Metode – metode yang digunakan (Uraikan tiap bagian metode : ekstraksi dan identifikasi)

a. Pra proses

Pada penelitian ini, setelah melalui tahap perolehan data melalui perekaman sinyal, selanjutnya tahap pra-proses dilakukan untuk memperoleh data input dalam bentuk citra gambar spektogram. Perolehan data input tersebut didapatkan dengan menganalisis data sinyal EEG berdasarkan frekuensi dan waktu. Pada tahap awal, sinyal disegmentasi

kedalam 3 bagian sesuai dengan kelas yaitu takut, sedih dan senang. Sinyal yang sudah disegmentasi selanjutnya dipetakan kedalam fungsi 2 dimensi yang terdiri atas waktu dan frekuensi agar dapat memperoleh informasi pada sinyal. Selanjutnya, dilakukan tahap ekstraksi informasi dengan menggunakan penerapan metode Short Time Fourier Transform (STFT). Hasil perhitungan koefisien pada penerapan metode STFT tersebut selanjutnya di kuadratkan untuk memperoleh ukuran citra spektogram sebagai input pada proses pembelajaran [1].

Pada penelitian ini, setelah memperoleh data perekaman sinyal EEG pada 10 subjek, selanjutnya data sinyal tersebut disegmentasi setiap 10 detik. Kemudian proses ekstraksi dilakukan untuk memisahkan antara gelombang Alpha, Beta, dan Theta dengan menggunakan metode Wavelet. Pada tahap selanjutnya, masing masing gelombang diidentifikasi menggunakan Learning Vector Quantization [2].

Pada penelitian ini, tahap pra-proses dilakukan dalam 2 tahap, dimana pada tahap pertama sinyal EEG mentah dipotong kedalam M1 segmen dengan panjang yang sama pada kedua dataset. Pada tahap kedua, dilakukan penambahan elemen pada setiap segmen dan menghitung rata rata untuk mendapatkan nilai x yang mewakili keadaan emosi subjek tanpa stimulus apapun. Selanjutnya dilakukan penggabungan antara sinyal eksperimental kedalam matriks baru bernama Y dengan ukuran yang sama [3].

Pada penelitian ini, tahap pra-proses diawali dengan melakukan downsampling terhadap data sinyal EEG hingga mencapai frekuensi 128 Hz [4] [13] [14] [17] [18], 256 Hz [20]. Salah satu penelitian melakukan proses downsampling dengan menerapkan teknik blind source separation [4]. Selanjutnya tahapan pra – proses dilanjutkan dengan menerapkan filter Band – Pass pada frekuensi (4–45 Hz) [4] [6] [14], (4–47 Hz) [18] (1–50 Hz) [5] [18], (1–45 Hz) [7] [16], dan (0,2–45 Hz) [8]. Sementara itu,

penelitian lain menerapkan filter Band-Pass untuk membagi data sinyal kedalam kelompok frekuensi gelombang otak, yaitu alpha, beta [5], gamma [12] [13], theta [4], dan delta [8] [14]. Penelitian lain menerapkan proses filtering dengan Chebishev type II [4] [5], menggunakan Hamming Window [18], serta Butterworth IIR bandpass [20]. Hal tersebut dilakukan untuk menentukan masing masing rentang frekuensi pada setiap gelombang, diantaranya yaitu gelombang theta (4–7 Hz) [18] (4–8 Hz) [5], alpha (8–12 Hz) [5] (8–15 Hz) [18], beta (12–30 Hz) [5] (16–31 Hz) [18] dan gamma (30–45/50 Hz) [4] [8] (>32 Hz) [18]. Selanjutnya pada beberapa penelitian, proses klasifikasi dilakukan dengan menggunakan metode Independent Component Analysis (ICA) [5] [7] [8], sementara sumber lain menerapkan metode Independent Component Analysis (ICA) untuk menghapus artefak EOG [17], untuk mendapatkan data EEG yang lebih jelas yang hanya berisi aktivitas otak [5], menguraikan seluruh dataset pelatihan sinyal EEG menjadi 14 Independent Components (ICs) [19] yang dicirikan oleh oleh topografi dan Power Spectral Density (PSD) [7], serta untuk menolak komponen noise dari sinyal yang diperoleh [8].

Dalam penelitian ini, tahap pra-proses dilakukan menggunakan transformasi wavelet diskrit (DWT) dengan mother wavelet 'db5' mendekomposisi setiap kanal (1 kali percobaan/1 peserta) menjadi lima pita frekuensi. Kemudian memertakan setiap fitur dengan TOPO-FM dan HOLO-FM. TOPO-FM menggunakan setiap karakteristik sinyal EEG secara terpisah, kemudian memetakannya ke dalam peta fitur dua dimensi untuk masing-masing dari lima pita frekuensi. Setelah itu ruang kosong pada matriks diinterpolasi, dan peta warna “jet” diterapkan untuk membentuk peta topografi lengkap dari fitur tertentu. Sedangkan HOLO-FM menghitung karakteristik setiap pita frekuensi pada setiap kanal dan

dipetakan ke dalam area spasial, kemudian memetakan objek tiga dimensi ke dalam bidang, dan menampilkannya sebagai gambar dua dimensi [9].

Pada penelitian ini, pra-proses dilakukan menggunakan Transformasi Wavelet Stasioner (SWT) untuk menghilangkan noise dari EEG mentah, kemudian menggunakan Transformasi Wavelet untuk menguraikan sinyal EEG yang telah diproses sebelumnya dan mengekstrak empat pita frekuensi yaitu Alfa (8–16 Hz), Beta Rendah (16–24 Hz), Beta Tinggi (24–32Hz) dan Gamma (32–40 Hz) [10].

Pada penelitian ini, pra-proses dilakukan dengan mengekstraksi 14 kanal (AF3, F3, F7, FC5, T7, P7, O1, O2, P8, T8, FC6, F8, F4, dan AF4) dari 32 kanal yang berasal dari sumber data. Setiap kanal memiliki 40 rekaman EEG berdurasi 1 menit, rekaman tersebut disegmentasi dengan menghilangkan 20 detik pertama karena memungkinkan emosi pada detik tersebut adalah perubahan mood dari video sebelumnya, bukan emosi sebenarnya dari video yang sedang ditonton. 40 detik selanjutnya disegmentasi menjadi 4 segmen berdurasi 10 detik [11].

Pada penelitian ini, 1500 data yang diperoleh dilakukan filterisasi 0.7 Hz low pass filter, 250 Hz high pass filter, 50 Hz notch filter. Hasil filterisasi tersebut kemudian dilanjutkan untuk melakukan dekomposisi menggunakan EMD (Empirical Mode Decomposition). agar dapat menghasilkan IMF(Intrinsic Mode Functions) [15].

Pada tahapan pra-proses, dilakukan normalisasi data dimana data mentah tersebut distandarisasi. Setelah data mentah distandarisasi maka setiap index yang berada dalam urutan yang besarannya sama dilakukan evaluasi secara komparatif dan komprehensif. Setiap dimensi diproses untuk menghindari pengaruh besar dari dimensi yang berbeda pada perhitungan algoritma klasifikasi atau clustering. Sehingga metode standarisasi data memproses nilai mean dan standar deviasi dari data asli, dengan nilai 0 untuk mean dan 1 untuk standar deviasi [16].

b. Metode ekstraksi sinyal, penanganan kanal, dan identifikasi (khusus sinyal EEG), metode identifikasi arah spasial dan arah temporal (video, dapat disederhanakan), metode prediksi (cuaca)

Pada penelitian ini, proses ekstraksi fitur yang digunakan adalah Short Time Fourier Transform (STFT) [1][7][19]. Ditinjau berdasarkan informasi waktu diskrit pada sinyal dan tahap transformasi tersebut dihitung menggunakan persamaan Discrete Time Fourier (DTFT) kemudian hasil keluarannya dijadikan masukkan pada metode CNN dengan lapisan klasifikasi menggunakan Multi Layer Perceptron dan pada penelitian [1]. Dalam mengenali emosi diskrit secara real time digunakan pendekatan sliding time window selain STFT untuk ekstraksi fitur dan normalisasi berdasarkan analisis Time-Frequency (TF) [7]. Fitur power spectrum diekstraksi menggunakan metode STFT yaitu membagi sinyal waktu yang lebih panjang menjadi segmen-segmen yang lebih pendek dengan panjang yang sama dan menghitung spektrum Fourier pada setiap segmen yang lebih pendek. Fitur power spectrum berada pada 4 pita frekuensi yaitu theta (4–7 Hz), alfa (8–12 Hz), beta (13–30 Hz) dan gamma (30–47 Hz).

Pada penelitian ini, metode ekstraksi fitur yang digunakan adalah Discrete Wavelet Transform (DWT) [2][6][13][19]. Proses transformasi dilakukan dengan menerapkan fungsi Symlet2 dengan empat koefisien pada filter low pass dan high pass yang dalam proses ekstraksinya dalam memperoleh gelombang Theta dilakukan dengan melalui 5 tahap dengan mendekati rentang frekuensi 5–8 Hz yang menghasilkan 8 titik, untuk menghasilkan sinyal Alpha dilakukan ekstraksi pada rentang 9–14 Hz yang menghasilkan 12 titik, untuk memperoleh gelombang Beta dilakukan dengan mengekstraksi gelombang pada rentang 15–31 Hz yang

menghasilkan 36 titik dan setelah melakukan ekstraksi menggunakan Wavelet, proses dilanjutkan dengan mereduksi 128 titik menjadi 56 titik dengan penggunaan 3 jenis gelombang, maka total input yang digunakan pada LVQ berjumlah 1680 data. Tahap identifikasi dilakukan berdasarkan hasil ekstraksi wavelet terhadap 3 gelombang setiap 10 detik pada setiap kanal dengan mempertimbangkan keadaan emosi pada kanal simetris dan asimetris, sehingga dengan menggunakan 10 detik data didapatkan jumlah titik yang digunakan berjumlah 560 titik [2]. Proses ekstraksi diterapkan untuk menguraikan sinyal EEG menjadi satu set sub-band melalui filtering time domain high-pass dan low-pass kemudian untuk mendeteksi perubahan sinyal EEG pada laju sampling 128Hz maka wavelet Daubechies (db4) digunakan dalam mengekstrak sub-band gelombang otak (Delta, Theta, Alpha, Beta, Gamma) [6]. Proses dekomposisi menggunakan EMD (Empirical Mode Decomposition) untuk menganalisa non-linear dan non-stationary sinyal dan EMD tersebut juga digunakan untuk menguraikan sinyal primer dan menghasilkan IMF (Intrinsic Mode Functions) kemudian setelah menghasilkan IMF maka dilakukan pencarian IMF dominan yang akan dilakukan proses DWT menggunakan wavelet db5 untuk melakukan lokalisasi waktu dan frekuensi ketika proses transformasi Fourier kehilangan informasi waktu disaat melakukan konversi dari sinyal menjadi domain frekuensi, saat proses DWT selesai maka dilakukan pengolahan pada koefisien DWT untuk mencari HOS (Higher Order Statistics) dari beberapa nilai yaitu perbedaan, skewness dan kurtosis untuk pembentukan fitur dari vector [13]. Fitur wavelet entropy energy diekstraksi dengan metode DWT yang dapat secara otomatis menyesuaikan window size sesuai dengan frekuensi, kemudian mengolah matriks koefisien transformasi wavelet menjadi barisan distribusi probabilitas dan menggunakan nilai entropi barisan tersebut untuk mencerminkan matriks koefisien sparseness [19].

Pada penelitian ini, proses ekstraksi fitur yang digunakan adalah TDF (Time Domain Features) [4][5][11][18]. Penerapan metode TDF yang meliputi penggunaan fitur statistic, parameter Hjorth, dan penggunaan dimensi fractal yang mana pada fitur statistic, variable yang ditinjau diantaranya meliputi variable deskriptif dasar pada statistic seperti rata rata sinyal, median, kekuatan frekuensi pita, standar deviasi, kurtosis, skewness, jumlah puncak maksimum, dan jumlah zero – crossing, sementara itu pada parameter Hjorth, fitur yang digunakan diperoleh berdasarkan kompleksitas, mobilitas dan aktivitas pada sinyal, kemudian pada penerapan dimensi fractal dilakukan dengan menggunakan metode algoritma Higuchi sebagai ekstraksi fitur pada domain frekuensi (FDF) dan penerapan metode Welch untuk meninjau kerapatan spectral data (PSD) dilanjutkan proses klasifikasi dilakukan dengan menerapkan tiga metode berbasis aturan, diantaranya yaitu algoritma Rule-Based, algoritma Decision Tree, dan Support Vector Machine (SVM) [4]. Metode time domain (TD) diterapkan pada beberapa fitur diantaranya Mean yang didefinisikan sebagai nilai rata-rata dari setiap rekaman EEG pada kanal, Standard Deviation yang merupakan salah satu ukuran statistik yang dapat digunakan untuk mengukur karakteristik suatu sinyal EEG dan Number of Peaks yang didefinisikan sebagai number of signal peaks pada setiap rekaman EEG, dimana fitur NOP digunakan dengan asumsi bahwa setiap rekaman EEG peserta memiliki nilai perbedaan yang signifikan antara emosi happy dan sad dilanjutkan proses klasifikasi emosi dilakukan dengan pengklasifikasi Naive Bayes, dimana Naive Bayes dikelompokkan dalam metode supervised (trained) yang membutuhkan label untuk memprediksi data sampel [5]. Pita frekuensi sinyal EEG dari tiga kelompok tag emosi (netral, positif dan negatif) dibagi menjadi beberapa segmen sinyal yang overlapping sebesar 50% kemudian mengekstrak karakteristik statistik domain frekuensi waktu antara window yang berdekatan. Kemudian, fitur

yang diekstraksi di setiap pita frekuensi dihubungkan sepanjang arah waktu untuk membentuk urutan fitur EEG, yang digunakan sebagai input bagi tahap klasifikasi menggunakan metode LSTM dengan input vektor melewati 2 layer LSTM, kemudian layer max pooling, lalu masuk pada fully connected dengan fungsi aktivasi softmax untuk mendapatkan label emosi (netral, positif, negative) [10]. Data akan diproses berdasarkan sembilan tipe ekstraksi fitur TFD, yaitu Peak to peak, Mean square value, Variance, Maximum power spectral density, Maximum power spectral frequency, Power sum, Hjort parameter Mobility, Activity dan Complexity. Data baris (1280) mewakili jumlah video 40 dikalikan jumlah subjek 32 ($40 * 32 = 1280$), sedangkan kolom (1208) mewakili data hasil ekstraksi yang terdiri dari 9 fitur dikalikan 32 kanal ditambah 14 asimetri otak dan dikalikan 4 ritme ($((9 * 32) + 14) * 4 = 1208$). Kemudian dalam penelitian ini digunakan PCA untuk mereduksi data, dimana percobaan akan menggunakan 3 jenis PCA dengan nilai skor yang berbeda yaitu 30, 40 dan 100. Terakhir, Jaringan Syaraf Tiruan Backpropagation digunakan sebagai metode klasifikasi, dimana parameter backpropagation dalam percobaan ini didefinisikan dengan jumlah input neuron yang ditentukan oleh dimensi data, jumlah hidden neuron adalah 100 dan learning rate yang digunakan adalah 0,2 [18].

Pada penelitian ini, metode ekstraksi yang digunakan adalah Principle Component Analysis (PCA) [11][12][16]. Selain menggunakan metode PCA juga menggunakan metode Relief Based Algorithm (RBA) yang digunakan untuk mendapatkan metode mana yang dapat mengekstraksi fitur paling baik dan hasil dari ekstraksi fitur diklasifikasikan untuk mendapatkan label emosi menggunakan metode Support Vector Machine (SVM), K-Nearest Neighbors (KNN), dan Decision Tree (DT) [11]. Setelah diekstraksi dengan PCA, hasilnya diklasifikasi menggunakan algoritma K-Star untuk menguji nilai k 1 sampai 5, kemudian menghitung

jarak data uji terhadap data latih berdasarkan entropi sehingga didapatkan kelas untuk data uji [12]. PCA digunakan untuk menghitung transformasi matriks dimana data dengan ukuran 3 dimensi $40 \times 40 \times 8064$ dilakukan reduksi menjadi 40×8064 2 dimensi yang dilanjut dengan proses konvolusi data menggunakan metode CNN, data sample diambil sebagai input dengan ukuran 40×40 dengan konfigurasi pada lapisan pertama konvolusi (C1) diberikan 100 filter dimana setiap filternya memiliki parameter unit $5 \times 5 = 25$ dan parameter bias, sehingga ukuran dari setiap feature map yaitu 36×36 , pada lapisan kedua (S2) dilakukan downsampling terhadap feature map menjadi 18×18 , pada lapisan konvolusi ketiga (C3) menkonvolusi lapisan S2 menggunakan kernel konvolusi 5×5 , sehingga feature map berukuran 14×14 dengan setiap feature map di C3 terdiri dari semua feature map di S2, pada lapisan S4 merupakan downsampling layer yang berisikan feature map dengan ukuran 5×5 , setiap sel pada feature map S4 terhubung dengan feature map 2×2 pada lapisan C3, dan pada layer konvolusi terakhir yaitu C5, setiap cell terhubung dengan 5×5 dari setiap feature map pada lapisan S4 [16].

Pada penelitian ini, metode ekstraksi fitur yang digunakan adalah Power Spectral Density (PSD) yang berfokus dalam mengekstraksi tiga pita frekuensi, yaitu Theta, Alpha dan Beta dari sinyal EEG yang diperoleh (4-30Hz) untuk memunculkan karakteristik EEG dengan cara mengelompokkannya ke dalam tampilan energi (gerak otot dan kedipan mata), kemudian hasil dari ekstraksi fitur diklasifikasikan menggunakan metode Support Vector Machine (SVM) dan Linear Discriminant Analysis (LDA) untuk mendapatkan perbandingan nilai akurasi terbaik yang akan diperoleh oleh klasifikasi SVM atau LDA [8].

Pada penelitian ini, metode ekstraksi fitur yang digunakan adalah Empirical Mode Decomposition (EMD) untuk menganalisa sinyal non-

linear dan non-stationary dari sebuah sinyal EEG dimana hasil dari EMD ini menghasilkan lebih dari satu IMF dan pada sinyal IMF dilakukan pemilihan menggunakan metode Periodogram dan Welch's yang berfungsi untuk memeriksa kerapatan spectrum frekuensi yang menyebar lebih luas di setiap IMF, sehingga pada IMF1, IMF2 dan IMF3 memiliki akurasi tertinggi dibanding IMF lainnya dengan beberapa tambahan ekstraksi fitur lainnya yang digunakan yaitu mean, standar deviasi, skewness, kurtosis, root mean square, band power, median frequency, power sum, peak to peak, entropies, dan Hjorth parameter untuk menetapkan dan memaksimalkan perbedaan antara sinyal IMF, kemudian proses klasifikasi menggunakan metode Support Vector Machine (SVM) pada sinyal yang telah difilter, IMF1, IMF2, IMF3 dan rata rata dari tiga IMF pertama, sehingga kanal grup yang diberikan label yaitu arousal, valence dan dominance dengan 32 kanal dibagi menjadi 3 bagian yaitu 1-12 untuk bagian pertama, 13-21 bagian kedua dan 22-32 bagian ketiga [15].

Pada penelitian ini, metode ekstraksi yang digunakan adalah CNN [9][14]. Dalam menganalisa peta fitur TOPO-FM dan HOLO-FM berbentuk citra 2 dimensi, masing-masing peta fitur diekstraksi dengan metode CNN secara terpisah per-karakteristik sinyal EEG, dimana CNN terdiri dari 5 layer yaitu layer input (input citra), layer konvolusi 1, layer max pooling dengan aktivasi ReLu, layer konvolusi 2 dan fully connected dengan aktivasi ReLu [9]. Hasil representasi akhir dari fitur diklasifikasikan menggunakan metode SVM dengan kernel Radial Basis Function (RBF) untuk mendapatkan label emosi [7][9]. Proses ekstraksi dan klasifikasi CNN menggunakan 64, 128 dan 256 filter ukuran 3x3 pada setiap stridenya dengan fungsi aktivasi yang digunakan pada penelitian ini yaitu ReLU dengan pooling layer 2x2 matriks pada 1 stridenya, proses optimisasi dan fungsi loss pada model CNN yang digunakan yaitu 'Adam' dan 'Cross Entropy' sehingga data dibagi menjadi dua bagian yaitu 80%

untuk training dan 20% untuk testing, epochs yang diberikan sebesar 50 dengan batch size sebanyak 20 dan learning rate 0,001 didapatkan total parameter pada model CNN ini yaitu 1,553,808 dan parameter yang dapat dilatih sebesar 1,533,418 [14].

Pada penelitian ini, metode ekstraksi fitur melalui penerapan metode Discriminative Frequency Components (DFC) terhadap penggunaan variable frekuensi. Penerapan metode ini dilakukan dengan menghitung Power Spectral Density (PSD) menggunakan persamaan pada Short Time Fourier Transform (STFT). Sebanyak 512 titik berdasarkan perhitungan Fast Fourier Transform (FFT) dengan penggunaan filter windowing pada 500 ms digunakan sebagai input pada tahap klasifikasi. Sementara itu tahap klasifikasi dilakukan dengan menerapkan dua metode, diantaranya adalah Hidden Markov Model (HMM) dan Support Vector Machine (SVM) [17].

Pada penelitian ini, proses fitur ekstraksinya menggunakan wavelet dekomposisi (Daubechies-2 dan Coiflet-2) untuk non-stationary sinyal yang dibagi menjadi 5 tingkat yaitu $cd5 = \text{theta}$ (4-8 Hz), $cd4 = \text{alpha}$ (8-16 Hz), $cd3 = \text{beta}$ (16-32 Hz) dan $cd2 = \text{gamma}$ (32-64 Hz). Proses dekomposisi tersebut dilanjutkan untuk melakukan penyamarataan hasil dari dekomposisi frekuensi sinyal dengan menerapkan nilai maximum dan minimum dari setiap subjeknya. Proses Normalisasi dilakukan dengan cara membagi frekuensi sinyal dengan frekuensi sinyal tertinggi pada saluran yang sama, serta dilakukan secara terpisah pada setiap subjek sehingga menghasilkan nilai berkisar antara 0 hingga 1. Hal tersebut merupakan bagian dari tahapan fitur ekstraksi, selanjutnya dilakukan proses klasifikasi menggunakan metode KNN. Untuk mendapatkan nilai k yang optimal dilakukan cross validation setiap sinyal EEG, lain dari itu terdapat sebuah kalkulasi rerata nilai error pada daubechies2 maupun coiflet2. Tahapan pengujian dilakukan menggunakan nilai ganjil k dengan rentang nilai terkecil yaitu 1 dan tertinggi ada 31, hasil yang paling optimal pada kedua

fitur ekstraksi daubechies2 yaitu nilai $k = 21$ sedangkan untuk coiflet 2 yaitu 23 untuk nilai k . Sehingga nilai k pada metode KNN yang diterapkan yaitu 1 untuk minimum, 21 untuk optimum dan 31 untuk maximum, hal tersebut dilakukan untuk membandingkan hasil akurasi pada tahap klasifikasi [20].

Pada penelitian ini, dataset yang digunakan tidak dilakukan tahap ekstraksi fitur. Hal tersebut dikarenakan penggunaan dataset Multi Level Features (MLF)–Capsnet sudah dilakukan ekstraksi terlebih dahulu, sehingga data mentah yang digunakan dapat dijadikan input proses setelah melalui tahap segmentasi dan filtering. Sementara itu, tahap klasifikasi dilakukan dengan menerapkan metode CNN terhadap 32 kanal pada 8 unit konvolusi dengan filter berukuran 9×9 dan 6×6 serta nilai pergeseran (stride) bernilai 1, kemudian tahapan dilanjutkan dengan menggabungkan feature maps hasil konvolusi pada setiap kanal sehingga diperoleh 512 feature maps dan pada layer selanjutnya diterapkan metode bottleneck dengan menggunakan 256 kernel konvolusi untuk mereduksi jumlah kanal [3].

2.4. Hasil yang diujikan yang meliputi semua eksperimen yang dilakukan penelitian dalam paper tersebut.

Pada penelitian ini, data yang diperoleh setiap peserta berjumlah 49 citra gambar spektogram. Total gambar yang diperoleh sebagai dataset adalah berjumlah 490 data dengan 80% dari data tersebut digunakan dalam pelatihan sementara sisanya digunakan dalam pengujian. Proses pengujian dilakukan dengan menggunakan 20 epoch serta 26 iterasi pada setiap epoch dengan akurasi keseluruhan mencapai 84,69%. Akurasi klasifikasi yang diperoleh terhadap tiga kelas dengan meliputi takut, senang, dan sedih masing masing mencapai 100%, 83,3%, dan 68,8% [1].

Penelitian ini melakukan pengujian terhadap semua data latih dengan mengoptimalkan penggunaan parameter pelatihan terhadap penerapan LVQ menggunakan learning rate 0,01 – 0,05 dengan pengurangan senilai 0,001 pada setiap epoch. Proses pembelajaran dilakukan hingga mencapai maximal epoch pada iterasi ke 10000. Perolehan akurasi terbaik terdapat pada penggunaan learning rate 0,05 dengan akurasi mencapai 87% [2].

Tahap pengujian pada penelitian ini dilakukan dengan menggunakan 20–30 dataset terhadap 8 perbandingan metode dengan hasil akurasi terhadap perbandingan kelas valence, arousal dan dominance mencapai 94.59%, 95.26% dan 95.13% [3].

Pada penelitian ini, tahap pengujian dilakukan terhadap 7 percobaan untuk setiap satu klasifikasi biner, yaitu (happy/sad, angry/relaxed, happy/angry, relax/sad, sad/angry, happy/relaxed dan 1 macam klasifikasi multi kelas. Hasil yang dicapai membuktikan bahwa penggunaan metode algoritma Rule-Based (RIPPER) mencapai akurasi tertinggi sebesar 92,1% terhadap emosi relax, sementara untuk kelas happy/relax mencapai akurasi 75,04% dan angry/relax mencapai akurasi 72,84% [4].

Pada penelitian ini semua analisis dilakukan pada pita frekuensi alfa dan beta yang melibatkan empat kanal EEG yaitu AF3, AF4, O1, dan O2. Akurasi yang paling tinggi diperoleh dari fitur Mean atau fitur yang memiliki elemen Mean, khususnya pada pita frekuensi Beta dan kombinasi pita frekuensi Alpha dan Beta dengan akurasi yang didapatkan adalah 87,5%. Berbeda dengan fitur yang memiliki elemen Standar Deviation hanya mendapati akurasi sebesar 50% dan Number of Peak hanya mendapati akurasi sebesar 75% [5].

Pada penelitian ini dilakukan evaluasi kinerja sistem, data EEG dibagi menjadi 70% untuk pelatihan dan 30% untuk pengujian. Data pelatihan dan pengujian dipisahkan dari subjek yang berbeda untuk memastikan independensi

antara kedua data. Hasil akurasi dari setiap keadaan emosi menggunakan 3 metode klasifikasi (QDA, KNN, SVM), performa terbaik didapati oleh klasifikasi SVM yang memiliki nilai akurasi sebesar 83,87% dibandingkan klasifikasi lain yang hanya mendapati akurasi sebesar 75,53% untuk klasifikasi KNN dan 60,78% untuk klasifikasi QDA [6].

Pada penelitian ini, skema klasifikasi dibagi menjadi tiga tingkat berdasarkan pengetahuan sebelumnya untuk membedakan delapan emosi kelas pada saat yang sama. Pada tingkat pertama, dipisahkan high arousal dan emosi valenced dari netralitas dengan akurasi rata-rata yang didapat 92,26%. Pada tingkat kedua, high arousal dan emosi valenced diklasifikasikan lebih lanjut ke dalam kategori positif atau negatif dengan akurasi yang didapat adalah 86,63%. Pada tingkat ketiga, emosi positif diklasifikasikan menjadi joy, amusement, tenderness dengan akurasi yang didapat adalah 86,43% [7].

Pada penelitian ini, diamati bahwa emosi happy dan sad dapat dikenali dengan akurasi terbaik pada metode klasifikasi SVM dengan seluruh sample pelatihan yang digunakan mampu mengenali emosi happy dengan akurasi 87,5% dan emosi sad dengan akurasi 92,5% sedangkan pada klasifikasi LDA dengan seluruh sample pelatihan yang digunakan mendapati penurunan akurasi menjadi 82,5% untuk emosi happy dan 87,5% untuk emosi sad [8].

Pada penelitian ini, untuk penggunaan fitur TOPO-FM, dataset DEAP menghasilkan akurasi 76% pada valence dan arousal, dataset SEED menghasilkan akurasi 70% pada valence, dataset DREAMER menghasilkan 81% pada valence dan 84% pada arousal, dan dataset AMIGOS menghasilkan akurasi 80% pada valence dan 85% pada arousal. Sementara untuk penggunaan fitur HOLO-FM, dataset DEAP menghasilkan akurasi 76% pada valence dan 77% pada arousal, dataset SEED menghasilkan akurasi 88% pada valence, dataset DREAMER menghasilkan 80% pada valence dan 90% pada arousal,

dan dataset AMIGOS menghasilkan akurasi 87% pada valence dan 90% pada arousal. Dari hasil tersebut dapat terlihat bahwa metode HOLOFM mengungguli TOPO-FM untuk semua dataset. Dataset DEAP menghasilkan akurasi yang sama untuk kedua metode, sementara SEED menghasilkan akurasi yang cukup jauh bagi kedua metode yaitu 18%. DREAMER dan AMIGOS membedakan nilai valence mereka masing-masing sekitar 7%, dan arousal 5%. Karena feature map dibuat dari fitur yang dihitung untuk setiap kanal, hasil ini menunjukkan bahwa perbedaan terbesar ada pada kumpulan data dengan lebih banyak kanal [9].

Dengan menggabungkan fitur EEG dalam domain waktu dan frekuensi, LSTM dapat secara otomatis mempelajari fitur domain waktu dan frekuensi yang memiliki korelasi tertinggi dengan dimensi emosional. Adapun model yang diusulkan menghasilkan rata-rata akurasi sebesar 93,09%. Hasil ini lebih baik dari klasifikasi dengan metode lain seperti KNN dengan 64,69%, NU-SVM dengan 67,98% dan Random Forest dengan 89,92%. Kemudian model diujikan pada Emotion State dataset dari 2 orang dewasa (1 laki-laki dan 1 perempuan) berumur 21 tahun yang menghasilkan data aktivitas gelombang otak selama 36 menit. Model menghasilkan akurasi 98,36%, mengungguli metode lain seperti Devo MLP dengan 96,11% dan LSTM dengan 96,86% [10].

Penelitian ini melakukan perbandingan metode ekstraksi fitur (RBA dan PCA) yang lebih baik untuk merepresentasikan fitur sinyal EEG. Hasil penelitian menunjukkan metode PCA lebih baik daripada RBA. Maka selanjutnya, dilakukan penghitungan berdasarkan fitur dengan metode PCA. Sistem yang dibuat mencapai akurasi klasifikasi terbaik secara keseluruhan sebesar 77,62%, 78,96% dan 77,60% masing-masing untuk dimensi valence, arousal, dan dominance [11].

Hasil percobaan pada penelitian ini menunjukkan metode K-stars selalu mengungguli KNN dalam klasifikasi valence dan arousal. Hal ini menunjukkan bahwa pencarian data terdekat berdasarkan entropi lebih baik daripada jarak (Euclidian). K-Star menghasilkan akurasi 81.2% pada arousal dan 82.6 pada valence, sementara KNN menghasilkan 80.6% pada arousal dan 81.6% pada valence untuk nilai k 1. KNN dengan nilai k 2-5 menghasilkan akurasi 62-71% [12].

Pada penelitian ini, model yang dibangun menghasilkan sebuah akurasi berdasarkan fitur reduksi dari metode PCA yaitu sebesar 64.71% untuk Valence, 66.51% untuk Arousal, 66.88% untuk Dominance dan 70.52% untuk Liking. Setelah proses fitur reduksi tersebut selesai maka dilakukan percobaan untuk mengevaluasi performa F1 Score menghasilkan 74.94 untuk Valence, 76.68 untuk Arousal, 76.67 untuk Dominance dan 81.8356 untuk Liking [13].

Pada penelitian ini, memiliki tujuan untuk mengkonversi sinyal 1 dimensi menjadi 2 dimensi menggunakan gambar virtual dari PCC, pada proses klasifikasi terdapat dua buah protocol yaitu protocol 1 dengan jumlah emosi sebanyak 2 dan protocol 2 dengan jumlah emosi sebanyak 4, nilai akurasi (mean \pm standar) protocol 1 yang dihasilkan pada class Valence $81.51 \pm 10.7\%$ dan arousal $79.42 \pm 11.8\%$. Sedangkan pada protocol 2 menghasilkan akurasi (mean \pm standar) class Valence $71.67 \pm 11.1\%$ dan Arousal $70.18 \pm 13.15\%$. Semakin banyak jumlah emosi yang harus diklasifikasikan maka nilai dari akurasi klasifikasi tersebut semakin berkurang [14].

Penelitian ini menggunakan Hjorth parameter, peak to peak, entropy, dan statistik menghasilkan nilai kesuksesan pada kanal Fp2, F4, F8, FC4, FT8, T7, Cz, C4, T8, CPz, CP4, Pz dan O2 sebesar 74.60%, 81.90%, 74.73%, 82.20%, 76.13%, 75.40%, 71.10%, 77.13%, 73.07%, 74.93%, 76%, 70.60%, 73.67%, 75.60% dan 74.27%. Hasil pada penelitian ini yaitu nilai akurasi

valence sebesar 83.02%, arousal sebesar 64.44%, dominance 64.14% menggunakan SVM. Sedangkan investigasi terhadap setiap grup valence menghasilkan nilai kesuksesan pada bagian pertama sebesar 83.1%, bagian kedua 83.4% dan bagian ketiga 83.1% [15].

Pada penelitian ini, akurasi yang dihasilkan menggunakan metode Principal Component Analysis (PCA) untuk reduksi fitur dan konvolusi menggunakan metode Convolutional Neural Network (CNN) diuji berdasarkan dua kriteria yaitu (Valence) dan (Arousal) masing-masing dengan akurasi rata-rata 84,3% dan 81,2%, tetapi untuk subjek individu, karena faktor experimental environment, akurasi klasifikasi rata-rata hanya 63% [16].

Pada penelitian ini, tahap pengujian dilakukan terhadap keseluruhan dataset dengan membandingkan kedua penerapan metode klasifikasi yang berbeda dengan tahap pra-proses dan metode ekstraksi yang sama. Hasil yang dicapai pada penelitian ini adalah berupa peningkatan akurasi pada penerapan metode ekstraksi Discriminative Frequency Components (DFC) terhadap kedua penerapan metode klasifikasi, dengan akurasi sebesar 81,77% pada metode HMM dan 82,85% pada metode SVM [17].

Pada penelitian ini, data input untuk pelatihan akan divariasikan hingga 90% dan 70% dari semua data. Kemudian data yang tersisa akan digunakan sebagai data pengujian untuk memvalidasi persentase pengklasifikasi untuk mengklasifikasikan emosi. Misalnya data hasil ekstraksi domain frekuensi waktu berupa matriks berukuran 1280 x 1208, maka data latih 90% adalah 1152 x 1208 dan data pengujian 10% adalah 128 x 1208. PCA 30 mendapatkan tingkat pengenalan emosi rata-rata 98,1% untuk data latih dan 63,75% untuk data uji. Di sisi lain PCA 40 mendapatkan tingkat pengenalan emosi rata-rata 99,48% untuk data latih dan 59.84 untuk data uji dan PCA 100 mendapatkan tingkat pengenalan emosi rata-rata 99,98% untuk data latih dan 53,20% untuk

data uji. Dari hasil tersebut, PCA 30 menunjukkan tingkat pengenalan pengujian terbaik daripada dua lainnya meskipun menunjukkan tingkat pengenalan pelatihan yang lebih sedikit, tetapi hal tersebut menyiratkan bahwa PCA 30 memberikan variabel yang paling berpengaruh [18].

Hasil percobaan pada penelitian ini menunjukkan akurasi model menggunakan fitur wavelet entropy energy lebih baik daripada fitur power spectrum, dan fitur fusion memiliki akurasi yang paling tinggi. Hal tersebut membuktikan bahwa fitur fusion dapat meningkatkan akurasi klasifikasi dalam pengenalan emosi ke dalam 3 kelas (neutral, happiness dan sadness). Kemudian untuk metode klasifikasi, metode RVM menghasilkan akurasi rata-rata sebesar 91.18% dan SVM menghasilkan akurasi rata-rata sebesar 89.17%. Maka model terbaik hasil penelitian ini adalah dengan fitur fusion dan RVM [19].

Pada penelitian ini, nilai akurasi yang dihasilkan menggunakan nilai optimum $k = 21$ untuk proses klasifikasi KNN dengan metode dekomposisi wavelet daubechies2 menghasilkan nilai akurasi valence 59% dan arousal 65.7% pada subjek dependent, sedangkan untuk subjek independent menghasilkan akurasi valence 56.8% dan arousal 64.3%. Selain dari metode dekomposisi wavelet Daubechies2, terdapat metode lainnya yaitu coiflet2 dengan nilai akurasi pada subjek dependent 58.8% untuk valence dan 64.6% untuk arousal. Untuk subjek independent menggunakan coiflet2 menghasilkan nilai akurasi valence 57.5% dan 64% untuk arousal. Dari kedua metode ekstraksi fitur tersebut yang paling unggul untuk valence adalah coiflet2 sedangkan untuk arousal yaitu dekomposisi wavelet daubechies2 [20].

DAFTAR REFERENSI

- [1] H. Donmez and N. Ozkurt, "Emotion Classification from EEG Signals in Convolutional Neural Networks," *Proceedings - 2019 Innovations in Intelligent Systems and Applications Conference, ASYU 2019*, 2019, doi: 10.1109/ASYU48272.2019.8946364.
- [2] E. C. Djamal and P. Lodaya, "Eeg based emotion monitoring using wavelet and learning vector quantization," *International Conference on Electrical Engineering, Computer Science and Informatics (EECSI)*, vol. 2017-Decem, no. September, pp. 19–21, 2017, doi: 10.1109/EECSI.2017.8239090.
- [3] Y. Liu *et al.*, "Multi-channel EEG-based emotion recognition via a multi-level features guided capsule network," *Computers in Biology and Medicine*, vol. 123, no. July, p. 103927, 2020, doi: 10.1016/j.compbimed.2020.103927.
- [4] E. S. Pane, M. A. Hendrawan, A. D. Wibawa, and M. H. Purnomo, "Identifying Rules for Electroencephalograph (EEG) Emotion Recognition and Classification," *Proceedings of 2017 5th International Conference on Instrumentation, Communications, Information Technology, and Biomedical Engineering, ICICI-BME 2017*, no. November, pp. 167–172, 2018, doi: 10.1109/ICICI-BME.2017.8537731.
- [5] N. Y. Oktavia, A. D. Wibawa, E. S. Pane, and M. H. Purnomo, "Human Emotion Classification Based on EEG Signals Using Naïve Bayes Method," *Proceedings - 2019 International Seminar on Application for Technology of Information and Communication: Industry 4.0: Retrospect, Prospect, and Challenges, iSemantic 2019*, pp. 319–324, 2019, doi: 10.1109/ISEMANTIC.2019.8884224.
- [6] M. Ali, A. H. Mosa, F. Al Machot, and K. Kyamakya, "EEG-based emotion recognition approach for e-healthcare applications," *International Conference*

- on Ubiquitous and Future Networks, ICUFN*, vol. 2016-Augus, pp. 946–950, 2016, doi: 10.1109/ICUFN.2016.7536936.
- [7] Y. J. Liu, M. Yu, G. Zhao, J. Song, Y. Ge, and Y. Shi, “Real-time movie-induced discrete emotion recognition from EEG signals,” *IEEE Transactions on Affective Computing*, vol. 9, no. 4, pp. 550–562, 2018, doi: 10.1109/TAFFC.2017.2660485.
 - [8] A. Bhardwaj, A. Gupta, P. Jain, A. Rani, and J. Yadav, “Classification of human emotions from EEG signals using SVM and LDA Classifiers,” *2nd International Conference on Signal Processing and Integrated Networks, SPIN 2015*, pp. 180–185, 2015, doi: 10.1109/SPIN.2015.7095376.
 - [9] A. Topic and M. Russo, “Emotion recognition based on EEG feature maps through deep learning network,” *Engineering Science and Technology, an International Journal*, no. xxxx, 2021, doi: 10.1016/j.jestch.2021.03.012.
 - [10] X. Cao, K. Zhao, and D. Xu, “Emotion Recognition of Single-electrode EEG based on Multi-feature Combination in Time-frequency Domain,” *Journal of Physics: Conference Series*, vol. 1827, no. 1, 2021, doi: 10.1088/1742-6596/1827/1/012031.
 - [11] R. Nawaz, K. H. Cheah, H. Nisar, and V. V. Yap, “Comparison of different feature extraction methods for EEG-based emotion recognition,” *Biocybernetics and Biomedical Engineering*, vol. 40, no. 3, pp. 910–926, 2020, doi: 10.1016/j.bbe.2020.04.005.
 - [12] I. N. Yulita, R. R. Julviar, A. Triwahyuni, and T. Widiastuti, “Multichannel Electroencephalography-based Emotion Recognition Using Machine Learning,” *Journal of Physics: Conference Series*, vol. 1230, no. 1, 2019, doi: 10.1088/1742-6596/1230/1/012008.
 - [13] C. Shahnaz, S. Bin Masud, and S. M. S. Hasan, “Emotion recognition based on

- wavelet analysis of Empirical Mode Decomposed EEG signals responsive to music videos,” *IEEE Region 10 Annual International Conference, Proceedings/TENCON*, pp. 424–427, 2017, doi: 10.1109/TENCON.2016.7848034.
- [14] M. R. Islam and M. Ahmad, “Virtual Image from EEG to Recognize Appropriate Emotion using Convolutional Neural Network,” *1st International Conference on Advances in Science, Engineering and Robotics Technology 2019, ICASERT 2019*, vol. 2019, no. Icasert, pp. 1–4, 2019, doi: 10.1109/ICASERT.2019.8934760.
- [15] T. Ergin, M. A. Ozdemir, and A. Akan, “Emotion recognition with multi-channel EEG signals using visual stimulus,” *TIPTEKNO 2019 - Tip Teknolojileri Kongresi*, pp. 1–4, 2019, doi: 10.1109/TIPTEKNO.2019.8895242.
- [16] G. Cao, Y. Ma, X. Meng, Y. Gao, and M. Meng, “Emotion recognition based on CNN,” *Chinese Control Conference, CCC*, vol. 2019-July, no. 61372023, pp. 8627–8630, 2019, doi: 10.23919/ChiCC.2019.8866540.
- [17] S. Liu *et al.*, “EEG-based emotion estimation using adaptive tracking of discriminative frequency components,” *Proceedings of the Annual International Conference of the IEEE Engineering in Medicine and Biology Society, EMBS*, no. 91520205, pp. 2231–2234, 2017, doi: 10.1109/EMBC.2017.8037298.
- [18] D. K. Theresia, D. Ana, A. Faqih, and B. Kusumoputro, “The back-propagation neural network classification of EEG signal using time frequency domain feature extraction,” *2019 16th International Conference on Quality in Research, QIR 2019 - International Symposium on Electrical and Computer Engineering*, pp. 1–4, 2019, doi: 10.1109/QIR.2019.8898288.

- [19] Q. Gao, C. han Wang, Z. Wang, X. lin Song, E. zeng Dong, and Y. Song, “EEG based emotion recognition using fusion feature extraction method,” *Multimedia Tools and Applications*, vol. 79, no. 37–38, pp. 27057–27074, 2020, doi: 10.1007/s11042-020-09354-y.
- [20] A. E. Putra, C. Atmaji, and F. Ghaleb, “EEG-Based Emotion Classification Using Wavelet Decomposition and K-Nearest Neighbor,” *Proceedings - 2018 4th International Conference on Science and Technology, ICST 2018*, vol. 1, pp. 1–4, 2018, doi: 10.1109/ICSTC.2018.8528652.

PERAN ANGGOTA TIM

Nama	Peran	Progres Pengerjaan
Nursilva Aulianisa Putri	Ketua	Research jurnal [1] - [20], analisis jurnal [1] - [4] & [17], perbaikan metode pra proses [1] - [20].
Novia Putri Syahida	Anggota	Research jurnal [1] - [20], analisis jurnal [9] - [12] & [19], perbaikan dimensi data [1] - [20], desain diagram grafik database keyword “EEG Emotion Classification”.
Rafi Azizi Muchtar	Anggota	Research jurnal [1] - [20], analisis jurnal [13] - [16] & [20], perbaikan karekteristik data [1] - [20], desain diagram grafik database keyword “Identification EEG Emotion Classification”.
Iman Muhdi	Anggota	Research jurnal [1] - [20], analisis jurnal [5] - [8] & [18], perbaikan jumlah kelas dan metode ekstraksi [1] - [20], pengisian tabel, merekap keseluruhan progres pengerjaan.