

TUGAS REVIEW PAPER
IDENTIFIKASI EEG PASCA STROKE

Diajukan untuk Memenuhi salah satu Tugas Mata Kuliah Metodologi Penelitian

Disusun Oleh :

3411181151 Erik Fadliansyah
3411181025 Ayu Peraiyantika
3411181108 Chania Ayu Lestari
3411181143 Eprian Junan Setianto

AIG



PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS SAINS DAN INFORMATIKA
UNIVERSITAS JENDERAL ACHMAD YANI
2021

1. Pencarian Literatur

Dalam melakukan pencarian literatur, kami mencari beberapa informasi melalui database ScienceDirect, IEEE Xplore, dan Springer.

1.1. Keyword

Keyword yang digunakan pada review paper ini ialah *EEG Post Stroke (Computer Science)*, *EEG Stroke*, *BCI EEG*, *EEG after Stroke*, *Ischemic Stroke*, *EEG Motor Imagery Post Stroke Patients*, *EEG Based Winks*, *Motror Recovery After Stroke*, *Upper Limb Post Stroke*, *Post Stroke EEG With SVM*.

1.2. Hasil Pencarian


Database	Keyword	Jumlah Hasil Pencarian Yang Muncul	Jumlah Hasil Filter Setelah Membaca Abstrak	Referensi Hasil Filter
Science Direct	EEG Post Stroke	12.698	5	[1] [2] [3] [4]
Google Scholar	EEG Classifying after Stroke, EEG Motor Imagery Post Stroke Patients	17.800	13	[9] [10] [11] [12]
IEEE Xplore	EEG Post Stroke	94	2	[13][14]
Springer	Post Stroke EEG With SVM	295	29	[5] [6] [7] [8] [15] [16]

Jumlah hasil pencarian yang muncul pada database Sciene Direct mengenai EEG Post Stroke berjumlah 12.698. Dari hasil membaca setiap Abstract terdapat 5 yang membahas EEG dan Stroke, ada beberapa paper yang membahas EEG namun objek terapannya bukan kepada penderita stroke ataupun pasien pasca stroke. Selain

itu, pada pencarian di database springer mengenai Post Stroke EEG with SVM terdapat 295 referensi, namun setelah membaca abstract maka hasil pencarian yang sesuai dengan objek post stroke terdiri dari 29 paper. Pada Google Scholar dengan pencarian EEG Classifying after Stroke, EEG Motor Imagery Post Stroke Patients terdapat 17.800 data, namun yang sesuai dengan stroke serta EEG hanya terdiri dari 13 paper. Sedangkan pencarian pada database IEEE terdiri dari 94 paper, namun yang relevan pada topic literatur review ini terdiri dari 2 paper.

1.3. Jumlah Paper tiap tahun

Dalam penyajian jumlah paper tiap tahun, kami menggunakan grafik. Pada grafik dibawah ini, menunjukkan jumlah paper per tahun yang muncul.



2. Literatur Review

2.1. Kebaharuan Literatur

Tujuan dari penelitian ini adalah untuk menilai karakteristik khusus pasien pasca stroke dari aktivitas otak bioelectrical dalam proses gerakan nyata dan gerakan imajiner. [1]

Penelitian ini, mengkaji keefektifan model Transfer Learning yaitu ResNet50 V2, ResNet101 V2, dan ResNet152 V2 dalam mengekstraksi fitur dari sinyal EEG berbasis kedipan yang dikonversi Continuous Wavelet Transform (CWT), sebelum klasifikasinya melalui pengklasifikasi Support Vector Machine (SVM) yang disetel dengan baik. Dan dapat digambarkan bahwa ResNet152 SVM

yang dioptimalkan V2 dapat mengklasifikasikan sinyal EEG berbasis kedipan lebih baik setelah dievaluasi.[2]

Pada penelitian ini, peneliti melakukan kemampuan dari 10 Convolutional Neural Network (IOCNN) untuk membangun model klasifikasi yang dapat membedakan stroke EEG dan EOG dari data EEG dan data kontrol EOG. Dari parameter evaluasi secara keseluruhan, 1DCNN mendapatkan hasil yang lebih baik daripada semua pengklasifikasi yang dibandingkan. Nilai terbaik untuk akurasi, sensitivitas, spesifisitas, F-score, presisi, dan recall memiliki tingkat yang lebih tinggi dari 0,86. Dari hasil ini, terbukti bahwa EEG sangat potensial dan mungkin digunakan untuk membedakan seseorang dengan stroke dengan orang normal. [3]

Dalam penelitian ini, memperkenalkan EEG - PDC berbasis jaringan konektifitas derajat rata-rata (E-PDC) mengukur untuk menganalisis interaksi antara tubuh bagian kiri dan kanan atas pasca stroke. E-PDC menggunakan pendekatan graph dan Partial Directed Coherence (PDC) untuk mengukur konektivitas fungsional terarah antara korteks motorik. [4]

Pada penelitian ini, menggunakan metode multi-feature fusion untuk meningkatkan akurasi klasifikasi pada dua jenis stroke (stroke iskemik, dan stroke hemoragik) serta mendapatkan fitur dari stroke. Selain itu, pada penelitian ini melakukan perbandingan hasil kinerja dari klasifikasi model Support Vector Machine, Decision Tree dan Random Forest. [5].

Penelitian ini, menggunakan desain BCI (Brain Computer Interfaces) off – line berdasarkan Filter Bank Common Spatial Patterns (FBCSP) untuk melakukan pengujian dan perbandingan akurasi BCI rehabilitatif dengan data pasien yang terkena stroke maupun data pasien dengan kondisi sehat [6].

Pada penelitian ini, menggunakan desain EEG berbasis decoder yang digunakan untuk pasien yang mengalami stroke kronis. Selain itu, penelitian ini melakukan evaluasi pada kinerja parameter yang digunakan pada desain BMI untuk memecahkan kode gerakan pada pasien stroke kronis dengan kondisi tangan yang lumpuh total [7]. Penelitian ini bertujuan untuk melihat kelayakan dari paradigma motor imagery yang diterapkan pada sistem rehabilitasi untuk memulihkan motoric pada pasien stroke. [9]

Hal yang difokuskan pada penelitian ini mengenai parameter EEG seperti mean, STD dan MAV apakah dapat digunakan untuk memantau kemajuan rehabilitas stroke. [10] Fokus pada pemilihan fitur parameter yang paling stabil pada frekuensi dan gerakan tertentu. [11]

Paper ini berpfokus pada penentuan parameter EEG yang paling stabil sebagai dasar untuk mngukur kemajuan dalam pemantauan rehabilitas stroke dengan cara menghitung selisih antara nilai Gerakan tangan sehat dengan Gerakan tangan terpengaruh pada individu stroke yang sama dalam domain waktu.[12]

Pada penelitian ini menggunakan Brain Computer Interface (BCI) berbasis sinyal EEG yang dapat memecahkan kode arah Gerakan tangan dari sinyal EEG non-invasif pasien stroke, yang menderita cacat Gerakan tangan. Aktivitas kortikal yang terkait dengan Gerakan berbasis Motor Imagery (MI) dari tangan yang terkena di arah kiri/kanan diperiksa menggunakan fitur PLV dan fitur ini digunakan untuk klasifikasi biner arah gerakan kiri dan kanan MI. [13]

Penelitian ini berfokus pada klasifikasi bentuk gelombang P300 dari percobaan tunggal yang diperoleh melalui EEG menggunakan deep belief network (DBN). Deep learning algoritma dapat mengidentifikasi fitur yang relevan secara otomatis dari data subjek, yang membuat pada saat pelatihan membutuhkan lebih sedikit tahap pra-proses[14]

Penelitian ini berfokus pada perubahan sesi ke sesi individu dari akurasi dan distribusi skor probabilitas dari Support Vector Machine(SVM), dilatih untuk mengklasifikasikan Motor Imagery(MI) Gerakan tangan dan idle pada kedua pasien stroke selama MI-BCI intervention berlangsung. kemudian membandingkan metode klasifikasi SVM dengan model yang berbeda [15].

Penelitian ini mennggunakan metode deep learning untuk mengeksplorasi pola EEG dan pita frekuensi untuk pasien stroke dan juga difokuskan agar meningkatkan akurasi klasifikasi. kemudian dengan melacak perubahan terhadap pola EEG selama rehabilitasi, mengungkap mekanisme neurophysiological plasticity di korteks yang terganggu pada pasien stroke [16].

2.2. Karakteristik Data

a) Perolehan Data (Sumber Data)

Sumber data diperoleh dari 80 pasien yang terdiri dari 2 kelompok. Kelompok 1 disebut sebagai kelompok control, berisikan 30 sukarelawan sehat yang dipilih berdasarkan rekam medis dan data anamnestik mereka. Dan 50 orang sukarelawan dalam kondisi stroke sedang yang di diagnosis untuk pertama kalinya dan dikonfirmasi oleh data neuroimaging.[1]

Penelitian dilakukan di Fakultas Teknologi Teknik Elektro, Universitas Malaysia Pahang. Sebelum melakukan investigasi, etika izin diperoleh dari komite etika penelitian institusional.[2]

Sinyal EEG dari 62 orang sebagai objek data yang direkam. Proporsi dari data stroke adalah 32 dan untuk data normal adalah 30. Rentang usia subjek data antara 29 sampai 72 tahun, 37 orang laki-laki dan 25 orang perempuan. Untuk setiap rekaman, petugas mengambil durasi selama 15 menit. [3]

Data diambil dari 3 pasien dengan jenis stroke Ischemic. Dimana pasien 1 berusia 73 tahun dengan kronis 1 tahun. Pasien 2 berusia 47 tahun dengan kronis 5 tahun, dan pasien 3 berusia 61 tahun dengan kronis 37 tahun. [4]

Pada penelitian ini, menggunakan data eksperimen yang berasal dari sinyal EEG pasien stroke di Rumah Sakit Shanxi China dan data pasien yang mengalami perdarahan otak dan stroke infark. Data EEG yang digunakan pada penelitian ini sebanyak 346 segmen sampel yang mana setiap sampel nya terdiri dari 1000 sample data stroke. [5]

Penelitian ini, menggunakan kumpulan data subjek yang sehat sebanyak 10 orang diantaranya, yaitu 8 pria dan 2 wanita serta data pasien yang terkena stroke sebanyak 5 orang, diantaranya yaitu 3 laki – laki dan 2 perempuan dari Rumah Sakit Adelaide & Meath dan National University of Ireland Maynooth. [6]

Data pada penelitian ini, terdiri dari 37 data pasien stroke kronis dari Rumah Sakit Universitas Tubingen dengan rentang usia 53 hingga 73 tahun [7]. Pada penelitian ini, menggunakan kumpulan data subjke dalam keadaan sehat sebanyak 11, yang mana subjek tersebut baru menggunakan BCI. [9]

Pengukuran data dilakukan di rumah sakit Universitas airlangga, Surabaya yang melibatkan 3 pasien stroke dengan rentang usia 40 hingga 70 tahun. 1 laki-

laki dan 2 perempuan dengan menggunakan Alat OpenBCI Ultracortex Mark IV with 8 channel ganglion board untuk mengukur EEG pasien stroke yang terdiri dari 2 bagian yaitu Ultracortex Mark IV sebagai headset yang dipasang dikepala peserta dan 8 channel ganglion board sebagai pengolah sinyal yang nantinya akan disimpan dalam bentuk angka dengan format .txt. dataset yang diambil terdiri dari 12 dataset dimana pada setiap dataset pergerakan terdiri dari data pada 2 kanal yaitu C3 dan C4, 2 band yaitu alpha dan beta. Pengambilan data ini dilakukan melalui 2 gerakan yaitu gerakan tangan dan gerakan siku.[10]

Data diambil dari 10 pasien pasca stroke dari rumah sakit Airlangga dimana pasien tersebut merupakan 6 laki-laki dan 4 perempuan. Pasien tersebut dibagi menjadi dua kelompok berdasarkan rekomendasi dokter yaitu hemiparesis dan hemiplegia. Data direkam menggunakan perangkat eeg dari openBCI yaitu Cyton Board yang terdiri dari 8 channel yang di gabungkan dengan perangkat scalp Itracortex MarkIV dengan sampling rate sebesar 256 Hz, 50Hz notch filter, 1-50 Hz bandpass filter, dan 100 μ V vert scale. Dua kanal yang diaktifkan yaitu C3 dan C4 untuk mengukur aktivitas otak dengan telinga kiri dan kanan sebagai referensi. Seluruh pasien diminta untuk duduk dan mendengarkan seluruh instruksi yang disampaikan melalui suara. Instruksi yang disampaikan yaitu peserta diminta untuk melakukan beberapa gerakan seperti gerakan fleksi siku, fleksi bahu dan menggenggam dengan posisi tangan bertumpu pada bahu. [11][12]

Data sinyal EEG diambil dari 20 pasien stroke hemiplegic/hemi paresis. Data sinyal EEG ini direkam di NIMHANS, Bangalore, India. 20 pasien tersebut digolongkan menjadi 2 yakni 11 pasien laki-laki dan 9 pasien perempuan dalam kelompok usia 19-70 tahun termasuk 10 stroke iskemik dan 2 stroke hemoragik.[13]

Sumber data diperoleh dari 9 subjek dan dikelompokkan berdasarkan sehat dan pasca stroke berusia antara 20 dan 55. Enam peserta sehat (S01 hingga S06) bertindak sebagai kelompok kontrol untuk tiga pasien pasca stroke (S07 hingga S09). Subjek S08 menunjukkan komunikasi lisan yang terbatas dan mampu melakukan gerakan kaki yang terbatas. Subjek S07 menunjukkan kemampuan komunikasi lisan yang berkurang dan mampu melakukan gerakan dengan

ekstremitasnya. Terakhir, subjek S09 mampu melakukan Gerakan terbatas dengan tangan dan lengannya [14].

Data diambil dari 2 pasien dengan stroke iskemik kronis sisi kiri, 1 laki-laki dan 1 perempuan dengan usia 34 dan 71 tahun. Keduanya memiliki durasi pasca stroke lebih dari 6 bulan dan gangguan sensorimotor lengan dan moderate arm lalu kesulitan membuka dan menutup tangan [15].

Data EEG dikumpulkan dari 5 pasien dengan stroke lumpuh unilateral yang sakit dalam waktu dua bulan. Kemudian melakukan 24 tes Motor Imagery dari lengan yang cacat (kanan atau kiri) dalam sistem pelatihan BCI-FES rehabilitation selama 2 bulan [16].

b) Jumlah Kelas & Kelas Yang Digunakan

Kelas dibagi menjadi 4 dimana terdiri dari Gerakan tangan kanan asli, gerakan tangan kiri asli, gerakan tangan kanan imajiner, gerakan tangan kiri imajiner.[1] Kelas dibagi menjadi 3 berdasarkan kedipan, yaitu kedipan kanan, kedipan kiri, dan tidak ada kedipan.[2] Kelas dibagi menjadi menjadi 2 yaitu kelas Normal (Sehat) dan Stroke.[3][7][14] Kelas yang digunakan terdiri dari 2 yaitu Stroke tubuh bagian kanan atas, dan stroke tubuh bagian kiri atas. [4]

Pada penelitian ini, kelas dibagi menjadi 2, yaitu kelas negatif dan kelas positif. Kelas negatif menunjukkan data stroke iskemik, sedangkan kelas positif menunjukkan data stroke hemoragik. [5] Kelas yang digunakan pada penelitian ini ialah Healthy, Stroke Early dan Stroke Late. [6]

Kelas dibagi menjadi 2 yaitu posisi tangan (kiri atau kanan) dan tugas yang diberikan (M1, M2 atau M3). [9]. Kelas dibagi menjadi 2 pengklasifikasian MI kiri dan tangan kanan/kaki pasien [13]. Kelas terbagi menjadi 2 yaitu MI dan Idle[15]. Kelas terbagi menjadi 2 yaitu left imaging dan right imaging [16].

c) Dimensi Data (Kanal / Stimulasi)

Kanal yang digunakan terdiri dari 31, yaitu (O1, O2, P4, P3, C4, C3, F4, F3, Fp2, Fp1, T6, T5, T4, T3, F8, F7, Oz, Pz, Cz, Fz, Fpz, FT7, FC3, FCz, Fc4, FT8, TP7, CP3, CPz, CP4, TP8). [1]

Sinyal EEG berbasis kedipan dikumpulkan melalui perangkat Emotiv Insight 5 kanal. Posisi dari elektroda ditempatkan sesuai dengan sistem internasional 10-20, pada node AF3, AF4, T8, T7, dan Pz. Sinyal-sinyal dikumpulkan dari node

AF3 dan AF4, di mana AF3 bertanggung jawab untuk mengumpulkan sinyal kedipan kiri, sedangkan AF4 bertanggung jawab atas sinyal kedipan kanan. Sinyal dikumpulkan dari lima subjek sehat tanpa riwayat penyakit neurologis apapun.[2]

Pada penelitian ini, hanya menggunakan 2 kanal EEG (C3 dan OZ), dan 2 kanal electrooculography (EOG kiri dan EOG kanan). Untuk setiap pengukuran EEG terdiri dari lima kondisi kejadian, antara lain ialah membuka mata tanpa rangsangan, mata tertutup tanpa rangsangan, dan mata tertutup dengan kilatan rangsangan cahaya dalam tiga varian frekuensi (5 Hz, 10 Hz, dan 15 Hz).[3] Untuk percobaan dan tes kanal yang digunakan untuk bagian kiri yaitu ('FC3', 'FC1', 'C5', 'C3', 'C1', 'CP3', 'CP1') dan kanan ('FC2', 'FC4', 'C2', 'C4', 'C6', 'CP2', 'CP4'). [4].

Pada penelitian ini menggunakan delapan kanal, yaitu Fp1, Fp2, T3, T4, C3, C4, O1 dan O2. [5]. Selain itu, adapun penelitian lain yang menggunakan 32 kanal dengan 9 rentang frekuensi (4-8, 8-12, 12-16, 16-20, 20-24, 24-28, 28-32, 32- 36 dan 36-40 Hz).[6]

Penelitian ini menggunakan 16 kanal, diantaranya yaitu Fp1, Fp2, F3, Fz, F4, T7, C3, Cz, C4, T8, CP3, CP4, P3, Pz, P4 dan Oz. Terdapat 4 elektroda EOG yang digunakan untuk merekam gerakan mata horizontal pada kedua mata dan gerakan mata vertikal untuk mata kanan [7] Dalam penelitian ini, BCI berbasis EEG memiliki frekuensi alfa (8-13 Hz), dan beta (13-30 Hz). Selain itu, menggunakan menggunakan kanal, seperti C3, Cz, C4, F3, Fz, F4, P3, Pz, P4, T7 dan T8. [9]

Sinyal EEG direkam menggunakan 64 kanal dengan frekuensi sampling 500 Hz namun pada penelitian ini pada ekstraksi fitur dipilih 21 kanal dari area korteks motoric yaitu C5, FC3, FC1, FCz, FC2, FC4, FC6, C5, C3, C1, Cz, C2, C4, C6, CP5, CP3, CP1, CPz, CP2, CP4, CP6.[13]

Kanal yang digunakan terdiri dari 16 yaitu Fz, FC1, FC2, C3, Cz, C4, CP1, CP2, P7, P3, Pz, P4, P8, O1, O2, dan Oz. kemudian sinyal EEG diambil sampel pada 2400Hz. [14]

Kanal yang digunakan terdiri dari 48 yaitu AF3, AFz, AF4, F5, F3, F1, Fz, F2, F4, F6, FC5, FC3, FCz, FC4, FC6, FC5, FC3, FC1, FC2, C5, C3, C1, Cz, C2,

C4, C6, CP1, CPz, CP2, CP4, P7, P5, P3, P1, Pz, P2, P4, P6, P8, PO7, PO3, POz, PO4, PO8, O1, O2, dan Oz. dengan sampling rate 1 kHz[15].

Merekam data EEG dengan 16 Kanal yang terdiri C1C6, CP3, CPZ, CP4, CZ, FC3, FCZ, FC4, P3, P4 dan PZ dengan sampling rate 256 Hz. Pasien diminta untuk menyelesaikan lima kursus tugas terkait motor imagery dasar. Setiap pelajaran terdiri dari 40 percobaan yang berlangsung 240 detik. Pada awal setiap percobaan, panah tebal (kiri atau kanan) muncul secara acak sebagai isyarat visual yang berisi perintah yang menginstruksikan pasien untuk membayangkan memindahkan panah ke kiri atau kanan. Setelah itu, interval dua detik diperbolehkan antara percobaan, di mana subjek dapat menyesuaikan kondisi mental subjek tersebut [16].

a) Pra Proses

Menggunakan Wavelet untuk menganalisa setiap chanel EEG yang digunakan. Kemudian peneliti telah membagi rentang frekuensi total Hz ke dalam sub-rentang frekuensi: delta (1-4 Hz), theta (4-8 Hz), alfa (8-13 Hz), beta-1 (13-23 Hz), beta-2 (24-34 Hz), dan gamma (34-40 Hz). Untuk setiap kanal dilakukan perhitungan koefisien [1].

Data Pra proses menggunakan Continous Wavelet Transform (CWT). CWT menyediakan detail analisis domain waktu-frekuensi melalui resolusi waktu dan frekuensi tinggi. Sinyal EEG berbasis kedipan asli diubah menjadi scalogram yang merupakan nilai keseluruhan representasi dari koefisien CWT dari sinyal EEG. Skalogram yang dihasilkan diubah ukurannya menjadi 224×224 secara berurutan untuk masuk ke dalam model Transfer Learning (TL).[2]

Untuk membuat prosedur menjadi efisien dengan tujuan peneliti, maka peneliti menurunkan sampel data EEG dan Data EOG ke 64Hz. Setelah down sampling dari 62 data objek, diperoleh matriks 62×57600 untuk setiap channel. Pada sisi lain, label kelas direpresentasikan sebagai 0 untuk normal dan 1 untuk stroke. Data array untuk menyimpan label adalah 62×1 . [3]

Untuk menghubungkan Partial Directed Coherence (PDC) dengan graph, operasi thresholding harus dilakukan pada matriks. Metode Otsu dipilih untuk tujuan ini, metode thresholding ini hanya meminimalkan varians. Langkah thresholding ini mengubah matriks PDC menjadi matriks konektivitas bernilai

biner. Matriks konektivitas yang dihasilkan memiliki pita ritme sensorimotor ($f = 8-30$ Hz). [4]

Tahap pra-proses yang dilakukan pada penelitian ini ialah sinyal EEG difilter dengan menggunakan LPF (Low Pass Filter) dengan bandwidth 0 – 35 Hz. Wavelet digunakan untuk menguraikan sinyal. Kemudian dilanjutkan dengan proses segmentasi data menjadi beberapa subset. Untuk 8 channel yang digunakan, pada setiap segmen subset terdiri dari 1000 kolom dan 8 baris. Langkah berikutnya, untuk mendapatkan fitur wavelet packet energy maka dilakukan tahap mereduksi dimensi dengan menggunakan Principal Component Analysis. Metode PCA disini juga digunakan untuk mengurangi kompleksitas dari proses komputasi [5].

Pada penelitian ini, tahap pra – proses yang dilakukan ialah subjek menggerakkan jari nya dengan menggunakan tangan kiri yang kemudian dibandingkan dengan pola EEG tangan kanan. Data EEG akan difilter dengan rentang frekuensi 4-8, 8-12, 12-16, 16-20, 20-24, 24-28, 28-32, 32- 36 dan 36-40Hz, Kemudian, hasil dari filter ini akan diterapkan pada proses segmen data dengan menggunakan Algoritma CSP [6].

Tahap pra-proses pada penelitian ini ialah pasien melatih lengan tangan atas dengan menggerakannya, membuka dan menutup tangan dengan kondisi lengan pasien menempel pada orthosis robotik untuk dilakukan perekaman gerakan. Sistem BMI akan mengirimkan perintah posisi dan kecepatan orthosis tangan. Setiap percobaan dimulai dengan interval selama 3 detik dan diikuti dengan instruksi tugas yang harus dilakukan pasien.[7]

Penelitian ini melakukan tahap pra – proses yaitu pasien menerima 3 instruksi gerakan tangan dan pergelangan tangan untuk membuka atau menutup tangan, fleksi pergelangan tangan dan pronasi lengan dipilih sebagai tugas citra motorik untuk kedua tangan. Setiap tugas Motor Imagery terdiri dari 8 sesi dengan periode waktu 4 minggu. Sepuluh subjek berhasil menyelesaikan percobaan fleksi pergelangan tangan dan lima subjek menyelesaikan percobaan pronasi lengan bawah. Kemudian data difilter dari 8 hingga 30 Hz yang merupakan ritme dari SMR. [9].

Pada setiap peserta diberikan inform consent sebelum melakukan percobaan. Pertama - tama pasien laki – laki menunjukan bagian tubuh yang terkena stroke disebelah kiri, Wanita muda menunjukan tubuh kanan dan Wanita yang lebih tua menunjukkann tubuh kiri yang terkena stroke. Gerakan yang dilakukan dalam penelitiannya yaitu gerakan tangan dan gerakan siku yang nantinya Gerakan tersebut akan dilakukan pada bagian tubuh yang terkena stroke. Untuk bagian prapemrosesan terdiri dari beberapa pemrosesan yaitu EEG band filter, independent component analysis (ICA) yang berguna untuk mengurangi noise pada frekuensi, filter 50 Hz, dan pemotongan data menjadi data segmen 5 detik. Lalu proses selanjutnya yaitu ekstrasi fitur dengan menggunakan metode statistic dalam domain waktu. Fitur statistic yang digunakan yaitu Mean, Mean Absolute Value (MAV) dan Standard Deviation (STD).[10]

Tahap praproses sinyal ini dilakukan Filter Finite Impulse Responses (FIR) dengan high pass filtering untuk membersihkan sinyal dari interferensi otot dan low pass filtering untuk membersihkan sinyal dari gangguan gelombang RF. Selanjutnya, Metode Artifact Subspace Recontruction (ASR) untuk menghapus noise dan segmentasi data yang dilakukan untuk menangkap peristiwa pergerakan tertentu dimana data tersegmentasi mulai dari 1 detik sebelum pemindahan gerakan hingga 3 detik setelah pemindahan gerakan serta tahap terakhir yaitu band filter Infinite Responses (IIR) yang digunakan untuk menguraikan sinyal EEG menjadi beberapa band yaitu alpha, beta low, dan beta high. Setelah melakukan tahap praproses maka dilakukanlah ekstrasi fitur pada domain waktu dan frekuensi dengan beberapa fitur statistik yaitu mean absolute value (MAV), standar deviasi (STD), power spectral density (PSD) yang menggunakan metode welch, dan juga power presentation(PP). lalu dilakukan analisis setiap fitur dengan menggunakan metode analisis individual antara HHM dan AHM.[11]

Pada penelitian ini dilakuan pra-process dengan tahap awal yaitu filter bandpass yang berjenis Infinite Impulse Response (IIR) yang diberikan nilai tepi bawah sebesar 0,5Hz dan tepi atas yang diatur pada 45 Hz. Selanjutnya yaitu dilakukan tahap untuk menghilangkan artifact dengan menggunakan alat Artifact Subspacee Recontruction (ASR). Kedua tahap tersebut dilakukan dengan

menggunakan plugin EEGLab 2019 di Matlab R2015a. Lalu setelah itu adalah pembersihan sinyal dengan menggunakan ICA agar menghasilkan sinyal yang relevan yang nantinya akan dilakukan pemotongan data. Pemotongan tersebut dilakukan satu detik setelah perintah gerakan dan satu detik sebelum perintah Gerakan berikutnya. Proses ini menghasilkan panjang satu dataset menjadi 30 detik dimana data tersebut akan dipisahkan menjadi 8 pita frekuensi yaitu delta, theta, alpha, low alpha, high alpha, beta, low beta dan high beta.

Setelah praproses maka dilakukan tahap ekstraksi fitur dengan metode statistic. Sebelum menghitung nilai statistik, data disegmentasi menjadi 20 ms. Dalam 1 detik (1.000 ms), terdapat 256 frame data, sehingga dalam 20 ms menghasilkan 5 frame data. Setiap data memiliki durasi 30 detik, setara dengan 7.680 frame data. Segmentasi data menghasilkan 1.536 data frame yang kemudian dihitung nilai statistiknya dengan menggunakan mean, mean absolute value dan standar deviasi. Yang kemudian akan dilakukan analisis dengan melihat perbedaan antara nilai fitur gerakan tangan sehat dan fitur gerakan tangan terpengaruh. [12]

Data EEG *motor imagery task* menggunakan metode Common Average Referencing (CAR) dan sinyal tersebut difilter band pass menggunakan filter fifth order Butter worth di pita (0,05-45Hz). Kemudian fungsi Event-Related Spectral Perturbation (ERSP) dari EEGLAB digunakan untuk mendapatkan pola dari ERD/ERS dari MI task. Pada peniliti ini menetapkan frekuensi pada rentang (8-30Hz) [13].

Data di downsampling dari 2400 Hz menjadi 120 Hz kemudian disaring menggunakan filter Butterworth bandpass enam orde dengan frekuensi cut-off 1 dan 15 Hz. Titik data yang telah direkam dalam satu detik setelah diekstraksi dan disimpan dalam 16x120 matriks. Titik data dari setiap channel digabungkan. Kemudian vektor-vektor tersebut di normalisasi Kembali dari 0 menjadi 1 secara terpisah [14].

Sinyal EEG disegmentasi ke dalam windows dengan Panjang 250ms, dan komponen DC dihilangkan dari setiap segmen. Kemudian filter surface Laplacian diterapkan lebih lanjut untuk mengungkapkan aktivitas yang lebih terlokalisasi[15].

Sebelum Ekstraksi fitur, sinyal EEG perlu di pra proses agar dapat meningkatkan rasio signal-to-noise (SNR) yang rendah. EEG melakukan filter bandpass lalu data EEG disaring dalam frekuensi 5-40 Hz[16].

b) Ekstraksi Sinyal dan Identifikasi

Untuk setiap titik waktu untuk setiap saluran EEG, peneliti menghitung fraksi energi yang disebabkan oleh osilasi di setiap rentang frekuensi yang dipertimbangkan. Selanjutnya, untuk setiap saluran perekaman EEG, karakteristik rata-rata diperkirakan untuk setiap rentang frekuensi untuk berbagai jenis aktivitas motorik interval waktu di mana karakteristiknya dirata-ratakan untuk setiap rentang frekuensi, i – menentukan jenis aktivitas motorik (gerakan nyata dengan tangan kanan atau kiri, gerakan imajiner dengan tangan kiri atau kanan), k – nomor urut aktivitas motorik, K adalah jumlah total gerakan jenis ini yang rata-rata dilakukan.[1]

Model Transfer Learning yang diimplementasikan dalam penelitian ini adalah ResNet50 V2 dengan ukuran $7 \times 7 \times 1024$ dari dimensi yang rata, ResNet101 V2 dan ResNet152 V2 di mana ukuran rata kedua model adalah $7 \times 7 \times 2048$ bobot model TL dibekukan untuk mengekstrak fitur untuk tujuan klasifikasi. Dalam penelitian ini, Fully Connected Layer (FCL) yang melekat pada model CNN konvensional ditukar dengan classifier Support Vector Machine.[2]

Setelah data di pra proses, masuk ke dalam tahap ekstraksi. Sebagai masukan dari tahap ini adalah 4 saluran (C3, Oz, LEOG, dan REOG), 62x57600 data mentah. Hasil dari dari tahapan ini hanya ada 24 fitur untuk setiap objek data. Struktur data akhir untuk fitur dalam penelitian kami adalah 62x24.[3]

Untuk rentang frekuensi yang dipilih dan panjang jendela EEG untuk evaluasi, proses randomize dilakukan. Dalam proses ini, nilai PDC yang sesuai dengan rangkaian frekuensi yang dipilih secara acak dalam kisaran (30-64 Hz) dan panjang jendela yang dipilih secara acak (200-600 msec) digunakan untuk menghitung E-PDC untuk setiap percobaan. Sebanyak 100 uji coba acak dihasilkan dan dikorelasikan dengan FMUE (The Fugl – Meyer Upper Extremity Scale) dan kekuatan genggaman untuk setiap peserta. FMUE digunakan sebagai skala untuk pasien pasca stroke. [4]

Pada penelitian ini, setelah melakukan tahap pra-proses dilanjutkan dengan tahap proses yaitu menggunakan metode fitur fusion untuk mendapatkan fitur stroke fusion. Berikutnya dataset dibagi menjadi 2 yaitu data training dan data test. Validasi K-Fold digunakan pada penelitian ini untuk mendapatkan nilai akurasi klasifikasi. Selanjutnya untuk melakukan perbandingan model terbaik yang digunakan maka dilakukan proses klasifikasi dengan model SVM (Support Vector Machine), DT (Decision Tree) dan RF(Random Forest) [5].

Setelah dilakukan proses pra-processing maka hanya beberapa fitur saja dari CSP yang akan digunakan pada proses pelatihan dan pengujian yang mana fitur yang akan digunakan akan diberi peringkat dengan menggunakan marginal relevance dan penggolongan model. Kemudian 4 fitur dengan nilai tertinggi akan digunakan untuk data pelatihan. Hasil klasifikasi digunakan untuk melihat perbandingan subjek yang terkena stroke ataupun subjek dalam keadaan sehat [6].

Proses decoding EMG yang dilakukan ialah sinyal EMG difilter dengan menggunakan Bandpass dengan ukuran 5Hz dan 200 Hz. Panjang bentuk gelombang dari saluran EMG ini akan digunakan sebagai input untuk proses klasifikasi seperti kondisi lengan yang sehat, maupun lengan yang paresis dengan mempertimbangkan otot yang terlibat dalam menjalankan tugas (2 elektroda distal untuk membuka atau menutup tangan atau 2 elektroda proksimal untuk gerakan lengan atas [7].

Dalam penelitian ini, ekstraksi fitur menggunakan CSP dengan berdasarkan klasifikasi statistik. Untuk mengklasifikasikan data, filter akan mengubah data input menjadi ruang fitur. Selain itu, terdapat dua jenis ritme otak yang berbeda diekstraksi. Jenis pertama menerapkan CSP untuk mengekstrak fitur dari seluruh pita SMR. Sedangkan pada jenis kedua, SMR disaring menjadi lima pita ritme otak yaitu 8-12, 12-16, 16-20, 20-24 dan 24-30 Hz. [9]

Hasil pada penelitian ini menggunakan analisis nilai positif dan negative dari 240 data. Untuk pencarian parameter pada setiap fitur. Nilai positif terbesar dihasilkan oleh fitur standar deviasi yaitu sebesar 132/108. Sedangkan untuk pita frekuensi Dari 90 tanda untuk setiap frekuensi pita yang ditunjukkan ditemukan bahwa frekuensi alfa rendah memiliki jumlah tanda positif tertinggi dibandingkan dengan frekuensi lainnya. Hasil ini menggambarkan bahwa frekuensi terbaik

untuk mengamati pergerakan pasien stroke adalah alpha rendah. Sedangkan gerakan bahu memiliki hitungan yang lebih positif dibandingkan gerakan lainnya sehingga untuk gerakan yang memberikan hasil paling stabil untuk pemantauan pasien stroke adalah gerakan bahu.[12]

Sinyal tersebut di ekstrak menggunakan Phase Locking Value(PLV). PLV mengukur variabilitas fase intertrial dari dua sinyal EEG yakni C3 dan C4. Nilai 0 pada PLV menunjukkan sinyal yang tidak tersinkronisasi sedangkan nilai satu pada PLV menunjukkan sinyal tersinkronisasi sempurna. Kemudian diidentifikasi kanal yang paling signifikan dilakukan dengan mengambil selisih antara PLV di area korteks motorik. Kemudian menerapkan klasifikasi menggunakan Naïve Bayes Classifier (NBC) yang mengklasifikasikan dua kelompok sebagai MI berarah kiri dan kanan[13].

Deep belief network (DBN) digunakan untuk mengklasifikasikan single trial. DBN terbentuk dari 2 atau lebih RBM. RBM ini layer fully connected ke satu hidden layer. Empat RBM ditumpuk dan keluaran lapisan klasifikasi membentuk jaringan arsitektur pada penelitian ini. Fungsi logistic sigmoid digunakan untuk memodelkan fungsi aktivasi masing-masing neuron, kecuali pada output layer yang menggunakan fungsi softmax. Unsupervised training dari RBM diperbaiki untuk 100 iterasi menggunakan algoritma Contrastive Divergence (CD). Pembelajaran diatur pada 0,01 dengan momentum awal 0,5 dan momentum akhir 0,9. Algoritma yang digunakan untuk proses supervised learning adalah backpropagation. Semua subjek dikonvergen menggunakan 600 epochs [14].

Setelah masuk tahap pra proses selanjutnya fitur *Time-frequency power spectral* dihitung menggunakan short-time Fourier transform dengan frekuensi 2Hz hingga 60 Hz. Setiap fitur EEG diratakan dalam satu waktu jendela dari 500 ms hingga 3000 ms. Jumlah total fitur EEG adalah 2832 (48 channel x 59 frekuensi). Kemudian menggunakan klasifikasi SVM yang digunakan untuk membedakan fitur EEG yang terkait dengan MI dan Idle. Dalam proses ini dipilih secara acak dari sesi dasar. Lalu diuji dari MEI task selama setiap sesi NF (NF=32), dijalankan sebanyak 100 kali [15].

Ekstraksi fitur menggunakan sub-bands PSD (SBPSD) yang digunakan untuk mengekstrak fitur spectral spasial dengan menghitung power spectral density ganda (PSD), dari setiap channel memvariasikan sub-band frekuensi untuk mendapatkan frekuensi dan channel pada pasien stroke. Data EEG pertama-tama disaring menjadi beberapa sub band kemudian membagi menjadi band global G dan D menjadi satu set universal. Selanjutnya menggunakan deep neural network untuk mengidentifikasi fitur frekuensi channel utama yang memiliki sifat non-linear. Kemudian menggunakan algoritma backpropagation untuk melatih model [16].

2.3. Hasil Pengujian

Tujuan dari penelitian ini adalah untuk menilai karakteristik khusus pasien pasca stroke dari aktivitas otak bioelectrical dalam proses gerakan nyata dan gerakan imajiner. Saat pada bagian stage gerakan tangan nyata terdapat aktivitas beta frekuensi tinggi di wilayah sensorikmotor korteks dengan aktivasi berikutnya dari alpha irama di daerah oksipital dicatat. Untuk gerakan tangan imajiner, struktur frekuensi-spasial EEG menunjukkan karakter yang serupa, tetapi ritme alfa lebih jelas dan diamati di oksipital dan daerah parietal. Pada saat yang sama, area korteks motorik dan area lobus temporal menunjukkan peningkatan nyata dalam intensitas ritme beta. Sedangkan dalam rekaman EEG stage background pada pasien dengan gangguan motorik, ritme beta dengan aktivitas gamma memiliki nilai (30–45 Hz) yang mendominasi. Selain ritme beta, ritme alfa lemah di frontal dan posterior daerah otak dengan delta (0,5-3 Hz) dan ritme theta.[1]

Penelitian ini mengkaji keefektifan model Transfer Learning yaitu ResNet50 V2, ResNet101 V2, dan ResNet152 V2 dalam mengekstraksi fitur dari sinyal EEG berbasis kedipan yang dikonversi Continuous Wavelet Transform (CWT), sebelum klasifikasinya melalui pengklasifikasi Support Vector Machine (SVM) yang disetel dengan baik. Model Transfer Learning yang diberikan dipasangkan dengan pengklasifikasi SVM yang dioptimalkan. Untuk membandingkan kemanjuran yang diusulkan, model CNN konvensional, Fully Connected Layer (FCL) dengan lapisan dipertahankan juga dievaluasi. Fitur yang sama itu diekstraksi melalui model Transfer Learning dimasukkan ke dalam Fully Connected Layer dengan lapisan pertama terdiri dari 50 hidden neuron, dengan fungsi aktivasi ReLu. Dan nilai drop

out 0,5. Outputnya kemudian dimasukkan ke hidden layer dengan tiga hidden neuron dengan fungsi aktivasi softmax. Di penelitian ini, algoritma optimasi Adam digunakan dengan epoch 50 dan ukuran batch sepuluh. Hasil dievaluasi melalui confusion matrix dan klasifikasi akurasi. Penggambaran akurasi dari ketiga model yang diklasifikasikan melalui pengklasifikasi CNN konvensional dan model SVM yang disesuaikan. Diamati bahwa akurasi SVM yang diperoleh lebih baik dibandingkan dengan saluran CNN konvensional. Selain itu, dapat dilihat bahwa set data pelatihan ResNet50 V2 mencapai akurasi sebesar 98%. Sedangkan, dua model Transfer Learning lainnya mencapai akurasi sebesar 100% dalam fase pelatihan. Melalui dataset validasi, bisa diamati bahwa ResNet152 V2 memperoleh akurasi 100%. Sedangkan, melalui kumpulan data uji, ketiganya mencapai 100%. Oleh karena itu, dapat digambarkan bahwa ResNet152 SVM yang dioptimalkan V2 dapat mengklasifikasikan sinyal EEG berbasis kedipan lebih baik setelah dievaluasi.[2]

Pada penelitian ini, peneliti melakukan kemampuan dari 10 Convolutional Neural Network (IOCNN) untuk membangun model klasifikasi yang dapat membedakan stroke EEG dan EOG dari data EEG dan data kontrol EOG. Untuk mempercepat pelatihan proses model, peneliti menggunakan Batch Normalization. Eksperimen mengevaluasi IDCNN pada dua epochs yang berbeda (100 dan 200). Hasil eksperimen menunjukkan bahwa deep learning pendekatan 1DCNN telah berhasil menjadi model terbaik untuk membedakan antara data stroke EEG ke EEG. data kontrol. Hasil parameter kinerja untuk setiap Epoch dan semua classifier komparator disertai dengan peningkatan kinerja nilai parameter IDCNN meningkat. Dari percobaan dengan epochs 100 dan epoch 200, didapatkan rata-rata akurasi adalah 0,829 dan 0,861 untuk masing-masing. Hasil ini mendapatkan peningkatan akurasi dibandingkan dengan pencapaian terbaik dari komparator (hanya 0,69, Naive Bayes). Urutan menurun berdasarkan kinerja berdasarkan akurasi rata-rata adalah IDCNN, Dari eksperimen pengklasifikasi sederhana Naive Bayes sukses menjadi kinerja terbaik untuk model arsitektur dasar. F-Score dari Naive Bayes hanya 0,725 di sisi lain F-Score dari IDCNN adalah 0,861. Dari parameter evaluasi secara keseluruhan, 1DCNN (baik 100 epoch dan 200 epoch) selalu mendapatkan hasil yang lebih baik daripada semua pengklasifikasi yang

dibandingkan. Nilai terbaik parameter dicapai oleh IDCNN ketika maksimum epoch adalah 200. Nilai terbaik untuk akurasi, sensitivitas, spesifisitas, F-score, presisi, dan recall memiliki tingkat yang lebih tinggi dari 0,86. Dari hasil ini, terbukti bahwa EEG sangat potensial dan mungkin digunakan untuk membedakan seseorang dengan stroke dengan orang normal. [3]

Dalam penelitian ini, memperkenalkan EEG - PDC berbasis jaringan konektifitas derajat rata-rata (E-PDC) mengukur untuk menganalisis interaksi antara tubuh bagian kiri dan kanan atas pasca stroke. E-PDC menggunakan pendekatan graph dan Partial Directed Coherence (PDC) untuk mengukur konektivitas fungsional terarah antara korteks motorik. Aktivitas otak antara dua korteks motorik dihitung melalui PDC dan digunakan untuk membentuk graph. Diantara 3 pasien stroke, di mana satu individu menerima intervensi stimulasi otak non-invasif (NIBS) dan dua lainnya menerima intervensi palsu-NIBS. Berbeda dengan dua individu yang menerima NIBS palsu, individu yang menerima intervensi NIBS menunjukkan peningkatan E-PDC, yang sangat berkorelasi dengan peningkatan fungsi gerakan tangan setelah intervensi Fugl Meyer Upper Extremity Subscale (FMUE) dan kekuatan genggaman. Ini menyiratkan bahwa ukuran E-PDC yang diperkenalkan mengukur interaksi antara korteks motorik dapat digunakan untuk menjelaskan mekanisme yang mendasari dalam memulihkan fungsi tangan setelah stroke. [4]

Pada penelitian ini menunjukkan hasil, kinerja model klasifikasi stroke iskemik dan stroke hemoragik yang digunakan antara SVM, DT, dan RF dibandingkan secara bersamaan dan pada penelitian ini memperlihatkan tingkat akurasi pada model RF dengan menggunakan Fitur Fusi lebih tinggi yaitu sebesar 98.51%, dibandingkan dengan 2 model lainnya (SVM dan DT) berdasarkan fitur yang digunakan sebagai input seperti fitur fusion, hierarchical entropy dan fitur entropy [5].

Pada penelitian ini, menunjukkan bahwa dari validasi silang yang dilakukan 10 kali memperlihatkan kesalahan klasifikasi pada EEG dengan percobaan yang dilakukan individu bukan kelompok, yang mana hal tersebut dapat dipengaruhi oleh konsentrasi dari individu pada saat melaksanakan test, seperti gerakan tangan yang gelisah, kaki yang sulit terkontrol ataupun efek kelelahan sehingga mempengaruhi

hasil klasifikasi. Pada penelitian ini juga menunjukkan bahwa hasil klasifikasi dapat digunakan untuk menggolongkan perubahan aktivitas EEG pola selama fase pemulihan setelah stroke, yang mana BCI Rehabilitatif harus mempertimbangkan pola EEG dari subjek yang sehat dan subjek yang terkena stroke. [6]

Dalam penelitian ini, menunjukkan bahwa dengan menggunakan kumpulan data yang relevan dengan berbagai parameter dapat digunakan untuk merancang antarmuka BMI. Desain dengan kinerja tertinggi ada pada penggunaan aktivitas beta bihemispheric, dengan menerapkan common average reference (CAR) dan klasifikasi menggunakan metode SVM. Hasil decoding berdasarkan aktivitas otak menunjukkan lebih tinggi dibandingkan aktivitas otot.[7]

Penelitian ini, menunjukkan bahwa akurasi klasifikasi yang lebih tinggi membuat fitur FB cocok digunakan untuk mengklasifikasikan tangan kiri dan tangan kanan dalam semua tugas MI daripada fitur WB. Fitur FB digunakan untuk melihat pengaruh penambahan jumlah fitur terhadap akurasi klasifikasi. Keakuratan mengklasifikasikan setiap tugas MI tangan kiri dan tangan kanan juga menunjukkan kemungkinan mengklasifikasikan data EEG dari sisi yang sama dari area otak. [9]

Hasil dari penelitian yang dilakukan terbukti bahwa fitur data statistik seperti Mean, Mean Absolute Value dan Standard Deviation yang dihasilkan dari EEG ini sejalan dengan data kemajuan fisik pada pasien yang dinilai oleh dokter. Berdasarkan penelitian yang disajikan dalam bentuk table dapat diketahui hasil dari masing masing partisipan. Pada partisipan 1 dengan menggunakan gerakan tangan mengalami penurunan kecuali pada beta high, beta low, dan teta pada fitur statistik mean, sedangkan untuk gerakan siku menunjukan peningkatan kecuali pada alpha high, beta low pada fitur statistic mean dan alpha high, beta low serta teta pada fitur statistic standar deviasi sehingga partisipan 1 ini perlu perhatian khusus. Partisipan 2 dengan gerakan tangan menunjukan hasil yang meningkat terutama pada fitur statistik mean absolute dan standar deviasi kecuali pada alpha high, alpha low dan beta pada fitur statistic mean, begitupula dengan gerakan siku yang menunjukan peningkatan pada bagian fitur statistic mean absolute. Namun pada alpha, alpha high, beta high, beta low, beta pada fitur statistic mean dan alpha high pada fitur statistik standar deviasi mengalami penurunan. Sedangkan untuk partisipan 3 menunjukan peningkatan pada gerakan tangan, namun mengalami penurunan pada

gerakan siku sehingga dapat dikatakan bahwa partisipan 3 ini perkembangan rehabilitas gerakan sikunya berkurang secara signifikan.[10]

Hasil dari penelitian melalui Analisis individu dengan membandingkan nilai fitur antara HMM dan AHM. Perhitungan dilakukan dengan melihat banyaknya jumlah PD. Jumlah PD ini merupakan nilai selisih antara HMM dan AHM. Jumlah PD yang didapat dari setiap fitur PSD 69%, PP 51%, STD 59% dan MAV 53%. Untuk analisis frekuensi didapatkan nilai PD pada masing-masing band frekuensi yaitu alpha 66%, beta rendah 54%, beta tinggi 54%. Sedangkan untuk pergerakannya sendiri didapatkan nilai PD sebesar 53% untuk Gerakan siku, 60% untuk Gerakan bahu, dan 61% untuk Gerakan menggenggam. Maka dapat disimpulkan bahwa fitur parameter eeg yang baik dan stabil yaitu dengan menggunakan fitur PSD dengan frekuensi alpha dalam Gerakan menggenggam.[11]

Pada penelitian ini ERD berada pada wilayah 4000-11000 ms sesuai dengan frekuensi Mu dan Beta yang menunjukkan *motor imagery* dari tangan yang terkena posisi bug (kiri/kanan). Lalu ERS ritme beta terlihat di sekitar 6000ms pada kanal C3 di tangan kanan pasien dan sekitar 8000 ms pada kanal C4 di tangan kiri pasien. Dapat disimpulkan bahwa ERD pada Mu dan beta posisi C3 menunjukkan dominasi kontralateral pada MI tangan kanan dibandingkan dengan kanal C4. Demikian pula, untuk subjek lumpuh tangan kiri, elektroda C4 menunjukkan lebih banyak dominasi ERD di awal MI dan ERS di akhir MI. kemudian masukan yang diberikan ke pengklasifikasi adalah nilai rata-rata fitur PLV yang sesuai dengan pasangan elektroda yang diperoleh dari semua kombinasi 5 percobaan. Fitur PLV dihitung dari frekuensi 8-30 Hz. Akurasi klasifikasi tertinggi diperoleh pada pasien 14 dengan kanal (CP6-FC2), (FC6-C5), (FC5-C5), (Cz-FC2) dan (FC5-FC6). Rata-rata akurasi klasifikasi yang diperoleh pada 16 subjek adalah 74,44% untuk *calibration session*. Kemudian rata-rata akurasi klasifikasi 68,63% diperoleh untuk 16 subjek pada *feedback session*. Lalu pada penelitian ini akurasi yang diberikan menggunakan ERD/ERS mengalami peningkatan untuk subjek sehat akurasi yang diberikan 82,8% jika tanpa ERD/ERS 63,7% lalu subjek dengan label pasien stroke 74,4% yang sebelumnya tanpa ERD/ERS 56,9% [13].

Penelitian ini akurasi klasifikasi DBN yang diperoleh dari setiap subjek menggunakan metode 5-fold cross-validation untuk masing-masing klasifikasi,

subjek S01, S03, dan S09 memperoleh hasil terbaik dengan akurasi 91,6% untuk S01 lalu 85,8% pada subjek S03 dan S09, sedangkan S07 mendapatkan akurasi yang rendah yakni 66,6%. Kemudian penelitian ini membandingkan klasifikasi lain seperti SVM dan MLP. Hasil yang diberikan dari ketiga klasifikasi tersebut sama, kecuali pada subjek S04 dengan menggunakan DBN unggul dari kedua klasifikasi tersebut.[14]

Penelitian ini menganalisis akurasi SVM dan skor probabilitas menggunakan dua prosedur kalibrasi yang berbeda. Pertama model SVM tetap dan yang kedua Model Adaptif. Dengan model SVM tetap akurasi secara keseluruhan, subjek 1 menunjukkan penurunan rata-rata akurasi klasifikasi di semua sesi NF dibandingkan sesi BL, sedangkan subjek 2 menunjukkan peningkatan rata-rata. Subjek 1 BL=75,8% dan NF=68,2% lalu subjek 2 BL=72,4% dan NF=74,3%. Kemudian kedua subjek menunjukkan perbedaan skor diatas nol. perbedaan skor bervariasi dengan akurasi klasifikasi untuk tingkat yang lebih besar daripada untuk subjek 2. Pada model Adaptif menghasilkan akurasi SVM yang jauh lebih tinggi dibandingkan model tetap. Perbedaan yang signifikan meningkat pada subjek 2. Kemudian variabilitas perbedaan skor untuk setiap sesi di 100 run meningkat untuk kedua subjek tersebut [15].

Penelitian ini membandingkan 5 algoritma untuk ekstraksi fitur dan klasifikasi. PSD dikombinasikan dengan SVM (PSD-SVM); Common Spatial Patterns (CSP) dikombinasikan dengan SVM (CSP-SVM); sub-band CSP (SBCSP) dikombinasikan dengan SVM (SBCSPSVM); CSP digabungkan dengan DNN (CSP-DNN), dan SBSD digabungkan dengan SVM (SBPSD-SVM). Dalam perbandingan tersebut, menemukan bahwa metode SBPSD-DNN mendapatkan akurasi yang lebih baik yakni yang tertinggi ada pada subjek S3 dengan akurasi 80,2%. Kemudian dengan adanya fitur SBPSD dinilai lebih efektif dibandingkan dengan fitur lainnya dan juga metode DNN seringkali memperoleh akurasi yang lebih tinggi dibandingkan dengan SVM. Kemudian mengungkap mekanisme Neurophysiological Plasticity dipilih dari Pasien 3 lalu semua nilai dinormalisasi untuk perbandingan. Perbedaan berat antara kanal C4 dan frekuensi yang lebih rendah 10Hz secara bertahap meningkat, sedangkan perbedaan berat kanal C3 tetap

tidak berubah; kemudian perbedaan bobot antara kanal frekuensi tinggi CP4 dan 30Hz menunjukkan kecenderungan menurun [16].

3. Daftar Referensi

- [1] M. Zhuralvev, A. Runnova, and A. Kiselev, "Characteristics of post-stroke patients brain activity with real and Characteristics of post-stroke patients brain activity with real and imagined movements in the BCI - rehabilitation process," *Procedia Computer Science*, vol. 169, no. 2019, pp. 677–685, 2020, doi: 10.1016/j.procs.2020.02.184.
- [2] J. Letchumy, M. Kumar, M. Rashid, R. Muazu, and M. A. Mohd, "The classification of EEG-based wink signals: A CWT-Transfer Learning pipeline," *ICT Express*, no. xxxx, pp. 0–4, 2021, doi: 10.1016/j.icte.2021.01.004.
- [3] E. P. Giri, M. I. Fanany, A. M. Arymurthy, and S. K. Wijaya, "Ischemic stroke identification based on EEG and EOG using ID convolutional neural network and batch normalization," *2016 International Conference on Advanced Computer Science and Information Systems, ICACSIS 2016*, pp. 484–491, 2017, doi: 10.1109/ICACSIS.2016.7872780.
- [4] S. Eldeeb *et al.*, "Biomedical Signal Processing and Control EEG-based functional connectivity to analyze motor recovery after stroke: A pilot study," *Biomedical Signal Processing and Control*, vol. 49, pp. 419–426, 2019, doi: 10.1016/j.bspc.2018.12.022.
- [5] F. Li *et al.*, "Multi-Feature Fusion Method Based on EEG Signal and its Application in Stroke Classification," *Journal of Medical Systems*, vol. 44, no. 2, 2020, doi: 10.1007/s10916-019-1517-9.
- [6] D. J. Leamy *et al.*, "An exploration of EEG features during recovery following stroke - Implications for BCI-mediated neurorehabilitation therapy," *Journal of NeuroEngineering and Rehabilitation*, vol. 11, no. 1, pp. 1–16, 2014, doi: 10.1186/1743-0003-11-9.
- [7] M. Spüler, E. López-Larraz, and A. Ramos-Murguialday, "On the design of EEG-based movement decoders for completely paralyzed stroke patients," *Journal of NeuroEngineering and Rehabilitation*, vol. 15, no. 1, pp. 1–12, 2018, doi: 10.1186/s12984-018-0438-z.

- [8] A. Suwannarat, S. Pan-ngum, and P. Israsena, "Comparison of EEG measurement of upper limb movement in motor imagery training system," *BioMedical Engineering Online*, vol. 17, no. 1, pp. 1–22, 2018, doi: 10.1186/s12938-018-0534-0.
- [9] A. Suwannarat, S. Pan-ngum, and P. Israsena, "Comparison of EEG measurement of upper limb movement in motor imagery training system," *BioMedical Engineering Online*, vol. 17, no. 1, pp. 1–22, 2018, doi: 10.1186/s12938-018-0534-0.
- [10] A. F. Setiawan, A. D. Wibawa, M. H. Purnomo, and W. R. Islamiyah, "Monitoring stroke rehabilitation re-learning program using EEG parameter: A preliminary study for developing self-monitoring system for stroke rehabilitation during new normal," *Proceedings - 2020 International Seminar on Application for Technology of Information and Communication: IT Challenges for Sustainability, Scalability, and Security in the Age of Digital Disruption, iSemantic 2020*, pp. 620–624, 2020, doi: 10.1109/iSemantic50169.2020.9234239.
- [11] H. Setiawan, W. R. Islamiyah, A. D. Wibawa, and M. H. Purnomo, "Identifying EEG Parameters to Monitor Stroke Rehabilitation using Individual Analysis," *Proceedings - 2019 International Seminar on Intelligent Technology and Its Application, ISITIA 2019*, pp. 337–342, 2019, doi: 10.1109/ISITIA.2019.8937238.
- [12] M. D. Novitasari, A. D. Wibawa, M. H. Purnomo, W. R. Islamiyah, and A. Fatoni, "Investigating EEG Pattern during Designed-Hand Movement Tasks in Stroke Patients," *Proceedings - 2020 International Seminar on Intelligent Technology and Its Application: Humanification of Reliable Intelligent Systems, ISITIA 2020*, pp. 141–147, 2020, doi: 10.1109/ISITIA49792.2020.9163680.
- [13] V. K. Benzy, A. P. Vinod, R. Subasree, S. Alladi, and K. Raghavendra, "Motor Imagery Hand Movement Direction Decoding Using Brain Computer Interface to Aid Stroke Recovery and Rehabilitation," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 28, no. 12, pp. 3051–3062, 2020, doi: 10.1109/TNSRE.2020.3039331.

- [14] S. A. Cortez, C. Flores, and J. Andreu-Perez, "Single-trial P300 classification using deep belief networks for a BCI system," *Proceedings of the 2020 IEEE 27th International Conference on Electronics, Electrical Engineering and Computing, INTERCON 2020*, pp. 1–4, 2020, doi: 10.1109/INTERCON50315.2020.9220255.
- [15] E. Astrand, J. Plantin, S. Palmerantz, J. Tidare, and A. Participants, "EEG non-stationarity across multiple sessions during a Motor Imagery-BCI intervention: two post stroke case series," [Online]. Available: http://www.es.mdh.se/pdf_publications/6186.pdf.
- [16] D. Cheng, Y. Liu, and L. Zhang, "EXPLORING MOTOR IMAGERY EEG PATTERNS FOR STROKE PATIENTS WITH DEEP NEURAL NETWORKS Key Laboratory of Shanghai Education Commission for Intelligent Interaction and Cognitive Engineering , Dep . of Computer Science and Engineering , Shanghai Jiao Tong Unive," pp. 2561–2565, 2018.

4. Peran Anggota Tim

1. Erik Fadliansyah (Ketua)
 - Pengerjaan Review Literatur [1] [2] [3] [4]
 - Pencarian Keyword (Science Direct)
2. Ayu Peraiyantika (Anggota)
 - Pengerjaan Review Literatur [5] [6] [7] [8]
 - Penyusunan Dokumen
3. Chania Ayu Lestari (Anggota)
 - Pengerjaan Review Literatur [9] [10] [11] [12]
 - Pencarian Keyword (Google Scholar)
4. Eprian Junan Setianto (Anggota) [13] [14] [15] [16]
 - Pengerjaan Review Literatur
 - Pembuatan Grafik