

**MATA KULIAH**  
**METODE PENELITIAN**

**LITERATUR REVIEW BRAIN COMPUTER INTERFACE**

**Disusun Oleh:**

**KELOMPOK 3**

**SATRIO ANANDA [3411181144]**

**INDIARTO AJI BEGAWAN [3411181114]**

**DIYAS ISHLAHUDDIN [3411181098]**

**AIG**



**JURUSAN INFORMATIKA**  
**FAKULTAS SAINS DAN INFORMATIKA**  
**UNIVERSITAS JENDERAL ACHMAD YANI**

**2021**

## LITERATUR

### 1. Keyword yang digunakan untuk pencaharian

Keyword yang kami gunakan untuk melakukan pencarian di beberapa portal jurnal adalah *Brain Computer Interface*, *Near-Infrared Spectroscopy*, *Multimodal Signal*, *Motor Imagery*, dan *Steady-state visual evoked potential*, *BCI - Motor Imagery*, *BCI – Emotion*.

### 2. Hasil pencarian dalam bentuk tabel


Database	Keyword	Jumlah hasil pencarian	Filter yang digunakan	Jumlah hasil filter setelah membaca abstrak	Referensi hasil filter
Science Direct	<i>Brain Computer Interface</i>	31.956	-	322	[1][2][3]
Science Direct	<i>BCI - Motor Imagery</i>	2,499	Brain Computer Interfaces dan BCI Competition IV	39	[6] [7]
Science Direct	<i>BCI - Emotion</i>	4,745	Computer Science	109	[4][5]
IEEE Xplore	<i>Brain Computer Interface</i>	8.603	Brain Computer Interfaces dan Journals	875	[8][9][10][11]

IEEE Xplore	<i>Near-Infrared Spectroscopy</i>	2.702	Brain	548	[12]
IEEE Xplore	<i>Near-Infrared Spectroscopy</i>	2.702	Biomedical Optical Imaging	430	-
IEEE Xplore	<i>Multimodal Signal</i>	4.556	Learning (Artificial Intelligence)	822	[12]
IEEE Xplore	<i>Motor Imagery</i>	1.947	Brain-Computer Interfaces	1.411	[13][14]
IEEE Xplore	<i>Steady-State Visual Evoked Potentials</i>	916	Medical Signal Processing	586	[15]
Google scholar	Brain Computer Interface	12.500	Brain Computer Interface	18	[16][17][18][19][20][21][22]

Berdasarkan hasil pencarian dengan keyword Brain Computer Interface (BCI) menghasilkan jumlah penelitian yang sangat banyak contohnya pada Sciene Direct menghasilkan 31,956 dan google scholar menghasilkan 12.500, oleh karena itu dilakukan pencarian berdasarkan kebaruan jurnal, kemudian menggunakan filter yang disediakan oleh site tersebut, dengan berfokus pada subyek area atau hal yang berkaitan dengan machine learning, adapun hal lainnya jika paper tersebut muncul paling pertama dan relevan dengan machine

ataupun berkaitan dengan BCI, dalam 3 jurnal pertama yang digunakan karena dalam membaca abstrak memiliki dataset yang sama dan dengan tahun yang berbeda-beda. Adapun pada paper ke 4 berfokus pada keyword BCI dan emotional, dalam paper lainnya digunakan karena memiliki bentuk struktur paper yang point-pointnya penjelasannya cukup jelas dan mudah dimengerti serta keyword yang relevan. Dan pada sisa paper lainnya berfokus pada judul dan metode yang sering digunakan.

### 3. Jumlah paper tiap tahun dalam keyword terkait dalam bentuk grafik (jumlah vs tahun)



Gambar 1 Jumlah paper mengenai Brain-Computer Interfaces di IEEEExplore, Science Direct, dan Google Scholar pada tahun 2011-2021

Sumber portal jurnal yang digunakan berjumlah tiga yaitu IEEEExplor, Science Direct, dan google Scholar. Jika dilihat jumlah jurnal yang dipublikasi di IEEE semakin meningkat setiap tahun dengan puncaknya di tahun 2019 dengan jumlah 896 buah. Rata-rata tiap tahunnya menghasilkan 635 jurnal dengan total dari tahun 2011 sampai 2021 berjumlah 6.981 buah jurnal. Google scholar yang merupakan search engine yang dapat mengakses jurnal di berbagai tempat menghasilkan nilai pencarian yang

tinggi yaitu selalu diatas 3.000 buah. Rata-rata jurnal yang dapat ditemukan tiap tahunnya yaitu 5.469 buah dengan total jurnal mulai tahun 2011 sampai 2021 berjumlah 60.160 buah. Jurnal yang dipublikasi di Science Direct berjumlah 21.422 buah dalam kurun waktu tahun 2011 sampai 2021 dengan rata-rata 1.947 buah per tahun.

## **LITERATUR REVIEW**

---

### **1. Kebaharuan atau hal yang difokuskan pada paper.**

Kemudian pada Penelitian ini masih melakukan klasifikasi emosi menggunakan BCI, didalamnya memiliki kebaruan dimana terdapat metode seleksi fitur dengan nama Locally-robust feature selection (LRFS) yang memiliki 3 bagian didalamnya untuk mendapatkan fitur terkuat dari sinyal EEG, dalam LRFS pertama-tama terdapat evaluasi model kepadatan probabilitas, kemudian pemilihan fitur terkuat, dan terakhir ialah penggabungan fitur [1].

Dalam penelitian ini memiliki kebaruan dalam tahap praproses dimana data sebelum dilakukan Ekstraksi, terlebih dahulu masuk dalam metode Continuous Wavelet Transform CWT, pada Metode CWT sinyal EEG diubah menjadi bentuk yang merepresentasikan waktu-frekunesi dan amplitudo dua dimensi, Kemudian dilakukan ekstraksi menggunakan CNN dan kemudian pada pelatihan terdapat transfer learning sebelum dilakukan klasifikasi [2].

Pada penelitian ini memiliki kebaruan dimana mengusulkan robust and subject-specific sequential forward search method (RSS-SFSM) untuk pemilihan channel yang efektif, pada pemilihan channel dilakukan pencarian secara berurutan pada masing-masing channel yang menjadi kandidat, dalam mencari hal tersebut dilakukan pencatatan untuk menghindari masalah pemilihan secara acak dalam melakukan validasi [3].

Pada peneltian ini, memiliki focus kebaruan pada metode yang digunakan dimana terdapat penggunaan 4 model CNN dengan banyak

convolusi yang berbeda untuk mendapatkan fitur atau sebagai metode ekstraksi fitur, dan hal ini dinamakan penggabungan fitur. Empat model yang digunakan dinamakan dengan multilayer CNN, selain itu terdapat juga tahap klasifikasi yang menggunakan Decoding layer namun tidak mencapai hasil akurasi yang lebih baik dari MLP dengan softmax [4].

Pada penelitian ini memiliki kebaruan pada penanganan ekstraksi fitur frekuensi temporal-spasial dimana untuk fitur frekuensi penanganan spasial menggunakan CNN dan Penanganan temporal menggunakan LSTM atau biasa disebut dengan RNN, dengan bentuk struktur model Seti menghasilkan klasifikasi yang baik dibanding dengan method yang diusulkan sebelumnya [5].

Sama halnya dengan penelitian pada ke 5, dimana kebaruan terdapat pada metode ekstraksi penanganan spasial-temporal menggunakan CNN dan LSTM, tetapi terdapat sedikit perbedaan dimana hasil spasial tidak hanya masuk pada LSTM tetapi juga masuk dalam CNN kembali dan menghasilkan fitur Bernama special fitur, hasil LSM dan spasial fitur kemudian digabungkan dan dilakukan klasifikasi, metode ini dinamakan dengan Hybrid Deep Neural Network [6].

Dalam menentukan emosi berdasarkan sinyal EEG dibutuhkan metode yang tepat dalam melakukan pengelolaan fitur, dalam penelitian ini memiliki kebaruan dimana Ekstraksi fitur menggunakan LSTM yang dipembaharuan menjadi Bidirectional Long Short-Term Memory Network, dimana pada metode tersebut terdapat multi LSTM yang kemudian digabungkan menjadi output fitur dan kemudian dikurangi dimensinya serta diklasifikasikan [7].

Penelitian ini menawarkan sebuah paradigma baru menggunakan region based P300 spellers dengan menggunakan audio, visual, dan hybrid audio visual stimulus. Struktur hybrid P300 speller merupakan struktur baru. Subjek akan berfokus dengan menerima asukan berdasarkan tiga buah tipe stimulus yang telah ditentukan. Penelitian menggunakan metode Linear Discriminant Analysis secara bertahap untuk klasifikasi yang mana mengandung sinyal P300

atau tidak. Menggunakan paradigma baru pada penelitian ini terdapat peningkatan sebesar 15.69% dan 66,99% berdasarkan stimulus visual dan audio[8].

Mengemudi saat mengantuk menjadi salah satu penyebab kecelakaan terbesar di dunia. Selama dua dekade, banyak penelitian yang berfokus pada deteksi kantuk menggunakan sinyal electroencephalogram (EEG) berbasis sistem brain-computer interface (BCI).terdapat salah satu metode untuk mendapatkan sinyal EEG dengan menggunakannya pada area kepala dengan sistem non-hair bearing (NHB) yang menjadi alternatif solusi untuk menghindari berbagai limitasi teknis antara elektroda dengan kulit kepala yang dilapisi rambut. Penelitian ini merupakan kelanjutan dari beberapa penelitian terdahulu dengan menggunakan klasifikasi pada machine learning [9].

Brain-computer interface (BCI) bertujuan untuk mengukur dan menganalisa aktivitas otak dan mengkonversinya kedalam perintah komputer untuk mengendalikan perangkat eksternal. Penelitian ini mengusulkan metode pembelajaran pola secara invarian berbasis convolutional neural network (CNN) dan data sinyal EEG dari subjek berdasarkan P300 BCI. Metode CNN akan dilatih menggunakan data sinyal EEG dalam jumlah besar dari beberapa subjek, lalu mengekstraksi fitur-fitur dan membuat model prediksi untuk subjek baru. Data diambil dari 200 subjek menggunakan P300-based spelling dengan menggunakan dua buah tipe amplifier yang berbeda. Hampir sebagian besar subjek menghasilkan tingkat akurasi yang diatas nilai 85% [10].

Pengaruh pre-stimulus aktivitas otak pada hasil performa post-stimulus telah dianalisa di dalam beberapa penelitian terdahulu. Penelitian ini berfokus dalam bagaimana pengaturan mengenai brain-computer interface (BCI) berdasarkan modulasi dari sensorimotor rhythms (SMR). Tujuannya adalah untuk mengetahui bagaimana dan apa pengaruh aktivitas SMR terhadap hasil pengerjaan tugas yang dilakukan secara berurutan [11].

Teknologi Brain-computer interface (BCI) telah digunakan secara meluas di berbagai bidang. Teknologi electroencephalography (EEG) atau near-infrared spectroscopy (NIRS) digunakan untuk mendeteksi motor imagery, penyakit, atau kondisi kejiwaan. Penggabungan algoritma EEG dan NIRS memiliki hasil yang baik dibanding yang lain. Pada penelitian ini, terdapat tiga buah metode berdasarkan hybrid sistem EEG dan NIRS-based brain-computer interface yaitu linear fusion, tensor fusion, dan pth-order polynomial fusion. Berdasarkan penelitian yang dilakukan menghasilkan beberapa kesimpulan yaitu bahwa sistem Hybrid BCI menghasilkan nilai akurasi yang tinggi dan metode pth-order polynomial fusion merupakan metode klasifikasi terbaik diantara dua metode lainnya [12].

Motor imagery (MI) merupakan salah satu paradigma yang paling umum digunakan dalam brain-computer interfaces (BCI). Proses mental ini didefinisikan sebagai imajinasi gerakan tanpa gerakan apa pun. Penelitian ini menggunakan virtual reality (VR) sebagai salah satu stimulan disamping penggunaan layar. Selama menggunakan VR, subjek dapat lebih fokus dan terhindar dari distraksi yang dapat muncul saat eksperimen dilakukan. Hasil motor imagery dapat meningkat dengan penggunaan VR dibanding dengan layar biasa. Masing-masing teknik dilakukan pada saat subjek sedang duduk atau berdiri. Berdasarkan analisis, penggunaan VR memberikan nilai performa yang lebih tinggi terlepas kondisi subjek sedang duduk atau berdiri [13].

Tujuan mendasar dari penelitian ini adalah untuk meningkatkan persepsi karakter target dengan menggunakan rapid serial visual presentation (RSVP) spellers tanpa menggunakan gerakan mata, sehingga dapat diterapkan pada pasien lumpuh dengan disfungsi okulomotor. Untuk menguji kelayakan paradigma RSVP berbasis gerakan, penelitian menerapkan tiga metode RSVP yaitu gerakan arah tetap (FM-RSVP), gerak arah acak (RM-RSVP), dan (konvensional) stimulasi non-gerakan (NM-RSVP), dan masing-masing paradigma akan diperiksa performanya. Metode FM-RSVP dan RM-RSVP



menunjukkan latensi P300 yang pendek dan Amplitudo P300 yang tinggi sedangkan metode NM-RSVP menunjukkan kebalikannya [14].

Steady-state visual evoked potentials-based brain-computer interfaces (SSVEP-BCI) memiliki kelebihan pada nilai information transfer rate (ITR) yang tinggi, menggunakan pelatihan subjek yang rendah, dan memiliki tingkat pengaplikasian yang tinggi pada area pendampingan terhadap disabilitas dan interaksi manusia dan komputer. Penelitian sebelumnya menggunakan layar komputer untuk menampilkan beberapa stimulus visual yang dapat menurunkan tingkat portabilitas dan fleksibilitas dari subjek. Penelitian ini menggunakan augmented reality (AR) yang digunakan pada kepala subjek untuk menampilkan stimulus visual. Akan disiapkan empat buah stimulus layout yang akan ditampilkan pada Microsoft HoloLens. Penelitian akan menganalisa hasil akurasi dari empat buah layout yang diberikan oleh AR. Hasil tersebut kemudian akan dibandingkan dengan hasil akurasi dari penggunaan layar komputer konvensional [15].

Dalam penelitian ini fokus terhadap model yang dioptimalkan berdasarkan kedalaman Metode dengan menggunakan MLP yang digunakan untuk membantu orang cacat dengan mengendalikan kursi roda dengan menggunakan sinyal MI otak mereka. Lalu butterworth digunakan untuk pra-proses sinyal otak dan untuk menghilangkan sinyal noise yang diikuti dengan teknik ekstraksi menggunakan transformasi wavelet diskrit (DWT). Hasilnya menunjukkan bahwa efisiensi model MLP yang ditingkatkan diperbesar sebesar 3% jika dibandingkan dengan model yang tidak dioptimalkan. [16]

Di sini, menunjukkan bahwa tanda-tanda plastisitas otak yang spesifik secara spasial yang diukur dengan menggunakan MRI fungsional dan struktural setelah 1 jam pelatihan/percobaan BCI. Fokus disini menggunakan dua pendekatan BCI dengan neurofeedback berdasarkan (1) modulasi ritme EEG oleh citra motorik (MI-BCI) (2) potensi yang berkaitan dengan peristiwa yang diperoleh dengan penargetan (ERP-BCI). Untuk kedua percobaan BCI

pada penelitian ini menemukan peningkatan sinyal pada otak masing-masing. [17]

Dengan penelitian ini fokus pada identifikasi fisiologis yang kuat dari citra motorik yang diukur dalam EEG-BCI. Volume diaktifkan ke seluruh otak selama pengamatan motorik yang akan menghasilkan kinerja dalam EEG-BCI tersebut. Untuk mengontrol BCI, pengguna motor sensorik ritme (SMR) - BCI diklasifikasikan sesuai dengan kinerja kontrol BCI mereka. [18]

Stroke adalah penyebab utama kecacatan motorik jangka panjang di kalangan orang dewasa. Rehabilitasi masa kini sebagian besar tidak berhasil dalam mengurangi kasus gangguan motorik yang paling parah terutama pada bagian fungsi tangan. Di sini fokus terhadap uji coba hipotesis bahwa pasien yang mengalami plegia tangan sebagai akibat dari penyakit stroke subkortikal, kortikal atau penyakit lainnya yang terjadi setidaknya 1 tahun sebelumnya lalu dapat dilatih untuk mengoperasikan tangan melalui antarmuka otak-komputer (BCI). Hasil ini menunjukkan bahwa kontrol tersebut dari aktivitas neuromagnetik yang direkam di kulit kepala dapat dicapai dengan pelatihan/percobaan BCI. [19]

Penelitian ini fokus pada kebaruan fungsi hybrid baru untuk mesin vektor yang menggabungkan 2 fungsi. Fungsi nya yaitu fungsi kernel lokal dan fungsi kernel global hybrid yang membantu interpolasi dan ekstrapolasi. Fungsi kernel global yaitu algoritma ICA menggunakan komponen untuk mengisolasi independen dari motor multi-channel yaitu sinyal EEG citra yang digunakan untuk menghapus komponen EOG. Dengan menggunakan metode CSP membangun enam set terstruktur. Kemudian, enam set (PSCSP) fitur CSP diekstraksi lalu diklasifikasikan oleh RVM yang digunakan untuk pengklasifikasi kernel hibrida. [20]

Dalam penelitian Brain computer interface (BCI) berbasis motor imagery (MI) ini mempunyai peran penting dalam membantu meningkatkan dan memulihkan hilangnya fungsi fisik. Tugas MI ini yaitu membayangkan

mengepalkan tangan kanan dan mengangkat lengan bawah kanan. Pengklasifikasi menggunakan algoritma pola spasial umum dan mesin vektor pendukung. Selama percobaan, semua sukarelawan menghasilkan keluaran yang berbeda-beda. Selain itu, pembaharuan pada kinerja klasifikasinya yang menggunakan fitur event-related desynchronization (ERD). [21]

Dalam penelitian ini fokus Brain-computer interface (BCI) memperoleh, menganalisis, dan mengubah aktivitas otak manusia untuk mengontrol perintah yang memungkinkan orang cacat untuk berkomunikasi atau mengontrol perangkat lainnya. BCI berbasis citra motorik ini memungkinkan pasien untuk mengontrol pikiran buatan dan berkomunikasi dengan dunia luar hanya dengan memikirkan pergerakan lainnya seperti imajinasi gerakan tangan kiri, tangan kanan, atau kaki. Dengan hanya menggerakkan salah satu anggota badan akan memicu aktivitas saraf, yang diinduksi di area sensorimotor utama seperti yang diamati dengan gerakan yang dieksekusi nyata. Melacak ritme sensorimotor (SMR) yang dihasilkan dan mengekstraksi fitur yang kuat dan informatif dari sinyal elektroensefalogram (EEG) merupakan tantangan karena sifat sinyal EEG yang bervariasi waktu dan variabilitas antar manusia. Dalam penelitian ini menggunakan pendekatan EEG-zeros-time windowing (E2ZTW). Pada penelitian ini menggunakan beberapa algoritma seperti algoritma pola spasial umum yang digunakan untuk mengekstrak fitur dan analisis diskriminan linier dan jaringan saraf convolutional yang digunakan untuk klasifikasi fitur. [22]

## **2. Karakteristik data yang digunakan, meliputi:**

### **1. Berikan sumber data.**

Sumber data BCI salah satunya berasal dari sebuah kompetisi yang sudah berjalan selama 4 kali bernama BCI Competition, data yang diambil berasal dari kompetisi ke 4, tepatnya menggunakan dataset ke 2a dan 2b, data disediakan oleh Departemen Informatika Medis, Institut Teknik Biomedis, Universitas Teknologi Graz, didalamnya terdapat 9 subyek yang berpartisipasi dalam pengumpulan data, dan masing-masing diberi label sebagai A1-A9. Setiap percobaan memiliki dua sesi. Sesi pertama adalah

sebagai pelatihan, dan yang kedua adalah pengujian [4][5][6][20][22]. Selain itu dalam data BCI Competition ini terdapat validasi silang dengan sepuluh kelompok lain untuk meningkatkan akurasi pemodelan dengan dataset 2b [16]. Selain pada kompetisi ke 4 terdapat juga penggunaan dataset pada kompetisi ke 2 pada tahun 2003, tepatnya pada dataset III dengan 3 kanal pada seorang wanita yang berusia 25 tahun [2] dan Ia yang berasal dari perekaman subyek yang sehat pada Tubingen University [3]

Data lainnya terdapat juga pada dataset SEED-IV dari perekaman 44 orang mahasiswa (22 Mahasiswi dan 22 Mahasiswa), untuk mendapatkan kelas emosi dengan menggunakan 168 klip video [7]. Kemudian Adapun dataset yang didapatkan dari perekaman manual tanpa menggunakan dataset yang sudah ada, seperti data sinyal EEG yang didapatkan dari tujuh orang laki-laki dewasa berusia kurang lebih 27 tahun yang memiliki pendengaran dan pengelihan yang baik dan tidak memiliki kelainan jiwa [8], kemudian terdapat juga yang berasal dari sepuluh orang relawan yang sehat (dua orang perempuan dan delapan orang laki-laki) berusia 21 sampai dengan 26 tahun. Dimana partisipan memiliki pengelihan yang sehat atau baik [9], Selanjutnya terdapat dataset yang direkam secara manual yang berasal dari 29 orang sehat dengan 30 kanal , Adapun dataset yang diperoleh dari 29 sukarelawan dengan rincian 14 orang laki-laki dan 15 orang perempuan dengan usia rata-rata 30 tahun [12], kemudian dari 16 orang sukarelawan dengan rincian 12 orang laki-laki dan 4 orang perempuan dengan usia rata-rata 27 tahun. Seluruh sukarelawan memiliki pengelihan yang normal dan tidak punya rekam medis penyakit mata dan saraf [14] dan terdapat dataset yang berasal dari 23 orang sukarelawan dengan rincian 15 orang perempuan dan 8 orang laki-laki dengan rata-rata usia 30 tahun [11], Kemudian terdapat dataset yang berasal dari 12 orang sehat (enam laki-laki, enam perempuan dan berusia antara 20 hingga 25 tahun) yang mengikuti pelatihan dan diberitahu tentang prosedur-prosedur eksperimennya sebelum eksperimen formal dilakukan [21]

Dalam mendapatkan data sinyal EEG subyek dipasangkan dengan beberapa kanal, salah satunya ada yang menggunakan 22 kanal [4][5][6][20][22]. dan Adapun yang menggunakan 32 kanal[10]. Selain itu sinyal EEG yang didapatkan tidak harus berasal dari subyek yang banyak, contohnya terdapat salah satu sumber yang hanya memiliki lima subyek dengan usia 30 tahun yang sehat dan tidak memiliki gangguan pergerakan otot [15], tetapi terdapat juga sinyal EEG yang memiliki jumlah subyek yang banyak, yaitu sebanyak 200 orang dengan usia 18 sampai 32 tahun [13], Kemudian terdapat juga data sinyal EEG yang berasal dari satu kelompok gender saja yaitu berasal dari 23 perempuan sehat (11 perempuan dengan usia rata-rata 26,7 tahun) berpartisipasi dalam Eksperimen BCI (kelompok MI-BCI) namun terdapat dua peserta dieliminasi karena mereka gagal melakukan tugas citra motoric, 19 perempuan tersebut Menampilkan visual percobaan ejaan BCI (kelompok ERP-BCI) dan Semua peserta tidak kidal[17].

Salah Satu Sinyal EEG lainnya yang digunakan ialah untuk SMR-BCI, dengan banyak subyek yang mengikuti perekaman ialah 20 orang dan dengan hanya merekam satu kali sesi, Sesi ini termasuk tugas-tugas dan memberikan dasar untuk pemilihan peserta untuk percobaan fMRI. Pertama, okular (gerakan mata, berkedip) dan artefak EMG (kontraksi maksimum tangan) adalah diukur diikuti oleh 10 percobaan masing-masing 15 detik [18]. Selain penggunaan data terdapat pada subyek memiliki penyakit tangan yang kronis akibat stroke yang berasal dari Stroke Neurorehabilitation Clinic, Human Cortical Bagian Fisiologi Institut Nasional untuk Neurologis Gangguan dan Stroke (NINDS). Dengan rata-rata umur 50 tahun sebanyak 8 pasien [19],

Selain itu terdapat juga sumber data yang menggunakan DEAP (Dataset for Emotion Analysis using Physiological Signals) dan MAhnoB-HCI. Partisipan yang terlibat dalam dataset Deap adalah 32 orang dengan 16 wanita dan 16 pria yang diberikan 40 video musik berdurasi 1 menit [1]

## **2. Jumlah kelas dan sebutkan kelas yang digunakan**

Jumlah kelas yang digunakan dalam setiap penelitian memiliki nilai yang berbeda-beda, salah satunya berisi kelas Tangan Kanan, Tangan Kiri [19][21], Kaki [17][18] dan Lidah [4][5][6][20][22]. Ada pun hanya menggunakan 2 kelas, menjadi arah kanan dan arah kiri [11], dari BCI Competition IV 2b [16], kemudian kelas kanan dan kiri pada BCI Competition II 3 [2] dan Kelas atas dan bawah pada BCI Competition II 1a [3]. Selain itu terdapat kelas yang berfokus pada tangan dan juga mental aritmatika, dimana pada kelas tangan berisikan tangan sedang membuka dan menutup, kemudian pada mental terdapat kelas tambah dan kurang [12]

Dalam Penelitian lainnya dengan klasifikasi emotion memiliki kelas Netral, Frea, Sad dan Happy [7], kemudian pada penelitian lain memiliki kelas Valence dan Arousal [1], Selain itu adapun yang menggunakan tiga kelas dengan isi kelas audio, visual dan audio-visual (Hybrid) [8]. Kemudian terdapat juga dengan 2 kelas yang berisikan hair-covered dan no-hair-bearing (NHB) [10], serta bergerak dan diam [15]. Kemudian terdapat kelas terbanyak ialah sebanyak 40 yang merupakan abjad (A-Z), nomor (0-9) dan symbol [13]. Adapun dengan hanya 36 simbol yang berisi 26 abjad, 10 angka yang kemudian dibagi menjadi 5 buah grup yang dipisahkan berdasarkan warna yaitu warna merah, biru, hijau, oranye, magenta, dan hitam [14]

Kemudian terdapat empat buah kelas yaitu AR-Pos1, AR-Pos2, AR-Pos3, dan AR-Pos4 yang merepresentasikan posisi target yang diletakkan sejajar lalu masing-masing target menjauh secara vertical dari titik tengah. Posisi target berupa layar dengan ukuran 1280 px x 720 px yang memiliki kotak kecil berukuran 100px x 100px berjumlah empat buah. Kotak kecil tersebut berada dibagian tengah yang saling sejajar secara vertical dan horizontal tanpa bersentuhan. Posisi AR-Pos1 adalah pada saat kotak kecil berada dekat di tengah layer. Untuk posisi selanjutnya maka kotak kecil

akan bergerak perlahan menjauh dari titik tengah ke arah tepi kanan dan kiri layar [9].

**3. Dimensi data misalnya ukuran tiap durasi waktu satu set data, kanal (sinyal EEG), stimulasi (jika ada, khusus sinyal EEG).**

Pada Dataset BCI Competition IV 2a Menggunakan 22 kanal EEG dan 3 kanal EOG dengan frekuensi sampling sebesar 250Hz, disegmentasi dengan waktu 2 detik menghasilkan  $250\text{Hz} \times 22 \text{ kanal} \times 2 \text{ detik} = 11,000$  titik data pada setiap segmen, dan total 9 subyek  $\times$  4 kelas  $\times$  2 perulangan = 64 set data. Stimulasi yang diberikan yaitu subyek disajikan video dan lagu pemula selama 2 detik untuk pergantian tampilan, pada video ditampilkan isyarat berupa panah menunjuk ke arah kiri, kanan bawah atau atas. Subyek pada perekaman diposisikan duduk pada kursi yang nyaman didepan layar computer [4][5][6][20][22]. Pada Dataset BCI Competition II data 3 menggunakan frekuensi sampling 128Hz dengan stimulus subyek diperintahkan untuk membayangkan arah kiri dan kanan, kemudian hanya menggunakan 3 buah kanal yaitu C3, Cz dan C4 [2] dalam competition yang sama pada data 1a menggunakan frekuensi sampling 256Hz dan stimulus sebuah layar komputer yang akan berubah tampilannya dengan cursor arah atas dan bawah, menggunakan 6 buah kanal yaitu A1-Cz, A2-Cz, C3 (frontal dan parietal) dan C4 (frontal dan parietal) [3].

Pada dataset SEED IV menggunakan 62 channel ESI NeuroScan System dan setiap sinyal terpisah menjadi lima pita frekuensi. sehingga ukuran data adalah tiga dimensi matriks yang  $64 \times 62 \times 5 = 19.840$ , dengan stimulasi yang diberikan ada 4 macam video yang menggambarkan kelas yaitu netral, sad, fear dan happy [7]

Penelitian ini menggunakan alat CleveMedBioRadio untuk menerima data EEG. Sinyal EEG memiliki tujuh buah kanal yaitu P7, P8, Pz, C3, C4, Cz, dan Fz yang memiliki sinyal dominan P300. Elektroda EEG diletakkan pada kulit kepala berdasarkan sistem internasional 10/20. Data dari masing-

masing kanal EEG diisolasi agar menghasilkan 400 sinyal poin dengan 800 ms jendela sinyal menggunakan sample frekuensi sebesar 500 Hz. Dari 400 poin dataset yang diterima, dilakukan pengurangan sinyal point menjadi 40 poin data yang menghasilkan total 280 poin dataset. Satu stimulasi berlangsung selama 400ms dengan 275ms untuk memberikan stimulus bagi mode audio, visual, dan audio-visual (hybrid) lalu dilanjutkan dengan 125 ms waktu istirahat sebagai waktu tunggu antar dua stimulai yang dinamakan inter stimulus interval time [8]

Dalam penelitian lainnya Sinyal EEG diberi label pada bagian awal dan akhir cahaya berkedip. Terdapat sembilan buah kanal yang digunakan yaitu Oz, O1, O2, Pz, POz, PO3, PO4, PO7, dan PO8 yang dipilih untuk melakukan SSVEP recognition [9]

Ada pun sinyal EEG diambil dengan sampling rate 500 Hz dengan 16 bit kuantisasi. Enam elektroda yaitu Fp1, Fp2, F7, F8, A1, dan A2 diletakan dibagian kepala yang kemudian akan dikenal dengan kanal NHB (Non Hair Bearing). Kanal F7 dan F8 mengukur aktifitas otak dibagian frontal dan kanal A1 dan A2 mengukur aktivitas otan pada area mastoid kanan dan kiri. Masing-masing sinyal EEG akan melalui pita dengan frekuensi 1-50 Hz agar menghilangkan arus frekuensi rendah DC san noise yang dihasilkan perangkat power di frekuensi 60 Hz. Data EEG yang telah di filter selanjutnya dilakukan downsampling ke frekuensi 250 Hz untuk mengurangi beban komputasional. Data tersebut kemudian dibersihkan menggunakan procedure Artifact Subspace Reconstruction (ASR) yang disediakan EGLAB [10].

Selain itu terdapat penelitian dengan Sinyal EEG yang direkam menggunakan 32 elektroda (FZ, FC5, FC1, FCZ, FC2, FC6, C3, Cz, C4, CP5, CP1, CP2, CP6, P3, Pz, P4, PO7, PO3, PO4, PO8, FC3, FC4, C5, C1, C2, C6, CP3, CPz, CP4, P1,dan P2) dari system actiCap yang ditempatkan pada system 10-10 internasional. Masing-masing sinyal kemudian diperkuat menggunakan BrainAmp amplifier lalu ditransmisikan menggunakan



BrainVision recorder software. Ground elektroda ditempatkan di sebelah kanan dan kiri lubang telinga. Sampling frekuensi yang digunakan adalah pada frekuensi 500 Hz [15].

Pada penelitian lainya terdapat eksperimen, dimana data EEG diambil dengan sampling rate sebesar 250 Hz dengan jumlah kanal sebanyak 30 buah yang menggunakan system 10-20 internasional. Seluruh elektroda memiliki impedensi dibawah 5k Ohm [13].

Terdapat juga data MRI diperoleh menggunakan 3T Siemens Tim Pemindai trio (Siemens Medical, Erlangen, Jerman) dilengkapi dengan kumparan kepala 32 saluran. Untuk T1 gambar anatomi diperoleh menggunakan 3D [17].

Pada penelitian ini data EEG diambil sampelnya pada 1000 Hz dengan a band-pass filter 0,05 Hz hingga 200 Hz dan di saring pada 50 Hz. Untuk elektromiografi (EMG) direkam dengan elektroda di kedua lengan dan kaki pilihan peserta. Gerakan mata dan kedipan mata direkam dengan elektroda ditempatkan di atas dan di bawah mata kanan untuk EOG / Electrooculography vertikal dan untuk EOG horizontal dengan elektroda ditempatkan di luar mata [18].

Pada penelitian ini aktivitas neuromagnetik direkam dari 8 pasien tersebut dengan menggunakan MEG array (VSM Medtech) digunakan untuk mengontrol BCI. Dari semua saluran MEG antialias dengan 200 Hz dan sampel digital pada 600 Hz [19].

Pada penelitian mengenai emotion dengan DEAP dan MAhOB-HCI partisipasi diberikan stimulus berupa 40 video musik berdurasi satu menit, dengan frekuensi sampling 256 Hz dan menggunakan sebanyak 32 kanal, diantaranya adalah Fp1, AF3, F3, F7, FC5, FC1, C3, T7, CP5, CP1, P3, P7, PO3, O1, Oz, Pz, Fp2, AF4, Fz, F4, F8, FC6, FC2, Cz, C4, T8, CP6, CP2, P4, P8, PO4 dan O2. Dengan bantak titik data adalah , 3840 dan 1440 titik data [1]

Data sinyal EEG diambil menggunakan 30 kanal BrainAmp EEG amplifier (Brain Products GmbH, Gilching, Germany) dengan sampling rate sebesar 1000 Hz. Elektroda ditempatkan berdasarkan sistem internasional 10-5. Data Near-Infrared Spectroscopy (NIRS) diambil menggunakan NIRScout (NIRx GmbH, Berlin, Germany) yang berjumlah 30 kanal dengan sampling rate sebesar 12,5 Hz [12].

Sinyal EEG direkam dengan sampling rate sebesar 1000 Hz dan memiliki 63 elektroda yang ditempatkan berdasarkan sistem internasional 10-20. Elektroda ditempatkan di beberapa lokasi seperti Fp1-2, AF3-4, Fz, F1-10, FCz, FC1-6, FT7-8, Cz, C1-6, T7-8, CPz, CP1-6, P7-8, Pz, P1-10, POz, PO3-4, PO7-10, Oz, dan O1-2. Data Electrooculography (EOG) juga direkam di beberapa bagian wajah subjek seperti dibawah mata kanan, di bagian tengah hidung, dan dibagian AFz. Impedensi dari seluruh elektroda dijaga agar tetap dibawah 10K Ohm selama eksperimen berlanjut [14].

Aktivitas otak direkam menggunakan multi kanal EEG amplifier menggunakan 119 Ag/AgCl elektroda dengan menggunakan sistem 10-20. Sampling rate yang digunakan sebesar 1000 Hz dengan filter diantara 0,05 – 200 H [11]

Sinyal EEG direkam oleh sistem SynAmps2. Enam puluh empat elektroda kulit kepala Ag/AgCl ditempatkan sesuai dengan sistem 10/20 internasional. Elektroda terletak di dahi dan di hidung. Sinyal EEG difilter dengan band-pass antara 0,5 dan 100 Hz dengan frekuensi sampling 1000 Hz [21].

### **3. Metode-metode yang digunakan (uraikan tiap bagian metode: ekstraksi dan identifikasi)**

#### **1. Pra proses**

Tahap pra proses merupakan salah satu tahap terpenting dalam melakukan percobaan. Pada tahap ini data yang telah diseleksi kemudian kembali diseleksi ulang. Seleksi kedua ini berfungsi untuk

membuang data yang sekiranya tidak diperlukan. Data yang dibuang ini diantaranya adalah data yang tidak valid, data yang tidak konsisten, dan data ganda. Terdapat banyak sekali metode untuk melakukan tahap pra proses ini seperti menggunakan pita frekuensi, filter frekuensi, dan masih banyak metode yang dapat digunakan menyesuaikan kebutuhan dan keluaran yang diinginkan pengguna.

Beberapa penelitian mengenai EEG menggunakan pita frekuensi theta (4-8 Hz), alpha (8-13 Hz), dan beta (13-30 Hz) untuk melakukan pra proses. Data sinyal yang didapat akan di-filter menjadi 2 pita frekuensi yaitu alpha dan beta, hal itu karena penggunaan pita frekuensi yang berbeda menunjukkan respon yang berbeda pada setiap subjek untuk diklasifikasikan, dan penggunaan pita frekuensi alpha, beta dan gamma menunjukkan respon terbaik dalam klasifikasi motor imagery. Ada pula yang menggunakan informasi EEG kemudian didistribusikan ke dalam frekuensi theta (4-8Hz), alpha 1 (8-10Hz), alpha 2 (10-13Hz), beta 1 (13-20Hz) dan beta 2 (20-30Hz) gelombang, untuk meningkatkan rasio signal-to-noise [6] [10] [15]. Setelah sinyal tersebut di-filter berdasarkan frekuensi yang diinginkan maka data tersebut selanjutnya akan diklasifikasi kembali berdasarkan kebutuhan sinyal dari masing-masing eksperimen.

Selain itu ada pula yang menggunakan metode OVR-FBCSP, metode ini merupakan salah satu varian algoritma FBCSP yang dapat menangani Motor Imagery multi-kelas, didalamnya sinyal disaring dengan menggunakan filter bank dengan sembilan filter subbandpass, filter ini merupakan tipe II Chebyshev yang dimulai dari 4 Hz dan dengan subbandwidth 4 Hz (4-8 Hz, 8-12 Hz, dst.). menghasilkan 4 kelas OVR-FBCSP, dengan menggabungkan empat filter CSP one-versus-rest (OVR), digunakan untuk menghitung setiap output dari bank filter. dan pada bagian akhir sinyal yang ditransformasikan secara spasial [6].

Penelitian lain pula menggunakan metode fifth order Butterworth band pass filter untuk melakukan pra proses terhadap sinyal EEG yang diterimanya. Penggunaan fifth order Butterworth band pass filter yang memiliki 0.1 dan 35 Hz berguna untuk memotong frekuensi yang dapat mengganggu frekuensi utama yang ingin di uji. Filter ini digunakan untuk mengeliminasi noise sinyal elektrik yang ditimbulkan dari perangkat elektronik disekitar area pengujian dan menerima sinyal EEG yang memiliki frekuensi dominan pada otak [8][16]. Adapula penelitian yang menggunakan bandpass filter untuk memotong frekuensi 5 sampai 40 Hz supaya dapat menghilangkan noise sinyal dari komponen elektronik berarus DC dan noise sinyal ber-frekuensi tinggi dari benda-benda yang didalamnya memiliki perangkat power listrik[15] [16]. Untuk menghilangkan frekuensi rendah, data EEG yang telah diambil kemudian di filter pada frekuensi 0,5 – 10 Hz menggunakan filter fourth-order Butterworth yang merupakan filter infinite impulse response (IIR) [10][16]. Sinyal EEG di filter pada frekuensi 50 Hz untuk mengilangkan noise yang disebabkan kabel power kemudian dilanjutkan dengan high-pass filter pada frekuensi 0.5 Hz [13]. Empat buah pita filter digunakan untuk mendapatkan sinyal alpha dan beta pada frekuensi 5-10 Hz, 10-15 Hz, 15-20 Hz, dan 20-25 Hz [13].

Sinyal EEG juga sangat sensitive terhadap kedipan mata, pergerakan bola mata, dan pergerakan otot-otot pada seluruh bagian tubuh subjek maka dari itu digunakan proses winsorization untuk menghilangkan hal-hal yang dapat mengganggu data sinyal. Sebanyak 10% nilai ekstrem dalam sample sinyal EEG dari masing-masing elektroda akan digantikan dengan nilai ekstrem dari sample masing-masing elektroda. Setelah dilakukan pra-proses dihasilkan adanya penambahan sekitar 17 dB signal to noise ratio (SNR) [8].

Disisi lain terdapat pula tahap pra proses yang tidak menggunakan pita filter dalam mengeliminasi atau mengatur frekuensi dari sinyal EEG yang diterimanya. Salah satu cara yang digunakan adalah dengan membatasi ukuran data dari sinyal EEG, dimana ketika partisipan menonton setiap video, mereka akan diberikan petunjuk 5 detik di awal untuk memberi tahu mereka untuk dapat beremosi, Kemudian, para peserta menonton video klip standar emosi berdurasi 2 menit. Pada akhirnya, mereka punya waktu 45 detik untuk merekam emosi [7]. Ada pula penelitian yang menggunakan Sinyal EEG yang kemudian disegmentasi lalu diberi label pada saat awal dan akhir cahaya berpendar [15]. Penggunaan waktu delay pada saat sebelum penelitian dimulai juga dilakukan untuk mempersiapkan subjek sesaat sebelum memasuki tahap penelitian. Sebelum eksperimen dimulai, akan ada waktu persiapan selama 3000ms. Setelah waktu persiapan selesai maka masing-masing symbol akan menyala selama 100ms [10]. Pra proses juga dilakukan untuk menghilangkan kebisingan dan sinyal yang tidak diinginkan seperti gerakan mata, tubuh gerakan, dan kebisingan dari medan elektromagnetik [16]. Kebisingan ini akan berdampak besar pada sinyal otak dan akan mengurangi rasio sinyal terhadap noise [16]. Subjek juga tidak diperkenankan untuk berkedip, menelan atau mengunyah pada saat periode penelitian [13].

Pra-pemrosesan data dilakukan menggunakan kotak peralatan LIPSIA termasuk koreksi gerakan kepala, koreksi waktu irisan, umpan tinggi penyaringan (pada 1/100 s), dan penghalusan spasial (7 mm inti) [17]. Semua gambar didaftarkan bersama untuk individu Gambar struktur berbobot T1 [17]. Untuk normalisasi ke MNI ruang kami menggunakan matriks deformasi non-linier yang sama yang dihasilkan dari analisis DARTEL dari T1 gambar berbobot. Analisis CompCor dilakukan dengan menggunakan Kotak alat DPABI [17].

Untuk dataset yang menggunakan citra sebagai sumbernya maka terdapat metode yang berbeda dari penelitian yang lainnya. Semua gambar fungsional secara spasial disesuaikan dengan pemindaian pertama menggunakan kuadrat terkecil pendekatan dan transformasi spasial 6 parameter (benda kaku) [18]. Secara kronologis pemindaian pertama dipilih sebagai pemindaian referensi. Kemudian perbedaan waktu akuisisi gambar fungsional diperbaiki antara irisan dalam urutan menaik menggunakan irisan tengah sebagai referensi. Pada langkah selanjutnya, gambar anatomi didaftarkan bersama dengan rata-rata gambar fungsional menggunakan mutual yang dinormalisasi informasi sebagai fungsi biaya. Selain itu gambar anatomi adalah dinormalisasi ke template t1 standar yang disertakan dengan spm 8 ( $3 \times 3 \times 3\text{mm}$ ) dan diatur ke template konsorsium internasional untuk pemetaan otak (icbm) [18]. Gambar fungsional kemudian dinormalisasi menggunakan parameter normalisasi anatomi. Akhirnya, semua gambar fungsional dihaluskan menggunakan gaussian kernel smoothing dengan lebar-penuh-pada-setengah-maksimum pada  $8 \times 8 \times 8\text{ mm}$  [18].

Setiap sesi percobaan pasien melakukan 150 hingga 250 percobaan , untuk membantu mereka mencapai kontrol amplitudo ritme, dan sehingga mengontrol orthosis [19]. Representasi visual, dari kisaran yang dapat diterima amplitudo ritme untuk tindakan orthosis yang diinginkan [19]. Kursor layar (layar MEG untuk mengontrol signal) persegi kemudian akan mulai bergerak dengan kecepatan tetap dari kiri ke kanan di seluruh tampilan, dengan umpan balik kursor diperbarui setiap 300 ms [19].

Praproses yang dilakukan ialah downsampling menjadi 128 pada seluruh kanal (32 channel kanal), kemudian masuk pada tahap bandpass dan highpass filtering menggunakan Butterworth untuk memotong frekuensi menjadi 4-45Hz dan 3 Hz, selanjutnya pada

dataset DEAP masuk dalam ICA dengan rasio tertinggi antara 30– 45 Hz dan pita penuh diatur ke nol [1].

Dalam pra proses penelitian ini dilakukan proses transformasi wavelate, dimana sinyal dibagi menjadi 2 pita terpisah yaitu Mu (8-14Hz) dan Beta (15-30Hz), namun sebelum itu sinyal telah difilter menggunakan bandpass sehingga hanya memiliki rentang frekuensi 8-30Hz, dalam wavelate informasi yang terkait dengan MI menjadi hal yang dianalisis dan diubah dari sinyal ke dalam domain waktu-frekuensi [2].

Dalam penelitian ini proses awal menggunakan filter moving average filter MAF yang berfungsi untuk mengubah format sinyal menjadi lebih mudah dan efektif, dalam filter ini memungkinkan untuk menganalisis percobaan dengan membuat bagian baru yang berisikan rata-rata bagian tersebut berdasarkan data keseluruhan dan dapat juga menghilangkan noise dalam frekuensi yang tinggi [3].

Sinyal EEG di filter menggunakan 4th order Chebyshev tipe 2 dengan frekuensi pita 0,5 – 50 Hz. Kemudian menghilangkan artifak yang tidak diperlukan menggunakan Independent Component Analysis (ICA) berbasis EOG. Data NIRS dan EEG masing -masing di downsampling ke frekuensi yang berbeda. Data NIRS di downsampling ke frekuensi 20 Hz, sedangkan data sinyal EEG di downsampling ke frekuensi 200 Hz. Untuk data NIRS, akan ada perubahan pemusatan menjadi oxy-NIRS dan deoxy-NIRS yang di kalkulasi menggunakan hukum Beer-Lambert dengan beberapa modifikasi. Masing-masing oxy-NIRS dan deoxy-NIRS di filter menggunakan filter 6th-order zero phase Butterworth dengan frekuensi pita 0.01 – 0.1 Hz [12].

Untuk analisis data maka digunakan MATLAB (MathWorks, Natick, MA, USA) dengan BBCI toolbox. Seluruh data EEG dilakukan

downsampling ke frekuensi 100 Hz dan di filter pada frekuensi 0.5 – 30 Hz menggunakan Chebyshev filter untuk analisis offline. Untuk menghilangkan artifak fisiologis maka digunakan Independent Component Analysis (ICA) dengan menggunakan temporal decorrelation source separation algorithm. Dihitung juga korelasi antar komponen dan kanal EOG seperti Fp1, Fp2, F9, F10, dan EOG. Selain itu ditentukan juga nilai threshold (lebih dari dua standart deviasi) yng digunakan untuk menghilangkan komponen yang tidak perlu yang terkandung pada komponen EOG [14].

Data dari sesi kalibrasi di filter menggunakan frekuensi 45 Hz dan subspampling pada frekuensi 100 Hz. Lalu Local Average Reference (LAR) spatial filtering dipakai untuk meningkatkan sinyal yang diperlukan dan menurunkan noise yang muncul. Aktivitas pada masing-masing kanal di reduksi menggunakan rata-rata aktivitas pada delapan kanal terdekat (seperti pada kanal C3, maka akan menggunakan kanal terdekatnya yaitu kanal FC3, CFC5, CFC3, C5, C3, C1, CCP5, CCP3, dan CP3) [11].

Independent Component Analisis (ICA) adalah metode komputasi untuk memisahkan sinyal multivariat menjadi subkomponen aditif. Hal ini dilakukan dengan mengasumsikan bahwa subkomponen adalah sinyal non-Gaussian dan secara statistik independen satu sama lain. ICA adalah kasus khusus pemisahan sumber buta . Pada penelitian ini ICA memulihkan sinyal independen secara statistik dari sinyal hybrid linier menggunakan ukuran statistik orde tinggi. Artefak dan noise dalam sinyal EEG dapat dihilangkan oleh ICA. Sinyal EEG yang berisi EOG dan artefak yang berhubungan dengan EOG yang ada di saluran EEG dapat dihapus oleh ICA [20].

Elektroda terletak di dahi dan di hidung. Sinyal EEG difilter dengan band-pass antara 0,5 dan 100 Hz dengan frekuensi sampling dari 1000Hz. Impedansi setiap saluran disimpan di bawah 5kiloamper.



Selain itu, filter yang didapat dengan 50 Hz digunakan untuk menghilangkan gangguan frekuensi daya selama akuisisi data terjadi. Pada tahap pra-pemrosesan, data mentah di down sampling atau diturunkan samplingnya pada 200 Hz dan kemudian disaring secara spasial CAR (common average reference) [21].

Pada penelitian tersebut EEG-zero-time windowing (E2ZTW) digunakan untuk mengekstrak karakteristik spektral dari yang sangat pendek pada segmen percobaan EEG. E2ZTW ini mengubah durasi pendek di setiap percobaan pada setiap saluran dengan fungsi yang bentuknya mirip dengan respons frekuensi resonator nol. Dalam penelitian ini menggunakan dua teknik ekstraksi spektrum yaitu : Diskrit Fourier Transformasi (DFT) dan fungsi penundaan grup. Fungsi penundaan grup digunakan untuk mengekstrak spektrum dengan sifat resolusi tinggi dan menyorot fitur formant dari spektrum [22].

## **2. Metode ekstraksi sinyal, penanganan kanal, dan identifikasi (khusus sinyal EEG), metode identifikasi arah spasial dan arah temporal (video, dapat disederhanakan), metode prediksi (cuaca)**

Ekstraksi fitur menggunakan CNN multi layer dimana sinyal akan masuk pada 4 CNN yang memiliki arsitektur yang berbeda, pada CNN pertama hanya memiliki satu pooling, pada CNN kedua memiliki dua pooling dan begitu pula seterusnya sampai CNN ke empat, dalam CNN konvolusi pertama dilakukan diseluruh sample waktu (temporal) dan konvolusi kedua dilakukan di semua saluran channel (spasial). Hasil luaran dari seluruh CNN (1-4) akan digabungkan dengan concat, kemudian masuk pada klasifikasi dengan 2 tipe yaitu dengan MultiLayer Perceptron dan tipe lainnya adalah menggunakan autoencoder, penamaan CNN yang menggunakan klasifikasi MPL dinamakan dengan MCNN dan penamaan CNN dengan klasifikasi autoencoder dinamakan dengan CCNN [4].

Metode ekstraksi sinyal menggunakan CNN, dimana dalam penggunaannya mencoba dengan 2 varian CNN, kedua varian arsitektur CNN yang digunakan diantaranya ialah Compact CNN dan Shallow CNN, metode ekstraksi sinyal ini merupakan ekstraksi spasial dari sinyal EEG, kemudian hasil dari CNN akan menjadi nilai masuk pada metode selanjutnya yaitu LSTM (RNN) [2][3], metode LSTM (RNN) merupakan metode identifikasi untuk mendapatkan kelas dengan bantuan Fully Connected (FC) dan fungsi aktivasi softmax. Penamaan untuk penggunaan metode Compact CNN dan LSTM menjadi Series Compact Convolutional Recurrent Neural Network (SCCRNN) dan untuk Shallow CNN dan LSTM menjadi Series Shallow Convolutional Recurrent Neural Network (SSCRNN), Selain penggunaan kedua series tersebut terdapat kombinasi antara hasil luaran dari LSTM dan ekstraksi fitur dari CNN, keduanya dikombinasikan pada FC untuk diidentifikasi, kombinasi ini dinamakan dengan PSCCRNN dan PSSCRNN, dimana huruf P tersebut ialah parallel.

Metode Ekstraksi fitur spasial yang digunakan ialah CNN, namun penggunaan CNN [10] ini tidak sebatas hanya satu kali, hal ini karena hasil luaran dari CNN pertama (Ekstraksi spasial) akan masuk pada LSTM (RNN) [13] dan CNN ke dua. Dimana pada CNN kedua berfungsi untuk mencari kembali fitur spasial, dan pada LSTM berfungsi untuk mendapatkan fitur temporal. Kedua fitur yang telah didapatkan tersebut kemudian digabungkan dan masuk pada Fully Connected (FC) untuk diklasifikasikan, dalam FC terdapat fine tune training sebagai transfer learning. Penamaan keseluruhan metode ini ialah Hybrid Deep Neural Network – Transfer Learning (HDNN-TL) [3].

Dalam penelitian ini sinyal EEG hanya diambil fitur differential entropy (DE) karena menghasilkan akurasi yang baik pada saat proses.

Selanjutnya masuk pada Linier Dynamic System (LDS) untuk memperhalus proses. Kemudian masuk pada RNN (LSTM) untuk membantu prediksi hasil, hal ini karena penggunaan RNN lebih baik dari pada CNN dalam hal tersebut, CNN lebih baik pada bagian ekstraksi fitur yang dibutuhkan, implementasi LSTM ini adalah Bidirectional LSTM Networks (BiLSTM) dimana LSTM yang digunakan ialah tidak hanya mengirimkan urutan normal EEG tetapi juga urutan terbalik EEG ke metode pembelajaran, Atau dapat dikatakan dengan menggabungkan dua LSTM bersama-sama dan hasilnya disambungkan. Dimensi fitur luaraan BiLSTM cukup besar. dan harus dikurangi dimensi menjadi banyaknya jumlah kelas, dalam reduksi ini digunakan linier transform dan aktivasi softmax untuk mendapatkan kelasnya [7].

Metode CNN digunakan untuk melakukan ekstraksi fitur. Terdapat tiga buah layer convolutional dan dua buah layer fully connected. Ukuran data masukan adalah  $30 \times 25$  matriks. Filter convolutional pertama memproses dengan 10 kernal ukuran  $30 \times 1$  dengan stride 1 yang menghasilkan 10 fitur map dengan ukuran  $1 \times 25$ . Untuk layer convolutional kedua dan ketiga akan menggunakan 10 kernal dengan stride 1. Seluruh layer akan menggunakan fungsi aktivasi ReLU [10].

Untuk melakukan klasifikasi sinyal dan pemberian bobot untuk maka digunakan Stepwise Linear Discriminant Analysis (SWLDA). SWLDA merupakan ekstensi dari Fisher's Linear Discriminant Analysis. SWLDA akan memberikan nilai akurasi klasifikasi sinyal yang tinggi menggunakan P300 untuk aplikasi BCI. SWLDA akan memilih fungsi diskriminan yang sesuai dengan menambahkan kanal yang spesifik dan informasi waktu domain amplitude kedalam persamaan linear. Koefisien dari fungsi diskriminan ditentukan

menggunakan dataset latih. Penelitian ini menggunakan 400 poin dataset untuk proses klasifikasi [8].

Terdapat tiga buah metode klasifikasi yaitu Linear Discriminant Analysis (LDA), K Nearest Neighbors (kNN), dan Support Vector Machine (SVM). LDA akan memproyeksikan data kedalam hyperplanes untuk memaksimalkan pemisahan antara data dari kelas yang berbeda dan meminimalisasi variansi data yang berada di kelas yang sama. LDA sering digunakan untuk metode klasifikasi BCI karena memiliki permintaan komputasional yang rendah dan efisien [17]. Klasifikasi kNN akan menentukan kelas sample berdasarkan pilihan mayoritas dari sample k neighboring [9].

Algoritma FBCSP diaplikasikan kedalam sinyal pada masing-masing filter pita frekuensi. Hal tersebut akan merancang filter spasial yang dapat menambahkan diferensiasi antara dua tipe pola EEG didalam variasi tersebut. Metode klasifikasi yang digunakan adalah Linear Discriminant Analysis (LDA). Pada eksperimen pertama, percobaan dievaluasi menggunakan cross validation untuk masing-masing pendekatan, yaitu: VR+berdiri, VR+duduk, Layar+berdiri, dan layar+duduk. Pada eksperimen kedua, classifier dilatih menggunakan percobaan open-loop, lalu pada percobaan close-loop tiap epoch data diklasifikasi menjadi motor imagery atau keadaan istirahat [13].

Dalam penelitian ini, metode yang digunakan adalah Discrete Wavelet Transform (DWT). Metode ini akan membantu dalam menganalisis sinyal dalam jangka domain waktu dan frekuensi. Lima statistik fitur, yaitu, Standar deviasi, Median, Mean, Minimum, dan Maksimum terintegrasi dengan DWT. Untuk melakukan klasifikasi tugas mental, seorang Artificial Jaringan Syaraf Tiruan (JST) yang digunakan. ANN sebagai metode klasifikasi nonlinier telah banyak digunakan dieksplorasi untuk aplikasi biomedis termasuk BCI berbasis EEG [16].

Canonical Correlation Analysis (CCA) mengeksplorasi mengenai korelasi antara dua buah set data dalam metode multivariable statistical. Metode CCA memberikan performa pengenalan yang lebih baik dibanding dengan Power Spectral Density (PSD) analisis karena dapat memberikan optimisasi terhadap multiel kanal untuk memperbaiki signal to noise ratio (SNR). Karakteristik yang dikumpulkan sinyal EEG menggunakan PSD untuk memilih representasi dari respon SSVEP. Kanal dipilih untuk selanjutnya dianalisis menggunakan PSD. Selanjutnya fast fourier transform digunakan untuk mengkalkulasi power spektrum yang telah di pre proses oleh kanal Oz untuk waktu stimulasi selama empat detik [15].

Pada tingkatan ini, fitur-fiturnya kembali logaritmik kekuatan band, tetapi mereka dioptimalkan secara spasial menggunakan Filter CSP dan mengubah derivasi Laplace termasuk fleksibilitas spasial fitur. pengklasifikasian menggunakan LDA dengan penyusutan matriks kovarians dan dihitung ulang setelah setiap percobaan. Di tingkatan selanjutnya terdiri dari kekuatan pita logaritmik dari fixed Filter CSP yang diklasifikasikan dengan LDA yang diadaptasi dalam lingkungan untuk dapat menilai BCI kendali pengguna [17].

Pada penelitian ini (data individu) analisis statistik dari data fmri dilakukan dengan menggunakan model linier umum (GLM). Spasial parameter penataan kembali dari preprocessing digunakan sebagai tambahan regresi. Selain itu, fi high-pass Filter dengan cutoff 128 detik diterapkan untuk menghilangkan penyimpangan lambat dalam data. Korelasi serial dalam fmri deret waktu dicatat menggunakan model autoregresif [18].

Pada penelitian ini menggunakan alat MEG. MEG dipilih untuk bukti awal prinsip ini yaitu BCI pada stroke kronis karena non-invasif dan temporal. Dua fitur tambahan pada alat MEG membuatnya diinginkan relatif terhadap EEG. Medan magnet yang dihasilkan oleh

aktivitas otak minimal terdistorsi oleh otak, membuat MEG sangat cocok untuk studi stroke. Selanjutnya, pengumpulan data MEG tidak memerlukan lampiran kulit kepala elektroda atau prosedur pembersihan terkait yang digunakan untuk mengurangi elektroda impedansi. Karena itu membuat MEG menjadi alat ideal untuk perekaman online dan lokalisasi perubahan ritme kortikal dinamis pada otak [19].

Pada penelitian ini berfokus pada proses ekstraksi fitur dimana menggunakan locally-robust feature selection (LRFS) yang didalamnya terdapat 3 bagian untuk menentukan fitur yang akan digunakan, tahap pertama dalam melakukan ekstraksi fitur ialah evaluasi konsistensi fitur dengan menentukan terlebih dahulu model kepadatan fitur dari setiap subyek, kemudian hitung probabilitas kepadatan model dan mengubahnya menjadi sebuah vector. Tahap kedua ialah mencari fitur terkuat dengan menyortir fitur dengan algoritma individual ranking dan menemukan fitur yang optimal (terkuat). Selanjutnya tahap ketiga ialah menggabungkan fitur-fitur optimal untuk diklasifikasikan, dalam klasifikasi hanya menggunakan least square support vector machine (LSSVM) [1].

Dalam ekstraksi sinyal dan klasifikasi menggunakan Convolutional Neural Network, dalam CNN ini menggunakan beberapa arsitektur untuk diantaranya ialah vgg19, vgg16, alexnet dan lain-lainnya, penggunaan beberapa ini ialah berfungsi untuk transfer learning, kemudian klasifikasi pada CNN menggunakan fully connected layer dan fungsi aktivasi softmax untuk menentukan kelas apakah masuk dalam kiri atau kanan [2].

Metode yang digunakan dalam ekstraksi fitur penelitian ini ialah Hilbert Transform HT dan Hilbert Transform ditambah dengan jumlah derivative SDR. Dalam Transformasi Hilbert terdapat pergeseran sebesar 2 fase namun tanpa mengubah isi amplitudo sinyal tersebut.

Kemudian hasil ekstraksi akan masuk dalam klasifikasi dengan menggunakan SVM, dalam klasifikasi ini menentukan hyperplane yang paling tepat pada kumpulan data pelatihan untuk memisahkan label kelas menjadi subkelompok [3].

Metode yang digunakan pada penelitian ini adalah metode CNN satu dimensi. Tiga data yang berbeda yaitu data EEG, oxy-NIRS dan deoxy-NIRS masing-masing memiliki ukuran (kanal x waktu) yang berbeda yaitu secara berturut-turut adalah 30 x 600, 36 x 30, dan 36 x 30. Data sinyal EEG dan NIRS kemudian akan masuk arsitektur CNN 1D. Pertama-tama data akan masuk kedalam convolutional layer yang berisikan batch-norm layer and a ReLU layer. Tahap convolutional layer akan diulang sebanyak enam kali dengan ukuran filter adalah 9 dan 3, ukuran stride adalah 4 dan 1, dan ukuran padding adalah 0 yang dipilih secara berbeda pada masing-masing layer. Setelah convolutional layer selesai, maka dilanjutkan kedalam layer pooling 1D, ReLU, dan diakhiri dengan layer softmax. Data EEG dan NIRS menggunakan arsitektur CNN yang sama, yang membedakan hanya ukuran masukan dan keluaran yang dihaluskan pada masing-masing layer [12].

Pada saat eksperimen berlangsung, tiga buah kondisi stimulus dilakukan mulai dari waktu 233 – 800 ms. Pada waktu 0 – 233 ms, data yang diterima digunakan untuk sebagai basis koreksi untuk penelitian. Seluruh epoch yang dilakukan pada target dan non-target kemudian dirata-rata untuk melihat nilai rata-rata dari ERP. Untuk klasifikasi offline, lima buah data dengan nilai diskriminasi tertinggi diambil berdasarkan penelitian yang telah dilakukan. Nilai rata-rata ERP diperoleh dari perkalian antara jumlah kanal dan jumlah jendela yang digunakan dengan kata lain jumlah fitur tersiri dari 315 buah dimensi (63 kanal x 5 kali jendela). Data sesi training dan tes digunakan untuk membuat klasifikasi Regularized Linear

Discriminant Analysis dengan Shrinkage (S-RLDA) dari matriks kofarian [14].

Untuk setiap grup, data yang telah dilakukan pra proses lalu di filter menggunakan Common Spatial Patterns (CSP) yang telah dikalkulasi sebelumnya. Kemudian sequens dari fitur CSP didapatkan dari ekstraksi segmen yang dilakukan selama 1000 ms pada jendela dengan ukuran step sebesar 50 ms, dan menghitung log-variance dari data CSP yang telah di filter di dalam segmen tersebut [11].

#### **4. Hasil yang diujikan yang meliputi semua eksperimen yang dilakukan penelitian dalam paper tersebut.**

Hasil pengujian didapatkan bahwa penggunaan MCNN dalam klasifikasi mendapatkan nilai akurasi mencapai 75,7% dan 95,4%, hasil ini didapatkan dengan beberapa kali pengujian, pertama dalam menentukan penggunaan banyaknya CNN dalam penggabungan fitur, hasil yang dicapai adalah nilai akurasi terus meningkat pada CNN dengan pooling ke 4 (CNN-4), kemudian pengujian klasifikasi terhadap kombinasi penggabungan fitur, selain itu terdapat pengujian terhadap setiap subjek dan didapatkan bahwa nilai rata-rata terbaik ditunjukkan oleh metode MCNN, sama hal nya dengan pengujian terhadap hasil klassifikasi dimana nilai tertinggi dimiliki oleh MCNN, namun walaupun menghasilkan nilai akurasi yang baik penggunaan MCNN ini memiliki waktu yang jauh lebih lama dari pada metode lainnya [4].

Hasil akurasi tertinggi didapatkan oleh series SCCRNN, dengan Membandingkan dua jenis CNN, hasil rata-rata Shallow CNN lebih rendah dari Compact CNN. Alasannya adalah kuantitas data pelatihan kecil, dan tidak mudah untuk mencapai solusi optimal untuk Shallow CNN. selain dengan metode-metode yang digunakan perbandingan juga dilakukan dengan CSP dan SVM namun hasil akurasi rata-rata yang didapatkan tidak lebih tinggi dibanding dengan metode-metode yang disusulkan, pengujian



ini dilakukan secara langsung pada seluruh data namun dilakukan pada setiap subyek [5].

Dalam pengujian terdapat dilakukan perbandingan antara penggunaan HDNN-TL dan HDNN tanpa TL, hasilnya ialah HDDN-TL memberikan nilai pada pengujian yang lebih tinggi untuk tiap obyek, selain itu penggunaan banyaknya sampel cukup berpengaruh pada akurasi, dimana semakin banyak sampel yang digunakan menghasilkan akurasi yang semakin tinggi pada setiap obyek. walaupun sudah menghasilkan nilai yang lebih baik dari HDNN tetapi masih terdapat nilai yang belum lebih baik dari penelitian sebelumnya tepatnya pada obyek ke 2, 3, 4, 5 dan 7[6].

Dari hasil yang diujikan terhadap data SEED IV, model yang dibentuk menghasilkan akurasi yang lebih baik dari banding 2 penelitian sebelumnya, hal ini karena penggunaan DE dan ekstrasi fitur menggunakan BiLSTM, hasil akhir yang diberikan ialah akurasi mencapai 84,21%, lebih tinggi dibandingkan dengan penelitian terdahulu yang menggunakan KNN, SVM dan Logistic Regression (LR)[7].

Data yang didapat dari semua subjek dikumpulkan lalu dianalisis. Hasil klasifikasi dari delapan buah sequen disimpan dalam matrik untuk mendeteksi karakter huruf. Berdasarkan stage pertama dari P300, dihasilkan bahwa region pertama mendapatkan nilai tertinggi di angka 4 yang mengandung huruf "A", "B", "C", "D", "E", dan "F". lalu region dari stage pertama masuk kedalam stage kedua yang memiliki enam buah region. Berdasarkan stage kedua, didapatkan bahwa region ketiga mendapatkan nilai terbesar dengan nilai 5. Maka dari itu dapat disimpulkan bahwa huruf yang dipilih subjek adalah huruf "C". Nilai akurasi klasifikasi rate-rate dari mode visual, audio, dan audio-visual (Hybrid) berturut-turut adalah 78.06%, 54.08%, dan 90.31%. Nilai akurasi klasifikasi dengan mode audio-visual menyentuh nilai 90%, mode visual menyentuh nilai 80%, sedangkan mode audio hanya menyentuh nilai 60% saja [8].

Secara keseluruhan, hasil yang didapat menunjukkan peningkatan. Akurasi dari masing-masing kelas tidak terlalu jauh. Jika terdapat nilai threshold sebesar 90% maka jumlah subjek yang mencapai nilai threshold pada kelas AR-Pos2 lebih tinggi dibandingkan dengan posisi lainnya dalam seluruh waktu. Pada saat waktu uji diatas tiga detik, nilai akurasi yang diperoleh tidak meningkat secara signifikan. Secara keseluruhan, kelas AR-Pos2 mencatatkan rata-rata nilai akurasi sebesar 74.6% pada detik pertama, 89% pada detik kedua, 94,6% pada detik ketiga dan 95,6% pada detik keempat [15].

Berdasarkan hasil yang didapat sinyal EEG yang kuat berkorelasi dengan respon time muncul pada area frontal theta (korelasi negatif) dan area parietal-occipital alpha (korelasi positif) yang mengindikasikan bahwa informasi dapat diekstraksi dari area hair-covered dan NHB. Analisis statistic menunjukkan diskriminatif fitur yang sangat kuat pada pita alpha pada area yang tertutupi rambut dan NHB. Meskipun demikian terdapat perbedaan spektrum pada NHB EEG antara short dan long respon time yang sedikit lebih lemah dibanding dengan yang ditutupi rambut [9].

Pada eksperimen pertama tidak dihasilkan perbedaan nilai yang signifikan. Variasi antara protocol yang berbeda menghasilkan nilai yang setara yang mana menunjukkan bahwa test yang dilakukan Mauchy dapat dikonfirmasi benar. Shapiro-Wilk test dilakukan untuk menentukan apakah performa pada tiap protocol mengikuti normal distribusi dan hasilnya menunjukkan bahwa semua grup mengikuti normal distribution. Pada eksperimen kedua didapatkan hasil persentase total, MI, dan istirahat. Untuk subjek S21 menghasilkan nilai total sebesar 82.3%, nilai MI sebesar 88.1%, dan nilai istirahat sebesar 76.5%. sedangkan untuk subjek S22 menghasilkan nilai total sebesar 84.6%, nilai MI sebesar 82.3%, dan nilai istirahat sebesar 86.9% [13].

Setelah dilakukan sepuluh kali percobaan menggunakan subjek yang sama menghasilkan nilai rata-rata tingkat akurasi sebesar 83,74 %. Nilai

akurasi tertinggi mencapai nilai 89.19 % yang didapat pada percobaan kesepuluh sedangkan nilai akurasi terendah sebesar 18.10 % didapatkan pada percobaan pertama. Terdapat kenaikan nilai akurasi yang signifikan diawal percobaan tetapi mulai berkurang pada saat masuk percobaan keempat[10].

Pada percobaan-1, model diuji tanpa optimasi dan akurasi klasifikasi adalah 70%. Dalam percobaan-2 model diuji sementara sedang dioptimalkan menggunakan optimasi pencarian Grid metode dan hasil akurasi adalah 73%. Yang terakhir dua eksperimen yang dilakukan untuk mengevaluasi perilaku model pada dataset subjek tunggal. Percobaan-3 dilakukan pada dataset pelatihan dan eksperimen-4 dilakukan pada dataset evaluasi. Hasil dari percobaan-3 dan percobaan-4 disajikan dalam Tabel-1 dan Tabel-2, masing-masing. Bisa jadi disimpulkan dari hasil bahwa efisiensi model MLP yang dioptimalkan meningkat sebesar 3% dari yang besar dataset dibandingkan dengan model yang tidak dioptimalkan. Saya dapat didedikasikan bahwa model yang dioptimalkan dapat dikerahkan dalam kontrol kursi roda BCI berbasis MI sistem untuk membantu para penyandang cacat untuk kehidupan sehari-hari mereka kegiatan[16].

Peningkatan pembobotan T1 MR-intensitas yang ditemukan untuk Kelompok MI-BCI mungkin karena lateralisasi MI-task (melatih tangan dan kaki kanan yang terkait dengan gerakan kursor ke kanan dan ke bawah, masing-masing). Gerakan tersebut 'berhasil' dengan itu hasil gerakan tangan kanan dalam gerakan kursor ke kanan di layer [17].

Data dari rekaman EEG untuk citra motorik aktivitas otak terkait yang digunakan untuk memilih peserta kelompok pengguna berkemampuan tinggi dan rendah. Sepuluh pengguna berkemampuan tinggi dan 10 rendah berpartisipasi dalam percobaan fMRI. Ke-20 peserta mencapai kinerja rata-rata 82,1% dalam tugas umpan balik EEG SMR-BCI. Tidak ada efek gender ditemukan dalam kinerja EEG dari semua 80 peserta. Kinerja rendah

(64,2%) dan pengguna bakat tinggi (91,2%) berbeda secara signifikan terus menerus[18].

Tingkat keberhasilan dari pasien tersebut rata-rata berasal dari sesi percobaan dan pelatihan. Keberhasilan rata-rata pada percobaan terakhir adalah 72,48 % (rentang interkuartil median). Deret waktu untuk setiap individu diambil sampelnya kembali dan dinormalisasi hingga 20 sesi (modus sesi durasi di seluruh kelompok pasien) menggunakan linear interpolasi, sebelum dirata-ratakan. abu-abu daerah yang diarsir mewakili 95% CI dari estimasi median, yang dihitung menggunakan teknik bootstrap diulang 10.000 kali. Dengan begitu tingkat keberhasilan meningkat[19].

Pengujian yang dilakukan pada penelitian ini ialah melakukan perbandingan lama waktu komputasi dan hasil nilai standar deviation. Penggunaan LRFS jika dibanding dengan local learning-based clustering (LLC) memiliki waktu dan standar deviation yang jauh lebih kecil dengan nilai , yang artinya memiliki waktu komputasi dan standar deviation yang lebih baik, kemudian pengujian akurasi juga dilakukan pada beberapa metode klasifikasi lainnya seperti KNN, Naïve Bayes, logistic regression dll, namun hasil akurasi nilai yang lebih baik didapatkan tetap dengan menggunakan LSSVM (metode yang diusulkan) dengan nilai 0.65 untuk arousal dan 0.67 untuk valence pada dataset DEAP, nilai 0.67 (arousal) dan 0.69 (valence) pada dataset MAHNOB-HCI[1].

Dalam pengujian dan pelatihan dilakukan transfer learning antara beberapa arsitektur CNN, transfer learning ini dilakukan untuk fitur-fitur yang digunakan setelah masuk dari filter Wavelate, dalam menentukan metode cnn mana yang lebih baik terdapat perbandingan hasil nilai menggunakan fungsi kappa dan didapatkan nilai tertinggi menggunakan vgg 19 dengan 91%, selanjutnya terdapat perbandingan akurasi akhir dengan penelitian terdahulu dengan perbandingan 5% lebih baik dan dengan nilai akurasi hasil 95,71% [2].

Pengujian dilakukan berdasarkan channel yang paling efektif, hasil akurasi uji rata-rata 80,35% untuk dataset 1, yaitu 22,42% lebih baik dari hasil seluruh channel, kemudian tertinggi dicapai untuk Subjek 17, Subjek 21 dan Subjek 28 pada 90%, terendah adalah Subjek 9, Subjek 12 dan Subjek 16 sebesar 73,34%, kemudian pada dataset lain Di sisi lain, untuk dataset 2, kami memperoleh CA uji 91,12%, yang 9,55% lebih baik dari hasilnya dari semua channel [3].

Hasil yang muncul merupakan komparasi dari eksperimen sebelumnya dengan metode yang digunakan pada eksperimen ini. Terdapat perbaikan nilai akurasi yang signifikan pada saat menggunakan metode di eksperimen ini. Pada tugas Motor Imagery, hasil dari EEG, oxy-NIRS, deoxy-NIRS, LF (Linear Fusion), TF (Tensor Fusion) and PF (Polynomial Fusion) berturut-turut bernilai (71.55%), (67.01%), (69.31%), (75.29%), (75.34%) dan (77.53%) (5th-order). Sedangkan pada tugas Mental Aritmatika menghasilkan nilai berturut-turut sebesar (81.60%), (86.28%), (84.42%), (89.68%), (87.44%) dan (90.19%)(3rd-order) [12].

Pada penelitian ini, terdapat tiga tipe RSVP spellers yang kemudian dilakukan komparasi mengenai nilai akurasi menggunakan metode yang telah diperbaharui. Nilai hasil yang dikeluarkan pada eksperimen di masing-masing tipe menunjukkan nilai yang tergolong tinggi untuk tipe NM-RSVP, RM-RSVP, dan FM-RSVP speller yang berturut-turut mendapat hasil  $79.06 \pm 6.45\%$ ,  $90.60 \pm 2.98\%$ , dan  $92.74 \pm 2.55\%$  [14].

Pada akhir penelitian, didapatkan nilai error dari klasifikasi yang mana menggunakan ukuran window sebesar 1000 ms. Data nilai erro yang dihasilkan berdasarkan 4 jendela engan estimasi 400 ms. Pada awal jendela (0 – 100 ms) nilai error mencapai nilai tertinggi dengan nilai 50% lalu berangsur angsur menurun sampai titik terendah di nilai 8 % pada jendela 2000 ms dan kemudian semakin naik dengan perlahan sampai pada akhir jendela menyentuh nilai error sebesar 20% di jendela 4000 ms [11].

Berdasarkan metode ekstraksi tersebut komponen independen EEG dapat mengisolasi komponen EOG menggunakan ICA dan kemudian merekonstruksi EEG. Perbandingan akurasi klasifikasi dalam metode ekstraksi fitur yang berbeda – beda. Akurasi klasifikasi fitur CSP adalah 63,25% dan fitur CSP setelah penghapusan ICA komponen EOG adalah 63,39% yang meningkatkan akurasi klasifikasi dari citra motor EEG. Hasil klasifikasi fitur CSP yang diekstraksi setelah ICA dan PSR adalah 67,90%. Oleh karena itu, akurasi klasifikasi dapat ditingkatkan dengan mengekstraksi komponen independen dari ICA untuk menghilangkan interferensi EOG dan kemudian merekonstruksi EEG ke dalam ruang fase dimensi tinggi untuk mengekstrak fitur CSP. [20]

Rata-rata akurasi klasifikasi paradigma hybrid mencapai 76,39%, dengan nilai maksimum 88,34% dan nilai minimum 60%. Ini tidak hanya secara signifikan lebih tinggi dari yang diharapkan dengan pemilihan peluang tetapi juga secara signifikan lebih tinggi dari kondisi MI dengan peningkatan sebesar 11,66%. Hasil ini menunjukkan bahwa metode hibrida yang digunakan dalam penelitian ini dapat secara efektif meningkatkan resolusi spasial pengenalan MI di berbagai bagian persoalan dan masalah yang sama.[21]

Untuk akurasi klasifikasi yang diperoleh oleh dua pengklasifikasi (CNN dan LDA) dengan parameter E2ZTW yang berbeda. Pada klasifikasi yang diperoleh LDA untuk percobaan pertama berkurang 20%. Mempertahankan konfigurasi yang sama pada percobaan kedua, akurasi klasifikasi meningkat sebesar 6%. Untuk konfigurasi yang berbeda, LDA mengungguli CNN, di mana akurasi klasifikasi rata-rata melebihi 17%. Konfigurasi terakhir ini memungkinkan akurasi rata-rata maksimum untuk semua kumpulan data yang diperoleh. Akurasi antara LDA dan CNN disebabkan oleh dimensi kecil dari fitur yang diekstraksi oleh CSP. Faktanya, model CNN akan overfit dan memberikan kinerja yang buruk saat menggunakan fitur yang lainnya. Tidak seperti CNN, algoritma LDA

mengungguli ketika dimensi fitur per percobaan terlalu kecil dan kinerjanya menurun secara signifikan ketika dimensi meningkat. Dengan begitu, pada penelitian ini dengan menggunakan metode pengklasifikasi LDA, CSP dan pendekatan E2ZTW dengan parameter terbaik yang teridentifikasi. Dengan metode tersebut yang digunakan mencapai 85,30%, 81,85%, 84,86% masing-masing. Dengan begitu LDA lebih tinggi dari pada yang lainnya. [22]

## 5. Daftar Referensi

- [1] Z. Yin, L. Liu, J. Chen, B. Zhao, and Y. Wang, “Locally robust EEG feature selection for individual-independent emotion recognition,” *Expert Systems with Applications*, vol. 162, p. 113768, 2020, doi: 10.1016/j.eswa.2020.113768.
- [2] P. Kant, S. H. Laskar, J. Hazarika, and R. Mahamune, “CWT Based Transfer Learning for Motor Imagery Classification for Brain computer Interfaces,” *Journal of Neuroscience Methods*, vol. 345, no. July, p. 108886, 2020, doi: 10.1016/j.jneumeth.2020.108886.
- [3] O. Aydemir and E. Ergün, “A robust and subject-specific sequential forward search method for effective channel selection in brain computer interfaces,” *Journal of Neuroscience Methods*, vol. 313, pp. 60–67, 2019, doi: 10.1016/j.jneumeth.2018.12.004.
- [4] S. U. Amin, M. Alsulaiman, G. Muhammad, M. A. Mekhtiche, and M. Shamim Hossain, “Deep Learning for EEG motor imagery classification based on multi-layer CNNs feature fusion,” *Future Generation Computer Systems*, vol. 101, pp. 542–554, 2019, doi: 10.1016/j.future.2019.06.027.
- [5] L. Wang, W. Huang, Z. Yang, and C. Zhang, “Biomedical Signal Processing and Control Temporal-spatial-frequency depth extraction of brain-computer interface based on mental tasks,” *Biomedical Signal Processing and Control*, vol. 58, p. 101845, 2020, doi: 10.1016/j.bspc.2020.101845.

- [6] R. Zhang, Q. Zong, L. Dou, X. Zhao, Y. Tang, and Z. Li, “Biomedical Signal Processing and Control Hybrid deep neural network using transfer learning for EEG motor imagery decoding,” vol. 63, no. August 2020, 2021.
- [7] J. Yang, X. Huang, H. Wu, and X. Yang, “EEG-based emotion classification based on Bidirectional Long Short-Term Memory Network,” *Procedia Computer Science*, vol. 174, no. 2019, pp. 491–504, 2020, doi: 10.1016/j.procs.2020.06.117.
- [8] Z. Oralhan, “A New Paradigm for Region-Based P300 Speller in Brain Computer Interface,” *IEEE Access*, vol. 7, pp. 106618–106627, 2019, doi: 10.1109/ACCESS.2019.2933049.
- [9] C. S. Wei, Y. Te Wang, C. T. Lin, and T. P. Jung, “Toward Drowsiness Detection Using Non-hair-Bearing EEG-Based Brain-Computer Interfaces,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 26, no. 2, pp. 400–406, 2018, doi: 10.1109/TNSRE.2018.2790359.
- [10] W. Gao *et al.*, “Learning Invariant Patterns Based on a Convolutional Neural Network and Big Electroencephalography Data for Subject-Independent P300 Brain-Computer Interfaces,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, pp. 1–1, 2021, doi: 10.1109/tnsre.2021.3083548.
- [11] C. L. Maeder, C. Sannelli, S. Haufe, and B. Blankertz, “Pre-stimulus sensorimotor rhythms influence brain-computer interface classification performance,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 20, no. 5, pp. 653–662, 2012, doi: 10.1109/TNSRE.2012.2205707.
- [12] Z. Sun, Z. Huang, F. Duan, and Y. Liu, “A Novel Multimodal Approach for Hybrid Brain-Computer Interface,” *IEEE Access*, vol. 8, pp. 89909–89918, 2020, doi: 10.1109/ACCESS.2020.2994226.



- [13] L. Ferrero, M. Ortiz, V. Quiles, E. Iáñez, and J. M. Azorín, “Improving motor imagery of gait on a brain–computer interface by means of virtual reality: A case of study,” *IEEE Access*, vol. 9, pp. 49121–49130, 2021, doi: 10.1109/ACCESS.2021.3068929.
- [14] D. O. Won, H. J. Hwang, D. M. Kim, K. R. Müller, and S. W. Lee, “Motion-Based Rapid Serial Visual Presentation for Gaze-Independent Brain-Computer Interfaces,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 26, no. 2, pp. 334–343, 2018, doi: 10.1109/TNSRE.2017.2736600.
- [15] X. Zhao, C. Liu, Z. Xu, L. Zhang, and R. Zhang, “SSVEP Stimulus Layout Effect on Accuracy of Brain-Computer Interfaces in Augmented Reality Glasses,” *IEEE Access*, vol. 8, pp. 5990–5998, 2020, doi: 10.1109/ACCESS.2019.2963442.
- [16] E. Mhmood, “Tikrit Journal of Pure Science,” *Tikrit Journal of Pure Science*, vol. 23, no. 9, pp. 1813–1662, 2018.
- [17] T. Nierhaus, C. Vidaurre, C. Sannelli, K. R. Mueller, and A. Villringer, “Immediate brain plasticity after one hour of brain–computer interface (BCI),” *Journal of Physiology*, vol. 599, no. 9, pp. 2435–2451, 2021, doi: 10.1113/JP278118.
- [18] S. Halder *et al.*, “Neural mechanisms of brain-computer interface control,” *NeuroImage*, vol. 55, no. 4, pp. 1779–1790, 2011, doi: 10.1016/j.neuroimage.2011.01.021.
- [19] E. Buch *et al.*, “Think to move: A neuromagnetic brain-computer interface (BCI) system for chronic stroke,” *Stroke*, vol. 39, no. 3, pp. 910–917, 2008, doi: 10.1161/STROKEAHA.107.505313.
- [20] E. Dong, K. Zhou, J. Tong, and S. Du, “A novel hybrid kernel function relevance vector machine for multi-task motor imagery EEG classification,” *Biomedical Signal Processing and Control*, vol. 60, p.

101991, 2020, doi: 10.1016/j.bspc.2020.101991.

- [21] Z. Chen, Z. Wang, K. Wang, W. Yi, and H. Qi, "Recognizing Motor Imagery between Hand and Forearm in the Same Limb in a Hybrid Brain Computer Interface Paradigm: An Online Study," *IEEE Access*, vol. 7, pp. 59631–59639, 2019, doi: 10.1109/ACCESS.2019.2915614.
- [22] K. Belwafi, S. Gannouni, and H. Aboalsamh, "An Effective Zeros-Time Windowing Strategy to Detect Sensorimotor Rhythms Related to Motor Imagery EEG Signals," *IEEE Access*, vol. 8, pp. 152669–152679, 2020, doi: 10.1109/ACCESS.2020.3017888.

### Kelompok

<b>Nama</b>	<b>Paper yang di-review</b>	<b>Peran</b>
Satrio Ananda (ketua)	Analisis Jurnal [1]–[7]	Review paper Science Direct, Perbaikan Kebaruan paper [1]–[7], Penambahan narasi Tabel Keyword, Karakteristik data yang digunakan [1]–[22]
Indiarto Aji Begawan (anggota)	Analisis Jurnal [8]–[15]	Review paper IEEE Xplore, Perbaikan metode pra proses [1] – [22], Perbaikan Kebaruan paper [8]–[15]
Diyas Ishlahuddin (anggota)	Analisis Jurnal [16]–[22]	Review paper Google Scholar, Perbaikan Kebaruan paper [16]–[22], Perbaikan grafik setiap paper